2025

Analiza sprzedaży w firmie Adventure Works Cycles

INŻYNIERIA HURTOWNI DANYCH

TOBIASZ MAZUR

UNIWERSYTET EKONOMICZNY W KATOWICACH

Spis treści

Bezpieczeństwo danych w hurtowniach danych: strategie ochrony przed zagrożeniami i naruszeniami 2

1.Cel realizacji Projektu 10

2. Opis źródeł danych 11

3.Model logiczny hurtowni danych w oparciu o schemat gwiazdy 16

4.Opis procesów ETL 25

5.Podsumowanie 37

Bezpieczeństwo danych w hurtowniach danych: strategie ochrony przed zagrożeniami i naruszeniami

Wprowadzenie

Hurtownie danych odgrywają kluczową rolę w zarządzaniu informacjami w nowoczesnych organizacjach. Gromadzenie, przechowywanie i analiza ogromnych ilości danych umożliwiają podejmowanie lepszych decyzji biznesowych. Jednak wraz z rosnącą wartością danych rośnie również ryzyko związane z ich bezpieczeństwem. W niniejszym opracowaniu omówione zostaną strategie ochrony przed zagrożeniami i naruszeniami w hurtowniach danych.

Znaczenie bezpieczeństwa danych

Dane są często postrzegane jako jedno z najcenniejszych aktywów organizacji. Utrata, kradzież lub nieuprawniony dostęp do danych (np. dane o klientach) może prowadzić do poważnych konsekwencji, takich jak:

- Straty finansowe,
- Uszkodzenie reputacji,
- Sankcje prawne i regulacyjne.

Hurtownie danych, jako centralne repozytoria, są szczególnie narażone na różnorodne zagrożenia, w tym ataki cybernetyczne, błędy ludzkie oraz awarie technologiczne. Dlatego ochrona danych w tych systemach jest priorytetem.

Rodzaje zagrożeń w hurtowniach danych

1. Ataki cybernetyczne

- Phishing i ataki socjotechniczne: Wyłudzanie danych uwierzytelniających przez oszukańcze wiadomości e-mail lub strony internetowe.
- Malware: Złośliwe oprogramowanie, które może infiltrować systemy w celu kradzieży danych.
- Ransomware: Ataki szyfrujące dane i wymagające okupu za ich odblokowanie.

2. Zagrożenia wewnętrzne

- Nieuprawniony dostęp: Pracownicy lub współpracownicy mogą uzyskać dostęp do danych, do których nie powinni mieć uprawnień.
- Sabotaż lub błędy: Działania celowe lub niezamierzone mogą prowadzić do utraty lub ujawnienia danych.

3. Zagrożenia związane z technologią

- Awarie sprzętu: Uszkodzenie serwerów lub nośników danych może prowadzić do utraty danych.
- Luki w oprogramowaniu: Niezaktualizowane systemy mogą być podatne na ataki ze względu na stara wersje zabezpieczeń systemowych.

Strategie ochrony danych

1. Kontrola dostępu

a) Uwierzytelnianie

- Wdrożenie wielopoziomowego uwierzytelniania (MFA, ang. Multi-Factor Authentication).
- Używanie silnych haseł oraz ich regularna zmiana.
- Stosowanie mechanizmów Single Sign-On (SSO) dla uproszczenia zarządzania dostępem.

b) Autoryzacja

- Implementacja zasad najmniejszego uprzywilejowania (ang. Principle of Least Privilege), które pozwala użytkownikom na dostęp wyłącznie do tych zasobów, które są niezbędne do wykonywania ich obowiązków.
- Użycie ról użytkownika (ang. Role-Based Access Control, RBAC) i precyzyjne definiowanie uprawnień.

2. Szyfrowanie danych

a) Szyfrowanie w spoczynku

- Szyfrowanie danych przechowywanych w hurtowni przy użyciu silnych algorytmów, takich jak AES-256.
- Wdrożenie mechanizmów zarządzania kluczami szyfrującymi (ang. Key Management Systems, KMS).

b) Szyfrowanie w trakcie przesyłania

- Stosowanie protokołów takich jak TLS (ang. Transport Layer Security) w celu zabezpieczenia danych podczas przesyłania między systemami.
- Wykorzystywanie wirtualnych sieci prywatnych (VPN) dla połączeń między hurtownią danych a klientami.

3. Monitorowanie i detekcja zagrożeń

a) Systemy monitorowania

- Wdrożenie systemów SIEM (ang. Security Information and Event Management) do monitorowania logów, aktywności użytkowników i anomalii w czasie rzeczywistym.
- Regularne analizowanie logów pod kątem potencjalnych prób naruszeń.

b) Mechanizmy detekcji

- Zastosowanie systemów IDS/IPS (ang. Intrusion Detection/Prevention Systems) do wykrywania i zapobiegania nieautoryzowanym próbom dostępu.
- Korzystanie z technologii analizy behawioralnej w celu identyfikacji nietypowych działań użytkowników.

4. Bezpieczeństwo fizyczne

- Ograniczenie fizycznego dostępu do serwerów, na których przechowywana jest hurtownia danych, poprzez zastosowanie systemów kontroli dostępu, takich jak karty dostępu, biometryka czy monitoring wideo.
- Stosowanie redundancji zasilania oraz ochrony przeciwpożarowej w centrach danych.

5. Zarządzanie danymi

a) Maskowanie danych

- Maskowanie wrażliwych danych podczas ich przetwarzania lub udostępniania użytkownikom, którzy nie potrzebują pełnego dostępu do oryginalnych danych.

b) Anonimizacja

- Stosowanie technik anonimizacji danych wrażliwych przed ich udostępnieniem do analiz.

c) Klasyfikacja danych

- Klasyfikacja danych w celu określenia poziomu ich wrażliwości i dostosowania polityk bezpieczeństwa.

6. Testowanie bezpieczeństwa

a) Testy penetracyjne

- Regularne przeprowadzanie testów penetracyjnych w celu identyfikacji potencjalnych luk w zabezpieczeniach.

b) Audyty bezpieczeństwa

- Zewnętrzne audyty, które oceniają zgodność z międzynarodowymi standardami bezpieczeństwa, takimi jak ISO 27001 czy SOC 2.

7. Kopie zapasowe i przywracanie danych

- Regularne wykonywanie kopii zapasowych wszystkich danych hurtowni, przechowywanie ich w odizolowanych lokalizacjach oraz szyfrowanie tych kopii.
- Testowanie planów przywracania danych w celu zapewnienia ciągłości działania w przypadku awarii.

8. Zarządzanie podatnościami

- Regularne aktualizowanie oprogramowania hurtowni danych, w tym systemu operacyjnego, baz danych i aplikacji klienckich.
- Wdrożenie procesu zarządzania łatami bezpieczeństwa 9. Szkolenie personelu

- Edukacja pracowników w zakresie bezpieczeństwa danych, rozpoznawania phishingu oraz zasad ochrony informacji.
- Szkolenia techniczne dla administratorów systemów, obejmujące aktualne praktyki w zakresie bezpieczeństwa cybernetycznego.

10. Redukcja ryzyka związanego z dostawcami zewnętrznymi

- Weryfikacja dostawców zewnętrznych pod kątem zgodności z wymaganiami bezpieczeństwa.
- Umowy SLA (ang. Service Level Agreement) określające standardy ochrony danych i procedury reagowania na incydenty.

11. Ochrona przed złośliwym oprogramowaniem

- Instalacja oprogramowania antywirusowego i antymalware.
- Regularne skanowanie systemów pod kątem zagrożeń.

Zarządzanie incydentami bezpieczeństwa

1. Identyfikacja i analiza

Pierwszym krokiem w zarządzaniu incydentem jest jego szybkie wykrycie i ocena. Systemy monitoringu oraz mechanizmy detekcji zagrożeń odgrywają tutaj kluczową rolę.

2. Reakcja

Reakcja na incydent powinna być zgodna z opracowanymi procedurami i obejmować:

- Izolowanie zainfekowanych systemów,
- Informowanie odpowiednich osób i zespołów,
- Dokumentowanie incydentu.

3. Odbudowa

Proces odbudowy obejmuje przywracanie systemów do pełnej sprawności, w tym:

- Przywracanie danych z kopii zapasowych,
- Wdrażanie poprawek i ulepszeń zabezpieczeń.

4. Analiza po incydencie

Po każdym incydencie należy przeprowadzić analizę w celu zidentyfikowania przyczyn i wprowadzenia środków zapobiegawczych.

Technologie wspierające bezpieczeństwo hurtowni danych

1. Systemy wykrywania i zapobiegania włamaniom (IDS/IPS)

Systemy IDS/IPS monitorują ruch sieciowy w celu wykrywania i blokowania podejrzanych działań.

2. Mechanizmy DLP (Data Loss Prevention)

Systemy DLP pomagają w ochronie przed utratą danych poprzez monitorowanie i kontrolowanie przepływu informacji.

3. Narzędzia do analizy zagrożeń

Zaawansowane narzędzia analityczne, takie jak SIEM (Security Information and Event Management), umożliwiają zbieranie i analizowanie danych dotyczących bezpieczeństwa.

4. Chmura i bezpieczeństwo danych

W przypadku korzystania z hurtowni danych w chmurze konieczne jest stosowanie dodatkowych środków, takich jak:

- Szyfrowanie danych w chmurze,
- Ustalanie granic dostępu,
- Monitorowanie aktywności użytkowników w czasie rzeczywistym.

Dodatkowe aspekty ochrony danych

1. Edukacja i szkolenia pracowników

Czynniki ludzkie są jednym z najsłabszych ogniw w systemach bezpieczeństwa. Regularne szkolenia z zakresu rozpoznawania zagrożeń, takich jak phishing, oraz przestrzegania polityk bezpieczeństwa są niezbędne.

2. Zarządzanie urządzeniami mobilnymi

Pracownicy coraz częściej korzystają z urządzeń mobilnych do pracy. Wdrożenie polityk zarządzania urządzeniami mobilnymi (MDM) umożliwia zabezpieczenie danych przechowywanych na tych urządzeniach.

3. Bezpieczeństwo fizyczne

Dostęp fizyczny do serwerów hurtowni danych powinien być ściśle kontrolowany. Wdrożenie środków takich jak identyfikatory biometryczne, karty dostępu czy monitoring wizyjny minimalizuje ryzyko nieautoryzowanego dostępu.

Przyszłość bezpieczeństwa danych w hurtowniach danych

1. Wykorzystanie sztucznej inteligencji (AI)

Sztuczna inteligencja może wspierać ochronę danych poprzez:

- Analizę wzorców zachowań użytkowników,
- Wykrywanie nietypowych aktywności w czasie rzeczywistym,
- Automatyczne reagowanie na zagrożenia.

2. Blockchain w ochronie danych

Technologia blockchain może zapewnić wysoki poziom bezpieczeństwa dzięki:

- Transparentności i niezmienności zapisów transakcji,
- Możliwości śledzenia dostępu do danych.

3. Internet Rzeczy (IoT)

Rosnąca liczba urządzeń IoT zwiększa ryzyko naruszeń bezpieczeństwa. Wdrażanie dedykowanych mechanizmów ochrony dla IoT, takich jak segmentacja sieci, jest kluczowe.

4. Rozwój regulacji prawnych

Przepisy takie jak RODO (GDPR) czy CCPA zmuszają organizacje do inwestowania w środki ochrony danych. Przyszłość może przynieść kolejne regulacje, które będą wymagały jeszcze bardziej zaawansowanych zabezpieczeń.

Wyzwania i rekomendacje

1. Wyzwania

- Złożoność infrastruktury IT,
- Szybko zmieniający się krajobraz zagrożeń,
- Brak wykwalifikowanych specjalistów ds. bezpieczeństwa.

2. Rekomendacje

- Wdrażanie podejścia proaktywnego w zarządzaniu bezpieczeństwem,
- Ciągłe doskonalenie i aktualizowanie strategii ochrony,
- Inwestowanie w nowoczesne technologie i szkolenia.

Podsumowanie

Bezpieczeństwo danych w hurtowniach danych wymaga wielowarstwowego podejścia, obejmującego zarówno techniczne, jak i organizacyjne środki ochrony. Inwestowanie w odpowiednie technologie, edukację pracowników oraz opracowanie solidnych polityk bezpieczeństwa pozwala minimalizować ryzyko zagrożeń i naruszeń. Współczesne organizacje muszą być gotowe na dynamicznie zmieniające się wyzwania, aby skutecznie chronić swoje dane i reputację.

1.Cel realizacji Projektu

Specyfika działania oraz modelowania hurtowni danych

Celem realizowanego projektu było wykorzystanie potencjału hurtowni danych oraz zaprojektowanie logicznego modelu danych w układzie gwiazdy z użyciem narzędzia SAS Data Integration Studio. Projekt umożliwił przeprowadzenie analizy sprzedaży w oparciu o dane dużej, globalnej firmy specjalizującej się w produkcji oraz dystrybucji rowerów i akcesoriów.

Głównym celem projektu było ukazanie architektury hurtowni danych, zaprezentowanie ich zastosowań oraz przeprowadzenie procesu modelowania z wykorzystaniem narzędzia SAS Data Integration Studio. Szczególny nacisk położono na procesy ETL (Extract, Transform, Load), które składają się z trzech etapów:

1. **Ekstrakcja danych** – pobranie danych ze źródeł pierwotnych.
2. **Transformacja** – proces czyszczenia, konwertowania, konsolidacji oraz implementacji reguł biznesowych.
3. **Ładowanie** – przesłanie przetworzonych danych do hurtowni.

Projekt realizowano w oparciu o bazę danych AdventureWorks, która jest przykładowym zbiorem opracowanym przez firmę Microsoft.

Rysunek 1 - Logo firmy Adventure Works Cycles

W części teoretycznej scharakteryzowano Bezpieczeństwo danych w hurtowniach danych oraz strategie ochrony przed zagrożeniami i naruszeniami, zwracając uwagę na ich złożoność samego pojęcia jakim jest bezpieczeństwo hurtowni i szerokie zastosowania w biznesie strategii ochronnych . Szczegółowo omówiono architekturę gwiazdy, będącą jednym z logicznych schematów organizacji danych w hurtowniach. Architektura ta była modelowana z

myślą o potrzebach biznesowych, takich jak porównanie sprzedaży w różnych regionach, analiza wyborów produktowych czy identyfikacja preferencji klientów.

Na etapie praktycznym zaprezentowano strukturę bazy AdventureWorks oraz szczegółowy opis jej elementów. Następnie utworzono schemat gwiazdy, który stał się podstawą analizy. Procesy ETL umożliwiły przekształcenie danych w sposób umożliwiający ich efektywne wykorzystanie w analizie biznesowej. Szczególną uwagę poświęcono wynikom sprzedaży, które zostały przeanalizowane w kontekście regionów, kategorii produktów oraz wyników poszczególnych pracowników.

Otrzymane raporty dostarczyły kluczowych informacji, takich jak:

- info
- info
- info
- info

Tak zaprojektowany schemat hurtowni danych oraz procesy ETL nie tylko ułatwiły analizę zgromadzonych informacji, ale także pozwoliły na identyfikację kluczowych wniosków biznesowych. Zastosowanie SAS Data Integration Studio w realizacji tego projektu pokazało, jak narzędzie to może wspierać zarządzanie danymi i podejmowanie decyzji strategicznych w firmach działających w skali globalnej.

2. Opis źródeł danych

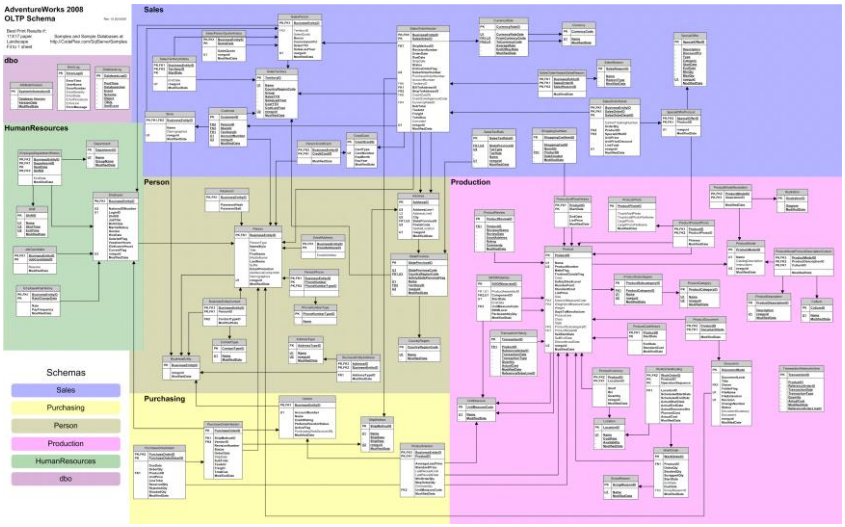
Dane wykorzystane w realizowanym projekcie pochodzą z treningowej bazy danych AdventureWorks, udostępnionej przez firmę Microsoft i przechowującą dane o fikcyjnej firmie Adventure Works Cycles. Zawiera ona szczegółowe informacje na temat oferowanych produktów, zasobów ludzkich, a także danych bezpośrednio związanych z procesem sprzedaży, zakupu oraz produkcji. Struktury oraz pełen zakres tabel zaprezentowano na rysunku 3. Ze względu na tematyczność zostały one podzielone na 6 obszarów:

- **Sales** (dane sprzedażowe),
- **Purchasing** (dane zakupowe),
- **Person** (dane osobowe),

- **Production** (dane produkcyjne),
- **HumanResources** (dane o zasobach ludzkich),
- **Dbo** (dane systemowe).

Pierwotna zawartość bazy obejmuje:

- około 20 000 klientów,
- 70 000 zamówień,
- 500 unikalnych produktów.



Rysunek 2 - Schemat bazy Adventure Works
Źródło: https://improveandrepeat.com/2019/02/use-the-adventureworks-sample-database-for-your-examples/

W projekcie szczególny nacisk jest położony na obszary takie jak Productions, Person ,Sales oraz HumanResources. Wymienione obszary zostaną szczegółowo scharakteryzowane poniżej.

Productions

Tabela **Product** wykorzystuje zmienną ProductID jako klucz główny, co umożliwia powiązanie jej z innymi tabelami. Zawiera ona szczegółowe dane identyfikacyjne dotyczące wszystkich produktów, takie jak nazwa czy numer. Ponadto obejmuje informacje o datach rozpoczęcia i zakończenia sprzedaży, a także opisuje istotne cechy produktów, w tym wagę, rozmiar, czas produkcji, zastosowanie i cenę. Tabela Category odpowiada za przechowywanie

danych o kategoriach produktów. Relacja z tabelą Product realizowana jest poprzez klucz ProductCategory oraz tabelę pośredniczącą ProductSubCategory.

Tabela **ProductCategory** odpowiada za przechowywanie danych o głównych kategoriach produktów, takich jak "Odzież" czy "Akcesoria". Klucz główny tej tabeli to ProductCategoryID. Powiązanie z produktami realizowane jest pośrednio przez tabelę **ProductSubcategory**, która przechowuje informacje o podkategoriach produktów (np. "Koszulki" dla kategorii "Odzież"). Klucz ProductSubcategoryID w tabeli Product pozwala na pełne odwzorowanie hierarchii kategorii.

Tabela **BillOfMaterials** opisuje strukturę zestawienia materiałowego (BOM). Klucz główny BillOfMaterialsID jednoznacznie identyfikuje każdy rekord, a klucz obcy ComponentID wskazuje składniki używane do produkcji innych produktów. Zawiera również szczegóły o ilościach komponentów i datach ich obowiązywania.

Tabela **WorkOrder** wykorzystuje WorkOrderID jako klucz główny, opisując procesy produkcyjne. Przechowuje informacje o produktach wytwarzanych w ramach zamówień, daty rozpoczęcia i zakończenia pracy, ilość oraz status zamówienia.

Person

Tabela **Person** korzysta z BusinessEntityID jako klucza głównego, co pozwala na jednoznaczną identyfikację każdej osoby w systemie. Zawiera dane podstawowe, takie jak imię, nazwisko, nazwisko panieńskie, pseudonim oraz dane kontaktowe (np. numery telefonów i adresy e-mail).

Tabela **Address** przechowuje szczegóły dotyczące adresów, takie jak ulica, miasto, województwo, kod pocztowy i kraj. Klucz główny to AddressID. Powiązanie z osobami realizowane jest za pomocą tabeli pośredniczącej **BusinessEntityAddress**, w której BusinessEntityID łączy dane kontaktowe z danymi osobowymi.

Tabela **ContactType** przechowuje informacje o typach kontaktów, takich jak "Klient", "Dostawca" czy "Pracownik". Klucz główny to ContactTypeID. Relacje z osobami realizowane są za pomocą tabeli **BusinessEntityContact**, która wiąże typy kontaktów z poszczególnymi osobami.

Sales

Tabela **SalesOrderHeader** wykorzystuje SalesOrderID jako klucz główny, który identyfikuje każde zamówienie. Przechowuje informacje o zamówieniach, takie jak data złożenia, metoda wysyłki, kwota podatku, koszt transportu oraz całkowita wartość zamówienia. Klucz obcy CustomerID łączy zamówienie z klientem.

Tabela **SalesOrderDetail** szczegółowo opisuje pozycje w zamówieniach. Klucz główny jest kombinacją SalesOrderID i SalesOrderDetailID, co pozwala na jednoznaczne identyfikowanie pozycji w ramach zamówienia. Zawiera dane o produktach, ilości, cenie jednostkowej, rabatach oraz kwocie netto.

Tabela **Customer** przechowuje informacje o klientach, takich jak imię, nazwisko, nazwa firmy, numer konta i status aktywności. Klucz główny CustomerID pozwala na identyfikację klientów. Dane kontaktowe klientów są przechowywane w powiązanych tabelach Person lub BusinessEntity.

Tabela **SalesTerritory** wykorzystuje TerritoryID jako klucz główny i zawiera dane o regionach sprzedaży, takich jak ich nazwy, regiony geograficzne i poziomy sprzedaży. Powiązania z zamówieniami realizowane są przez tabelę SalesOrderHeader.

Human Resources

Tabela **Employee** korzysta z BusinessEntityID jako klucza głównego, co pozwala na identyfikację pracowników i powiązanie ich danych z innymi tabelami. Przechowuje informacje takie jak data zatrudnienia, płeć, stanowisko, poziom zarobków i status pracy (np. pełnoetatowy lub niepełnoetatowy).

Tabela **Department** przechowuje informacje o działach w organizacji, takich jak nazwa działu, grupa oraz data utworzenia. Klucz główny DepartmentID jednoznacznie identyfikuje każdy dział.

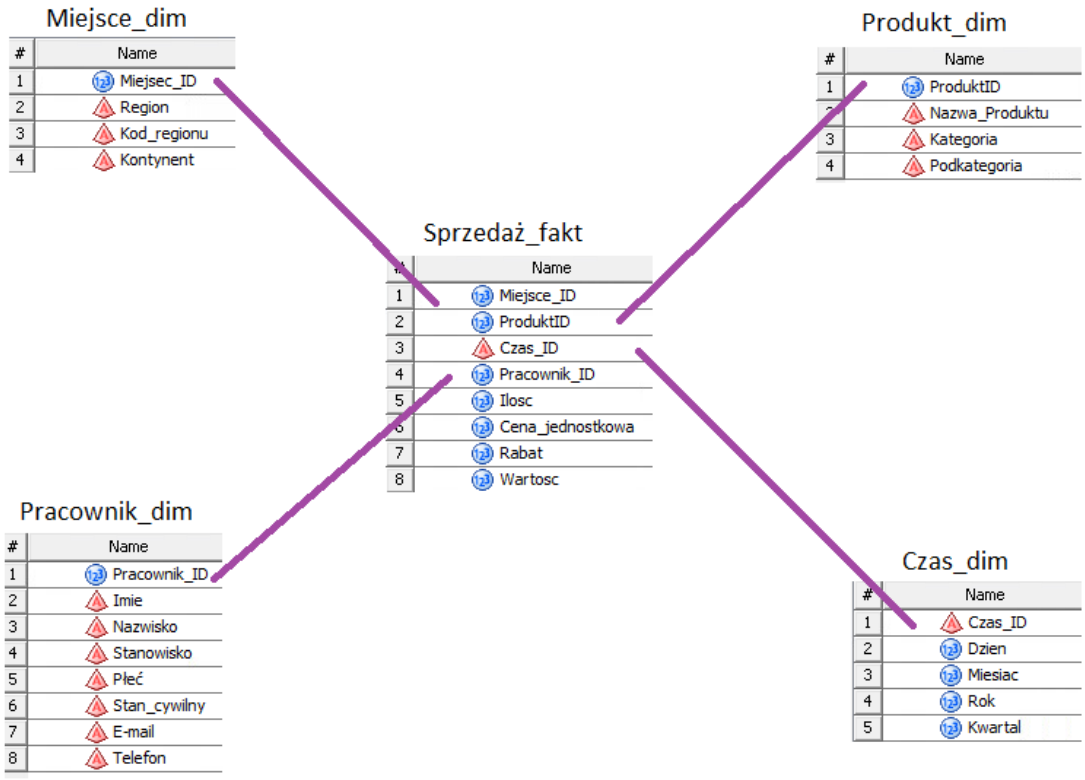
Tabela **EmployeeDepartmentHistory** opisuje historię przypisania pracowników do działów. Klucz główny to kombinacja BusinessEntityID, DepartmentID i daty rozpoczęcia. Przechowuje dane o czasowym przydziale pracowników do różnych działów.

Tabela **JobCandidate** przechowuje dane o kandydatach na pracowników, takie jak CV czy informacje o kwalifikacjach. Klucz główny JobCandidateID jednoznacznie identyfikuje każdego kandydata.

Tabela **Shift** zarządza danymi o zmianach pracy. Klucz główny ShiftID opisuje unikalne zmiany, takie jak godziny rozpoczęcia i zakończenia oraz dni obowiązywania.

3.Model logiczny hurtowni danych w oparciu o schemat gwiazdy

Architektura gwiazdy, przedstawiona na Rysunku 9, jest prostym modelem hurtowni danych, który składa się z centralnej tabeli faktów połączonej z tabelami wymiarów. W tym przypadku model obejmuje tabelę faktów oraz cztery wymiary, które ukazują kluczowe dane dotyczące sprzedaży. Główną cechą tego modelu jest możliwość przeglądania poszczególnych kategorii, agregacji, drążenia i filtrowania danych. Wymiary opisane są za pomocą atrybutów, które przechowują dodatkowe informacje o faktach, a same fakty są przyporządkowane miarom – wartościom liczbowym. W kolejnych częściach pracy zostaną omówione etapy tworzenia modelu logicznego hurtowni danych, zawierającego informacje o firmie AdventureWorks.

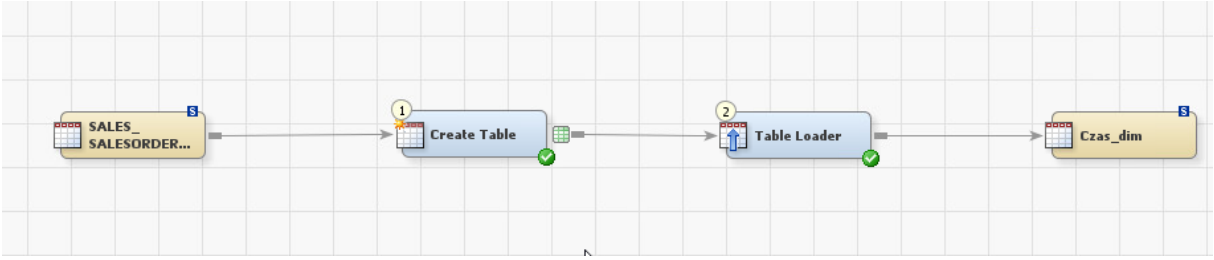


Rysunek 3 – Schemt gwiazdy

Zbudowany schemat gwiazdy składa się z tabeli faktów opisującej sprzedaż oraz czterech tabel wymiarów, są one następujące:

1.Wymiar czas

Jako pierwszy wymiar pozostanie przedastawiony wymiar czas. Zawarte w nim informacje określają datę złożenia zamówienia. Wymiar ten pozwala na przeglądanie i analizowanie danych według roku, kwartału, miesiąca oraz dnia. Kluczem głównym tabeli jest Czas_ID.



Rysunek 4 – proces ETL tworzący czas_dim

W utworzeniu tabeli czas_dim posłużyła nam tabela SALES_SALESORDERHEADER ,która zawiera informacje o dacie zamówienia , płatności oraz wysyłki

Go to row Go

#	SalesOrderID	RevisionNumber	OrderDate	DueDate	ShipDate	Status	OnlineOrde
1	43659	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
2	43660	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
3	43661	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
4	43662	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
5	43663	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
6	43664	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
7	43665	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
8	43666	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
9	43667	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
10	43668	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
11	43669	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
12	43670	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
13	43671	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
14	43672	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
15	43673	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
16	43674	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
17	43675	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
18	43676	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
19	43677	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
20	43678	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
21	43679	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
22	43680	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
23	43681	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
24	43682	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
25	43683	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
26	43684	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
27	43685	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
28	43686	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
29	43687	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	
30	43688	1	01JUL2001:00:...	13JUL2001:00...	08JUL2001:00...	5	

Rysunek 5 - tabela SALES_SALESORDERHEADER

Podczas procesu ETL wykorzystane zostały funkcje takie jak Create Table oraz Table Loader . W funkcji Create Table zakładce results zdefiniowałem pięć zmian (rok, kwartał, miesiąc, dzień). Każdy z nich został zdefiniowany według schematu **year(datepart(SALES_SALESORDERHEADER."OrderDate"n))** z jedna zmiana ,która zastępuje „Year” na (qtr, month, day,). W celu utworzenia klucza głównego zastosowałem kod

compress(substr(put(YEAR(DATEPART(SALES_SALESORDERHEADER."OrderDate"n)),4.),3,2)||‘0’||put(MONTH(DATEPART(SALES_SALESORDERHEADER."OrderDate"n)),2.)||'0'||put(DAY(DATEPART(SALES_SALESORDERHEADER."OrderDate"n)), 2.))

1	Czas_ID	compress(substr(pu...	compress(substr(put(YEAR(DATEPART(SALES_S...	Charac
2	Dzien	Day(datepart(SALE...	Day(datepart(SALES_SALESORDERHEADER.Ord...	Numer
3	Miesiac	Month(datepart(SA...	Month(datepart(SALES_SALESORDERHEADER.O...	Numer
4	Rok	year(datepart(SAL...	year(datepart(SALES_SALESORDERHEADER.Ord...	Numer
5	Kwartal	qtr(datepart(SALES...	qtr(datepart(SALES_SALESORDERHEADER.Orde...	Numer

Rysunek 6 – Funkcje tworzące pola tabeli czas_dim

Po zakończonym procesie ETL otrzymujemy następującą tabele.

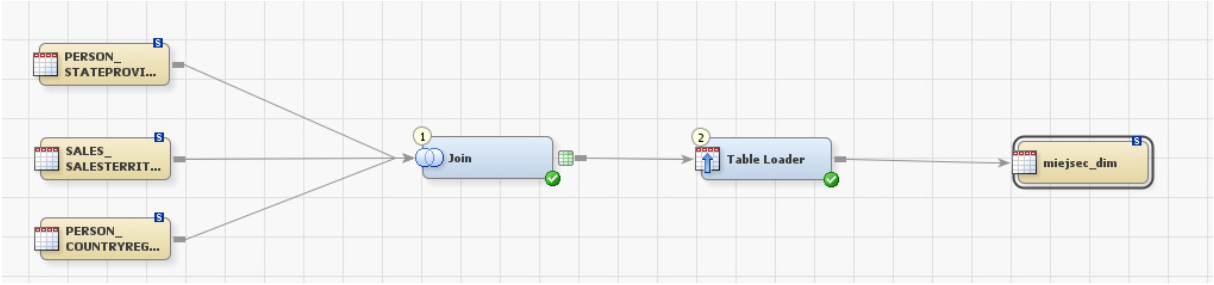
#	Czas_ID	Dzien	Miesiac	Rok	Kwartal
1	010701	1	7	2001	3
2	010701	1	7	2001	3
3	010701	1	7	2001	3
4	010701	1	7	2001	3
5	010701	1	7	2001	3
6	010701	1	7	2001	3
7	010701	1	7	2001	3
8	010701	1	7	2001	3
9	010701	1	7	2001	3
10	010701	1	7	2001	3
11	010701	1	7	2001	3
12	010701	1	7	2001	3
13	010701	1	7	2001	3
14	010701	1	7	2001	3
15	010701	1	7	2001	3
16	010701	1	7	2001	3
17	010701	1	7	2001	3
18	010701	1	7	2001	3
19	010701	1	7	2001	3
20	010701	1	7	2001	3
21	010701	1	7	2001	3
22	010701	1	7	2001	3
23	010701	1	7	2001	3
24	010701	1	7	2001	3

Rysunek 7 – tabela czas_dim

2.Wymiar miejsce

Kluczowym elementem analizy sprzedaży jest wymiar geograficzny, który zawiera informacje dotyczące lokalizacji związanych ze sprzedażą realizowaną przez firmę Adventure

Works Cycles. W celu jego stworzenia połączono trzy tabele, co pozwoliło uzyskać odpowiedni poziom szczegółowości danych. Wykorzystane tabele źródłowe to: Person_StateProvince, Sales_SalesTerritory oraz Person_CountryRegion. Głównym kluczem tabeli jest Miejsce_ID, który umożliwia powiązanie z centralną tabelą faktów. Do atrybutów wymiaru należą takie dane jak Region, Kod_regionu i Kontynent.



Rysunek 8 Proces ETL tworzący miejsce_dim

Struktura tabeli Person_StateProvince została przedstawiona na poniższym rysunku .

#	Name	Description	Type	Length	Informat	Format	Is Nullable
1	State...	StateProvinceID	Numeric	8	11.	11.	Yes
2	State...	StateProvinceCode	Character	3	$3.	$3.	Yes
3	Coun...	CountryRegionCode	Character	8	(None)	(None)	Yes
4	IsOnl...	IsOnlyStateProvinc...	Numeric	8	6.	6.	Yes
5	Name	Name	Character	50	$50.	$50.	Yes
6	Territ...	TerritoryID	Numeric	8	11.	11.	Yes
7	rowguid	rowguid	Character	38	$38.	$38.	Yes
8	Modif...	ModifiedDate	Numeric	8	DATETIME19.	DATETIME19.	Yes

Rysunek 9 - tabela Person_StateProvince

Kolejną tabelą źródłową, z której korzystano w procesie była Sales_SalesTerritory.

#	Name	Description	Type	Length	Informat	Format	Is Nullab
1	Territ...	TerritoryID	Numeric	8	11.	11.	Yes
2	Name	Name	Character	1024	$1024.	$1024.	Yes
3	Coun...	CountryRegionCode	Character	1024	$1024.	$1024.	Yes
4	Group	Group	Character	8	(None)	(None)	Yes
5	Sales...	SalesYTD	Numeric	8	DOLLAR21.2	DOLLAR21.2	Yes
6	Sales...	SalesLastYear	Numeric	8	DOLLAR21.2	DOLLAR21.2	Yes
7	Cost...	CostYTD	Numeric	8	DOLLAR21.2	DOLLAR21.2	Yes
8	CostL...	CostLastYear	Numeric	8	DOLLAR21.2	DOLLAR21.2	Yes
9	rowguid	rowguid	Character	38	$38.	$38.	Yes
10	Modif...	ModifiedDate	Numeric	8	DATETIME19.	DATETIME19.	Yes

Rysunek 10 – tabela Sales_SalesTerritory

Ostatnia tabela stanowiąca źródło to Person_CountryRegion.

#	Name	Description	Type	Length	Informat	Format	Is Nullable
1	Coun...	CountryRegionCode	Character	50	$50.	$50.	Yes
2	Name	Name	Character	8	(None)	(None)	Yes
3	Modif...	ModifiedDate	Numeric	8	DATETIME19.	DATETIME19.	Yes

Rysunek 11 - tabela Person_CountryRegion

W celu połączenia tabel wykorzystany został węzeł Join. Jest to klauzula umożliwiająca złączenia danych pochodzących z różnych tabel. Następnie dane wynikowe zostały przeładowane do tabeli docelowej

#	Boolean	(	Operand	Operator	Operand
1			PERSON_STATEPROVINCE.StateProvinceID	=	PERSON_STATEPROVINCE.StateProvinceID
2	AND		PERSON_STATEPROVINCE.TerritoryID	=	PERSON_STATEPROVINCE.TerritoryID
3	AND		PERSON_STATEPROVINCE.CountryRegionCode	=	PERSON_COUNTRYREGION.CountryRegionCode
4	AND		PERSON_STATEPROVINCE.CountryRegionCode	=	SALES_SALESTERRITORY.CountryRegionCode

Rysunek 12 - połaczenie tabel w wymiarze miejsca

W wyniku wcześniejszych kroków powstała tabela docelowa miejsce _dim

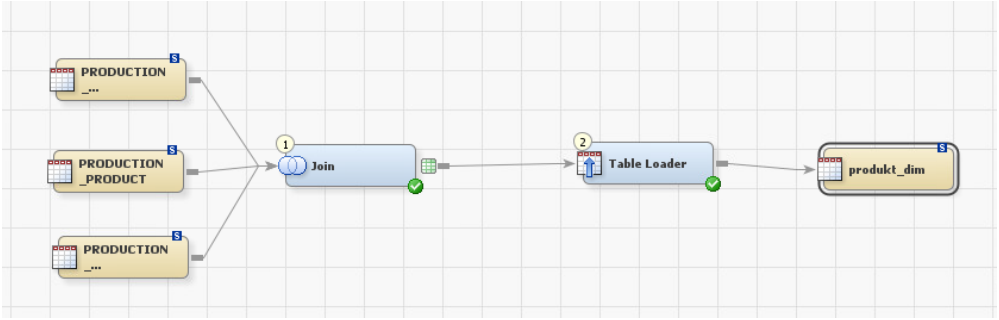
Go to row Go

#	Miejsec_ID	Region	Kod_regionu	Kontynent
1	6	Canada	CA	North Am
2	1	United S	US	North Am
3	1	United S	US	North Am
4	1	United S	US	North Am
5	1	United S	US	North Am
6	1	United S	US	North Am
7	5	United S	US	North Am
8	5	United S	US	North Am
9	5	United S	US	North Am
10	5	United S	US	North Am
11	5	United S	US	North Am
12	3	United S	US	North Am
13	3	United S	US	North Am
14	3	United S	US	North Am
15	3	United S	US	North Am
16	3	United S	US	North Am
17	4	United S	US	North Am
18	4	United S	US	North Am
19	4	United S	US	North Am

Rysunek 13 – Tabela miejsce_dim

3.Wymiar produkt

Trzecim opracowanym wymiarem był wymiar produktu , tabela przechowująca atrybuty opisujące produkty, dostarcza informacje o nazwie produktu, jego kategorii i podkategorii. Klucz główny tabeli stanowi pole Produkt_ID.



Rysunek 14 – Proces ETL tworzący produt_dim

W celu stworzenia wymiaru produkt ponownie połączono ze sobą trzy tabele . Wykorzystane tabele źródłowe to Production_ProductSubcategory , Production_Product oraz Production_ProductCategory. Kluczem głównym tabeli jest jak zostało wcześniej wspomniane Produkt_ID który umożliwia powiązanie z centralną tabelą faktów

Ponowanie został wykorzystany węzeł join którego połączenia widnieją na poniższym rysunku

#	Boolean	(	Operand	Operator	Operand
1			PRODUCTION_PRODUCTSUBCATEGORY.ProductSubcat...	=	PRODUCTION_PRODUCTSUBCATEGORY.ProductSubcat...
2	AND		PRODUCTION_PRODUCTSUBCATEGORY.ProductCateg...	=	PRODUCTION_PRODUCTSUBCATEGORY.ProductCateg...
3	AND		PRODUCTION_PRODUCTSUBCATEGORY.ProductSubcat...	=	PRODUCTION_PRODUCT.ProductSubcategoryID
4	AND		PRODUCTION_PRODUCTSUBCATEGORY.ProductCateg...	=	PRODUCTION_PRODUCTCATEGORY.ProductCategoryID

Rysunek 15- połaczenie tabel w wymiarze produkt

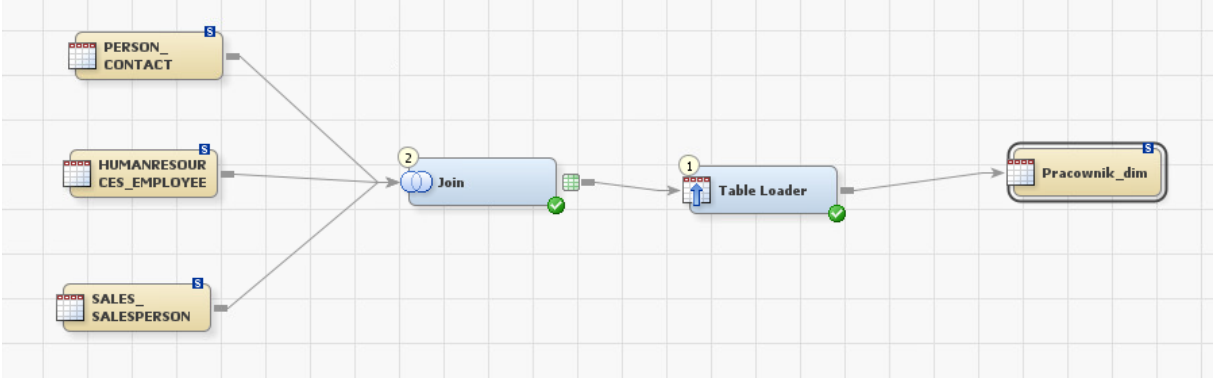
Gotowa tabela przedstawia się następująco .

#	ProduktID	Nazwa_Produktu	Kategoria	Podkategoria
1	680	HL Road	Componen	Road Fra
2	706	HL Road	Componen	Road Fra
3	707	Sport-10	Accessor	Helmets
4	708	Sport-10	Accessor	Helmets
5	709	Mountain	Clothing	Socks
6	710	Mountain	Clothing	Socks
7	711	Sport-10	Accessor	Helmets
8	712	AWC Logo	Clothing	Caps
9	713	Long-Sle	Clothing	Jerseys
10	714	Long-Sle	Clothing	Jerseys
11	715	Long-Sle	Clothing	Jerseys
12	716	Long-Sle	Clothing	Jerseys
13	717	HL Road	Componen	Road Fra
14	718	HL Road	Componen	Road Fra
15	719	HL Road	Componen	Road Fra
16	720	HL Road	Componen	Road Fra
17	721	HL Road	Componen	Road Fra
18	722	LL Road	Componen	Road Fra
19	723	LL Road	Componen	Road Fra
20	724	LL Road	Componen	Road Fra
21	725	LL Road	Componen	Road Fra

Rysunek 16 – tabela produkt_dim

4.Wymiar pracownik

Kolejnym wymiarem jest wymiar pracownik ,który opisuje pracowników firmy a jego atrybuty to należą imię, nazwisko, stanowisko, płeć, a także dane kontaktowe takie jak adres e-mail i numer telefonu. Kluczem głównym tabeli wymiaru jest Pracownik_ID. Tabela docelowa powstała z trzech następujących tabeli Person_Contact, HumanResources_Employee oraz Sales_SalesPerson.



Rysunek 17 – Proces ETL tworzący pracownik_dim

Poraz kolejny został zastosowany węzeł join którego połączenia przedstawiają się następująco.

		PERSON_CONTACT.ContactID	=	HUMANRESOURCES_EMPLOYEE.ContactID
AND		HUMANRESOURCES_EMPLOYEE.EmployeeID	=	SALES_SALESPERSON.SalesPersonID

Rysunek 18 - połaczenie tabel

Po uruchomieniu procesu ETL ,dane zostały złączone oraz przeładowane do tabeli docelowej przy użyciu węzła ładowania danych w wyniku czego otrzymaliśmy dane na rysunku 19.

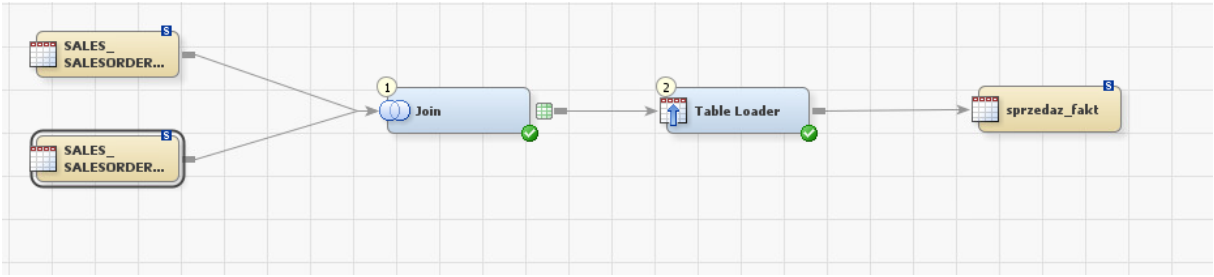
#	Pracownik_ID	Imie	Nazwisko	Stanowisko	Płeć	Stan_cywilny	E-mail	Telefo
1	268	Stephen	Jiang	North Am	M	M	stephen0	238-555-
2	288	Syed	Abbas	Pacific	M	M	syed0@ad	926-555-
3	284	Amy	Alberts	European	F	M	amy0@adv	775-555-
4	280	Pamela	Ansman-W	Sales Re	F	S	pamela0@	340-555-
5	283	David	Campbell	Sales Re	M	S	david8@a	740-555-
6	277	Jillian	Carson	Sales Re	F	S	jillian0	517-555-
7	281	Shu	Ito	Sales Re	M	M	shu0@adv	330-555-
8	276	Linda	Mitchell	Sales Re	F	M	linda3@a	883-555-
9	279	Tsvi	Reiter	Sales Re	M	M	tsvi0@ad	664-555-
10	282	José	Saraiva	Sales Re	M	M	josé1@a	185-555-
11	278	Garrett	Vargas	Sales Re	M	M	garrett1	922-555-
12	286	Ranjit	Varkey C	Sales Re	M	S	ranjit0@	1 (11) 5
13	289	Rachel	Valdez	Sales Re	F	S	rachel0@	1 (11) 5
14	290	Lynn	Tsoflias	Sales Re	F	S	lynn0@ad	1 (11) 5
15	285	Jae	Pak	Sales Re	F	M	jae0@adv	1 (11) 5
16	275	Michael	Blythe	Sales Re	M	S	michael9	257-555-
17	287	Tete	Mensa-An	Sales Re	M	M	tete0@ad	615-555-

Rysunek 19 – tabela pracownik_dim

5.Tabela faktów

Tabela faktów to centralna główna część schematu gwiazdy ponieważ łączy ze sobą wszystkie wymiary i posiada wszystkie klucze główne takie jak Miejsce_ID, Produkt_ID, Czas_ID, Pracownik_ID. Poza kluczami głównymi posiada również cztery miary opisujące sprzedaż - ilość , Cenę jednostkową , Rabat oraz Wartosc .

Tabela została stworzona poprzez połączenie dwóch tabel opisujących zamówienia SalesOrderDetail oraz SalesOrderHeader . Proces ETL wygląda następująco.



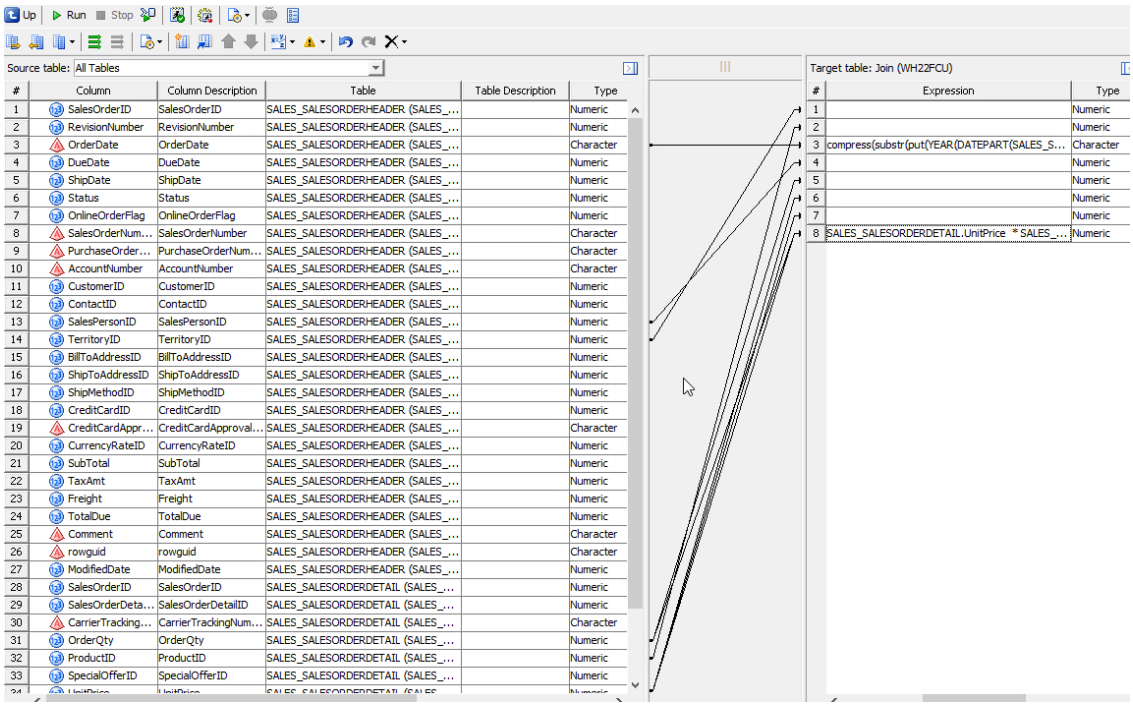
Rysunek 20 – Proces tworzący tabele sprzedaż fakt

Połączenia w inner join są przedstawione na rysunku poniżej.

Boolean	(	Operand	Operator	Operand	)
		SALES_SALESORDERHEADER.SalesOrderID	=	SALES_SALESORDERHEADER.SalesOrderID	
AND		SALES_SALESORDERHEADER.SalesOrderID	=	SALES_SALESORDERDETAIL.SalesOrderID	

Rysunek 21 – polaczenie tabel

Następnie w węźle Select dokonano mapowania zmiennych, tak aby w tabeli wynikowej pozostawić jedynie identyfikatory odnoszące się do tabel wymiarów oraz zmieniono ich nazwy na obecne tam odpowiedniki. Również na tym etapie utworzono dodatkowe miary, które posłużą do późniejszych analiz sprzedaży. W ten sposób do tabeli faktów dodano także pola Cena_jednostkowa, Rabat oraz Wartość aby którą uzyskać posłużyłem się następującym expression „SALES_SALESORDERDETAIL.UnitPrice * SALES_SALESORDERDETAIL.OrderQty * (1 - SALES_SALESORDERDETAIL.UnitPriceDiscount)” .



#	Column	Column Description	Table	Table Description	Type
1	SalesOrderID	SalesOrderID	SALES_SALESORDERHEADER (SALES_...		Numeric
2	RevisionNumber	RevisionNumber	SALES_SALESORDERHEADER (SALES_...		Numeric
3	OrderDate	OrderDate	SALES_SALESORDERHEADER (SALES_...		Character
4	DueDate	DueDate	SALES_SALESORDERHEADER (SALES_...		Numeric
5	ShipDate	ShipDate	SALES_SALESORDERHEADER (SALES_...		Numeric
6	Status	Status	SALES_SALESORDERHEADER (SALES_...		Numeric
7	OnlineOrderFlag	OnlineOrderFlag	SALES_SALESORDERHEADER (SALES_...		Numeric
8	SalesOrderNum...	SalesOrderNumber	SALES_SALESORDERHEADER (SALES_...		Character
9	PurchaseOrder...	PurchaseOrderNum...	SALES_SALESORDERHEADER (SALES_...		Character
10	AccountNumber	AccountNumber	SALES_SALESORDERHEADER (SALES_...		Character
11	CustomerID	CustomerID	SALES_SALESORDERHEADER (SALES_...		Numeric
12	ContactID	ContactID	SALES_SALESORDERHEADER (SALES_...		Numeric
13	SalesPersonID	SalesPersonID	SALES_SALESORDERHEADER (SALES_...		Numeric
14	TerritoryID	TerritoryID	SALES_SALESORDERHEADER (SALES_...		Numeric
15	BillToAddressID	BillToAddressID	SALES_SALESORDERHEADER (SALES_...		Numeric
16	ShipToAddressID	ShipToAddressID	SALES_SALESORDERHEADER (SALES_...		Numeric
17	ShipMethodID	ShipMethodID	SALES_SALESORDERHEADER (SALES_...		Numeric
18	CreditCardID	CreditCardID	SALES_SALESORDERHEADER (SALES_...		Numeric
19	CreditCardAppr...	CreditCardApproval...	SALES_SALESORDERHEADER (SALES_...		Character
20	CurrencyRateID	CurrencyRateID	SALES_SALESORDERHEADER (SALES_...		Numeric
21	SubTotal	SubTotal	SALES_SALESORDERHEADER (SALES_...		Numeric
22	TaxAmt	TaxAmt	SALES_SALESORDERHEADER (SALES_...		Numeric
23	Freight	Freight	SALES_SALESORDERHEADER (SALES_...		Numeric
24	TotalDue	TotalDue	SALES_SALESORDERHEADER (SALES_...		Numeric
25	Comment	Comment	SALES_SALESORDERHEADER (SALES_...		Character
26	rowguid	rowguid	SALES_SALESORDERHEADER (SALES_...		Character
27	ModifiedDate	ModifiedDate	SALES_SALESORDERHEADER (SALES_...		Numeric
28	SalesOrderID	SalesOrderID	SALES_SALESORDERDETAIL (SALES_...		Numeric
29	SalesOrderDeta...	SalesOrderDetailID	SALES_SALESORDERDETAIL (SALES_...		Numeric
30	CarrierTracking...	CarrierTrackingNum...	SALES_SALESORDERDETAIL (SALES_...		Character
31	OrderQty	OrderQty	SALES_SALESORDERDETAIL (SALES_...		Numeric
32	ProductID	ProductID	SALES_SALESORDERDETAIL (SALES_...		Numeric
33	SpecialOfferID	SpecialOfferID	SALES_SALESORDERDETAIL (SALES_...		Numeric

#	Expression	Type
1		Numeric
2		Numeric
3	compress(substr(put(YEAR(DATEPART(SALES_S...	Character
4		Numeric
5		Numeric
6		Numeric
7		Numeric
8	SALES_SALESORDERDETAIL.UnitPrice * SALES_...	Numeric

Rysunek 22 – kolumny tabeki faktów

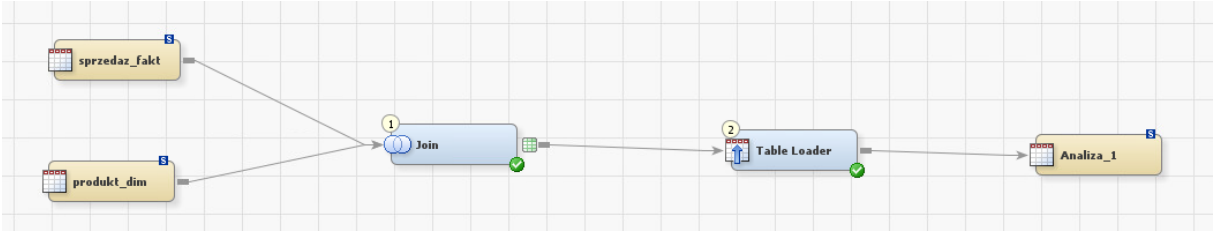
W efekcie powyższych działań nasz proces ETL generuje następującą tabelke.

#	Miejsce_ID	ProduktID	Czas_ID	Pracownik_ID	Ilosc	Cena_jednostkowa	Rabat	Wartosc
1	5	776	010701	279	1	2024.994	0	2024.994
2	5	777	010701	279	3	2024.994	0	6074.982
3	5	778	010701	279	1	2024.994	0	2024.994
4	5	771	010701	279	1	2039.994	0	2039.994
5	5	772	010701	279	1	2039.994	0	2039.994
6	5	773	010701	279	2	2039.994	0	4079.988
7	5	774	010701	279	1	2039.994	0	2039.994
8	5	714	010701	279	3	28.8404	0	86.5212
9	5	716	010701	279	1	28.8404	0	28.8404
10	5	709	010701	279	6	5.7	0	34.2
11	5	712	010701	279	2	5.1865	0	10.373
12	5	711	010701	279	4	20.1865	0	80.746
13	5	762	010701	279	1	419.4589	0	419.4589
14	5	758	010701	279	1	874.794	0	874.794
15	6	745	010701	282	1	809.76	0	809.76
16	6	743	010701	282	1	714.7043	0	714.7043
17	6	747	010701	282	2	714.7043	0	1429.4086
18	6	712	010701	282	4	5.1865	0	20.746
19	6	715	010701	282	4	28.8404	0	115.3616
20	6	742	010701	282	2	722.5949	0	1445.1898
21	6	775	010701	282	3	2024.994	0	6074.982
22	6	778	010701	282	2	2024.994	0	4049.988
23	6	711	010701	282	2	20.1865	0	40.373
24	6	741	010701	282	2	818.7	0	1637.4
25	6	776	010701	282	4	2024.994	0	8099.976
26	6	773	010701	282	2	2039.994	0	4079.988
27	6	716	010701	282	2	28.8404	0	57.6808
28	6	777	010701	282	2	2024.994	0	4049.988
29	6	708	010701	282	5	20.1865	0	100.9325
30	6	764	010701	282	3	419.4589	0	1258.3767

Rysunek 23 – Tabela faktów sprzedaż_fakt

4.Opis procesów ETL

Analiza 1 – Podczas pierwszej analizy skupimy się na wysokości całkowitej sprzedaży w latach 2001 -2004 według produktów. Celem procesu jest określenie ,które z produktów przynoszą największe zyski .W celu tej analizy zastosowaliśmy wcześniej utworzone tabele takie jak sprzedaż_fakt oraz produkt_dim tak jak jest to przedstawione na rysunku poniżej.



Rysunek 24 – Analiza 1

W procesie ETL zastosowaliśmy funkcję join która połączyła tabele za pomocą następujących kluczy głównych.

(	Operand	Operator	Operand	
	sprzedaz_fakt."ProduktID"n	=	produkt_dim."ProduktID"n	

Rysunek 25 – Klucz Produkt_ID

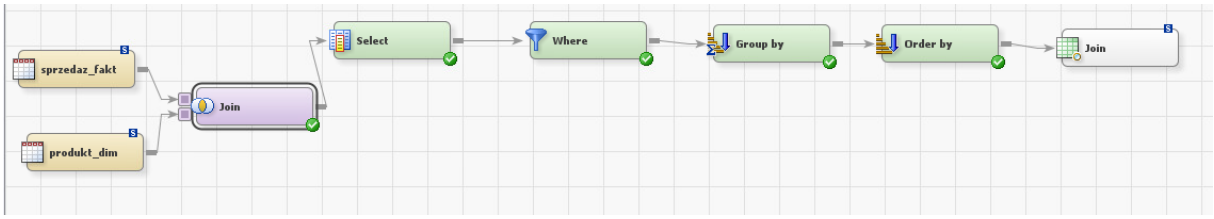
Następnie stworzyliśmy oraz dodaliśmy kolumny potrzbne nam do analizy jedną z takich była kolumna Całkowita sprzedaż która została stworzona za pomocą SUM(sprzedaż_fakt,”Wartosc”n)

#	Column	Column Description	Table	Table Description	Type	Length	Infor
1	Miejsce_ID		sprzedaz_fakt (s...		Numeric	8	(None)
2	ProduktID		sprzedaz_fakt (s...		Numeric	8	(None)
3	Czas_ID		sprzedaz_fakt (s...		Character	8	(None)
4	Pracowni...		sprzedaz_fakt (s...		Numeric	8	(None)
5	Ilosc		sprzedaz_fakt (s...		Numeric	8	(None)
6	Cena_jed...		sprzedaz_fakt (s...		Numeric	8	(None)
7	Rabat		sprzedaz_fakt (s...		Numeric	8	(None)
8	Wartosc		sprzedaz_fakt (s...		Numeric	8	(None)
9	ProduktID		produkt_dim (pro...		Numeric	8	(None)
10	Nazwa_P...		produkt_dim (pro...		Character	100	(None)
11	Kategoria		produkt_dim (pro...		Character	8	(None)
12	Podkateg...		produkt_dim (pro...		Character	8	(None)

#	Column	Column Description	Expression	Type
1	Nazwa_p...			Character
2	kategoria			Character
3	Całkowit...		SUM(sprzedaz_fakt."Wartosc"n)	Numeric
4	Podkateg...			Character

Rysunek 26 – kolumny tabeli analiza_1

Jako następne dane zostały pogrupowane oraz posortowane za pomocą klauzuli group by oraz order by .Dane zostały pogrupowane według nazwy produktu i posortowane malejąco.



Rysunek 27 - węzeł join

Uzyskane dane można zobaczyć poniżej.

#	Nazwa_produktu	kategoria	Podkategoria	Całkowita_sprzedaż
1	Mountain-200 Black, ...	Bikes	Mountain	11719760.779
2	Mountain-200 Black, ...	Bikes	Mountain	11719760.779
3	Mountain-200 Black, ...	Bikes	Mountain	11719760.779
4	Mountain-200 Black, ...	Bikes	Mountain	11719760.779
5	Mountain-200 Black, ...	Bikes	Mountain	11719760.779
6	Mountain-200 Black, ...	Bikes	Mountain	11719760.779
7	Mountain-200 Black, ...	Bikes	Mountain	11719760.779
8	Mountain-200 Black, ...	Bikes	Mountain	11719760.779
9	Mountain-200 Black, ...	Bikes	Mountain	11719760.779
10	Mountain-200 Black, ...	Bikes	Mountain	11719760.779
11	Mountain-200 Black, ...	Bikes	Mountain	11719760.779

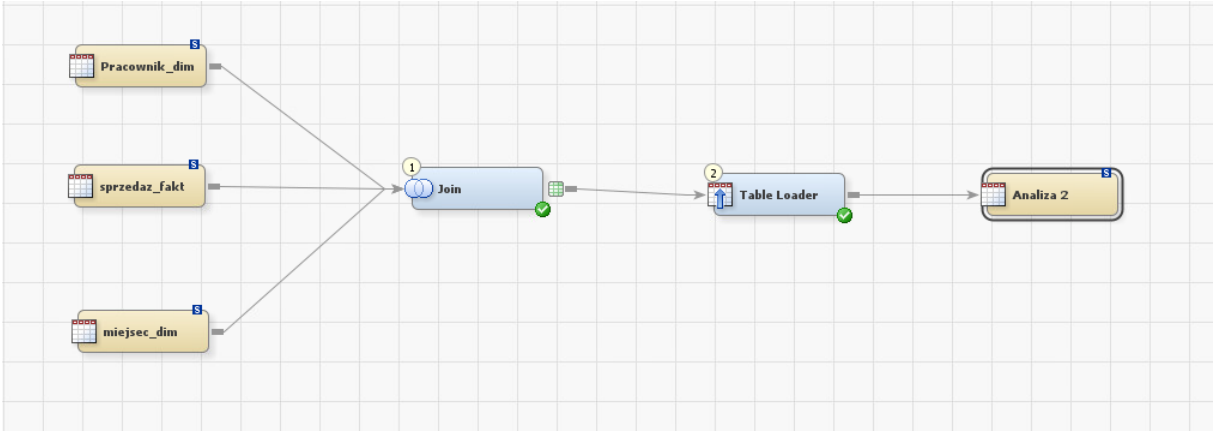
Rysunek 28 – Dane wynikowe analizy 1

#	Nazwa_produktu	kategoria	Podkategoria	Całkowita_sprzedaż
1	LL Road Seat/Saddle ...	Componen	Saddles	162.72
2	LL Road Seat/Saddle ...	Componen	Saddles	162.72
3	LL Road Seat/Saddle ...	Componen	Saddles	162.72
4	LL Road Seat/Saddle ...	Componen	Saddles	162.72
5	LL Road Seat/Saddle ...	Componen	Saddles	162.72
6	LL Road Seat/Saddle ...	Componen	Saddles	162.72
7	LL Touring Seat/Sadd ...	Componen	Saddles	1480.752
8	LL Touring Seat/Sadd ...	Componen	Saddles	1480.752
9	LL Touring Seat/Sadd ...	Componen	Saddles	1480.752
10	LL Touring Seat/Sadd ...	Componen	Saddles	1480.752

Rysunek 29 – Dane wynikowe analizy 1

Z otrzymanych danych można wyciągnąć wnioski ,że firma największy zysk zyskała na czarnym rowerze górskim z modelem określanym na 200.Za to najmniej dochodowym produktem jest siodełko rowero . Widac ,że firme w latach 2001-2004 głównie utrzymywała się ze sprzedaży rowerów górskich ,które to stanowią szczyt tabeli. Jest to spowodowane ,że cena rowerów jest zazwyczaj dużo wyższa niż komponentów znajdujących się na pozostałych miejscach tabeli co jest spójne i logiczne ,że komponenty z których składa się rower są pojedyńczo tańsze niż pełen produkt jakim jest rower.

Analiza 2 - Jako druga analiza jest przeanalizowanie sprzedaży osiągniętej przez poszczególnych pracowników w latach 2001-2004 oraz zbadanie czy istnieją czynniki mogące mieć wpływ na wielkość zysku wypracowanego przez danego sprzedawcę. Rozpoczęto od analizy rozkładu wielkości sprzedaży w zależności od pracowników w różnych regionach. Obliczono łączną sumę sprzedaży oraz średnią wartość przypadającą na jednego pracownika. Proces ETL obejmuje dwie tabele wymiarów – pracownika i lokalizację – oraz tabelę faktów



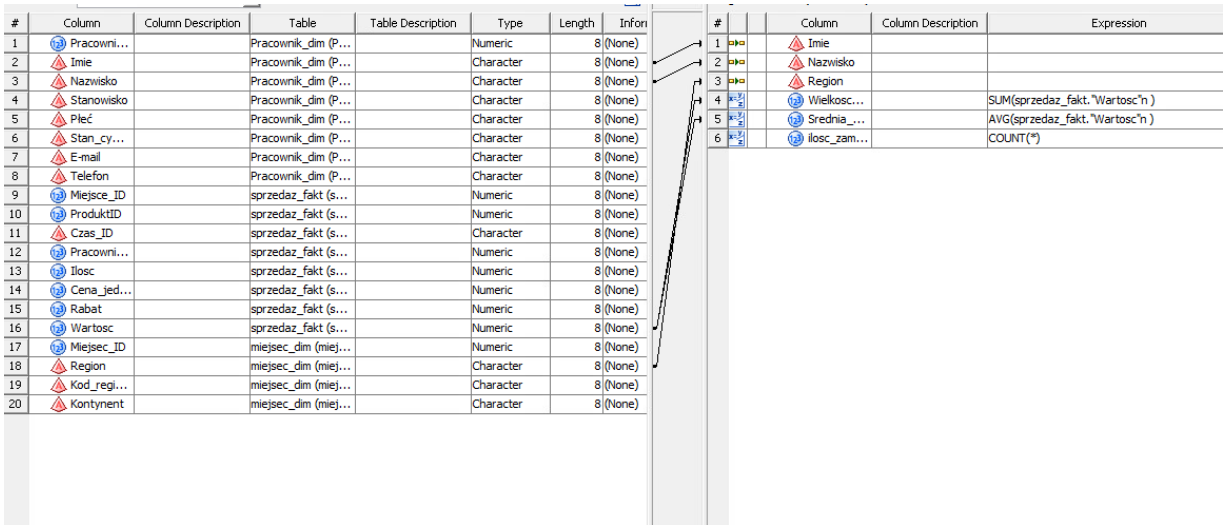
Rysunek 30 – Proces ETL analizy 2

W węźle join zostały połączane wymiary w następujący sposób

Boolean	(	Operand	Operator	Operand
		sprzedaz_fakt."Pracownik_ID"n	=	sprzedaz_fakt."Pracownik_ID"n
		sprzedaz_fakt."Miejsce_ID"n	=	sprzedaz_fakt."Miejsce_ID"n
		sprzedaz_fakt."Miejsce_ID"n	=	miejsec_dim."Miejsec_ID"n
		sprzedaz_fakt."Pracownik_ID"n	=	Pracownik_dim."Pracownik_ID"n

Rysunek 31 – połaczenie tabel

Następnie przeszedłem do Select gdzie utworzyłem oraz dodałem nowe kolumny takie jak Wielkosc sprzedaży, Srednia sprzedaż oraz ilość zamówień . W tym celu zastosowałem funkcje agregujące AVG ,SUM oraz COUNT .

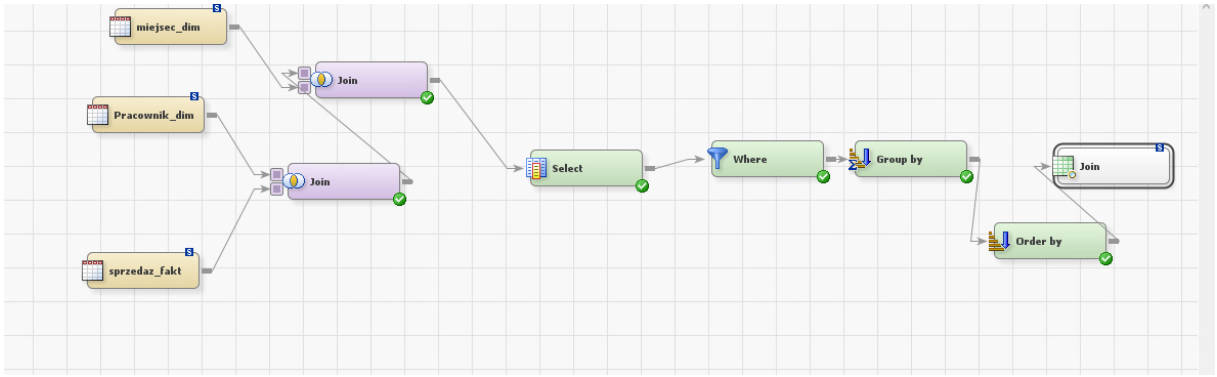


#	Column	Column Description	Table	Table Description	Type	Length	Infor
1	Pracowni...		Pracownik_dim (P...		Numeric	8	(None)
2	Imie		Pracownik_dim (P...		Character	8	(None)
3	Nazwisko		Pracownik_dim (P...		Character	8	(None)
4	Stanowisko		Pracownik_dim (P...		Character	8	(None)
5	Płeć		Pracownik_dim (P...		Character	8	(None)
6	Stan_cy...		Pracownik_dim (P...		Character	8	(None)
7	E-mail		Pracownik_dim (P...		Character	8	(None)
8	Telefon		Pracownik_dim (P...		Character	8	(None)
9	Miejsce_ID		sprzedaz_fakt (s...		Numeric	8	(None)
10	ProduktID		sprzedaz_fakt (s...		Numeric	8	(None)
11	Czas_ID		sprzedaz_fakt (s...		Character	8	(None)
12	Pracowni...		sprzedaz_fakt (s...		Numeric	8	(None)
13	Ilosc		sprzedaz_fakt (s...		Numeric	8	(None)
14	Cena_jed...		sprzedaz_fakt (s...		Numeric	8	(None)
15	Rabat		sprzedaz_fakt (s...		Numeric	8	(None)
16	Wartosc		sprzedaz_fakt (s...		Numeric	8	(None)
17	Miejsec_ID		miejsec_dim (miej...		Numeric	8	(None)
18	Region		miejsec_dim (miej...		Character	8	(None)
19	Kod_regi...		miejsec_dim (miej...		Character	8	(None)
20	Kontynent		miejsec_dim (miej...		Character	8	(None)

#	Column	Column Description	Expression
1	Imie		
2	Nazwisko		
3	Region		
4	Wielkosc...		SUM(sprzedaz_fakt."Wartosc"n)
5	Srednia_...		AVG(sprzedaz_fakt."Wartosc"n)
6	ilosc_zam...		COUNT(*)

Rysunek 32 – Kolumny analizy 2

Następnie dodałem klauzule group by wraz z klauzula order by dzięki ,którym pogrupowałem i posortowałem dane . Jako pierwszą dodałem group by przy pomocy ,której pogrupowałem dane według danych osobowych pracownika oraz regionu. Za pomocą order by posortowałem dane według wielkości sprzedaży.



Rysunek 33 – Węzeł join

W ten sposób otrzymaliśmy tak prezentujące się dane .

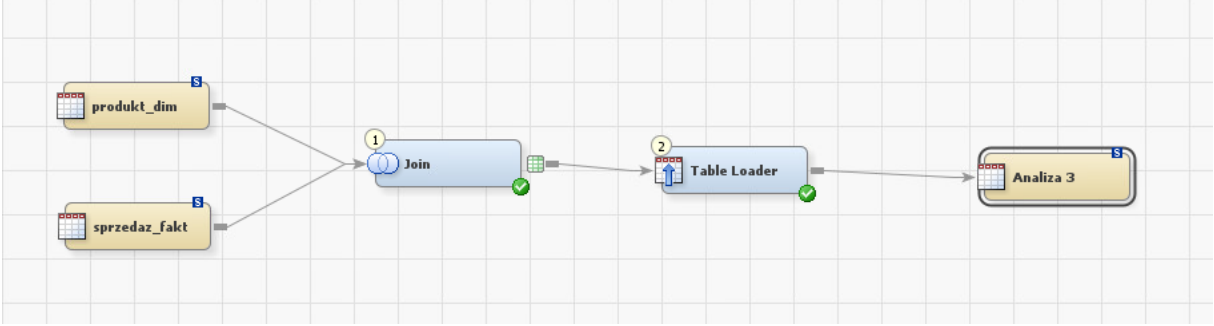
#	Imie	Nazwisko	Region	Wielkosc_sprzedazy	Srednia_sprzedaz	ilosc_zamowien
1	Jillian	Carson	United S	568067779.1	1251.9124187	453760
2	Michael	Blythe	United S	488505243.59	1304.7334302	374410
3	Ranjit	Varkey C	France	432949337.35	1319.0666659	328224
4	Tsvi	Reiter	United S	394405701.2	1323.7978123	297935
5	Linda	Mitchell	United S	383821945.99	1518.1028596	252830
6	Shu	Ito	United S	198942897.89	1391.9391142	142925
7	David	Campbell	United S	167847540.69	1659.9667774	101115
8	Pamela	Ansman-W	United S	149629616.73	1610.9993188	92880
9	Jae	Pak	Canada	110543402.39	1261.9974244	87594
10	Tete	Mensa-An	United S	104064556.05	1221.6300528	85185
11	Garrett	Vargas	Canada	46922813.792	1099.1008571	42692
12	Stephen	Jiang	United S	37382013.785	1350.5062783	27680
13	José	Saraiva	Canada	27150385.17	1641.8955715	16536
14	Rachel	Valdez	Germany	12789466.982	1024.7149253	12481
15	Amy	Alberts	France	9374304.18	879.72073761	10656
16	Lynn	Tsoflias	Australi	7109054.6192	968.53605166	7340
17	José	Saraiva	United K	3837927.1883	1212.6152254	3165
18	Stephen	Jiang	Canada	2296431.3544	1177.6571048	1950
19	Amy	Alberts	Germany	1358199.8216	1616.9045495	840
20	Syed	Abbas	Australi	862622.25537	704.18143296	1225
21	Amy	Alberts	United K	441081.63623	1242.4834823	355

Rysunek 34 – Dane wynikowe analizy 2

Dane przedstawione w tabeli pokazują wyniki sprzedaży dla różnych osób w różnych regionach, obejmując wielkość sprzedaży, średnią sprzedaż oraz liczbę zamówień. Największą wielkość sprzedaży osiągnęła Jillian Carson w Stanach Zjednoczonych (5,680,67779.1) przy liczbie zamówień wynoszącej 453,760, co świadczy o jej wysokiej wydajności w tym regionie. Najniższą średnią sprzedaż zanotowała Amy Alberts we Francji (879.72), co sugeruje potencjalne problemy na tym rynku. Najwyższą średnią sprzedaż osiągnął Garrett Vargas w Kanadzie (16,641.89), co może wskazywać na sprzedaż produktów o wyższej wartości jednostkowej.

Stany Zjednoczone wyróżniają się zarówno pod względem wielkości sprzedaży, jak i liczby zamówień, co czyni ten region kluczowym rynkiem. Kanada cechuje się wysoką średnią sprzedażą, mimo stosunkowo niższej liczby zamówień, co sugeruje, że warto rozwijać ofertę premium. Natomiast Francja wypada słabo, co może wskazywać na potrzebę optymalizacji strategii sprzedaży w tym regionie. Wnioski wskazują, że należy utrzymać silną pozycję w USA, rozwijać segment wysokowartościowych klientów, takich jak Garrett Vargas, oraz poprawić wyniki w słabszych regionach, szczególnie we Francji.

Analiza 3 – Trzecia analizą będzie analiza ilości udzielonych rabatów na dane produkty w latach 2001-2004. Celem analizy jest sprawdzenie czy obniżki wpływają na atrakcyjność produktów . Do procesu ETL zastosowaliśmy tabele sprzedaż_fakt oraz produkt_dim.



Rysunek 35 – Procest ETL analizy 3

W węźle join połączyliśmy ze sobą wyżej wymienione tabele za pomocą kolumny Produkt_ID

Następnie w SELECT dodałem nową kolumnę o nazwie liczba_rabatow , która będzie operowana za pomocą funkcji agregującej COUNT(*).

#	Column	Column Description	Table	Table Description	Type	Length	Infor
1	ProduktID		produkt_dim (pro…		Numeric	8	(None)
2	Nazwa_P…		produkt_dim (pro…		Character	100	(None)
3	Kategoria		produkt_dim (pro…		Character	8	(None)
4	Podkateg…		produkt_dim (pro…		Character	8	(None)
5	Miejsce_ID		sprzedaz_fakt (s…		Numeric	8	(None)
6	ProduktID		sprzedaz_fakt (s…		Numeric	8	(None)
7	Czas_ID		sprzedaz_fakt (s…		Character	8	(None)
8	Pracowni…		sprzedaz_fakt (s…		Numeric	8	(None)
9	Ilosc		sprzedaz_fakt (s…		Numeric	8	(None)
10	Cena_jed…		sprzedaz_fakt (s…		Numeric	8	(None)
11	Rabat		sprzedaz_fakt (s…		Numeric	8	(None)
12	Wartosc		sprzedaz_fakt (s…		Numeric	8	(None)

#	Column	Column Description	Expression
1	Liczba_ra…		COUNT(*)
2	Kategoria		
3	Podkateg…		

Rysunek 36 – kolumny analizy 3

Na ostatnim etapie tak jak w poprzednich analizach pogrupowaliśmy i posortowalismy dane . Dane zostały pogrupowane według kategorii i podkategorii a posortowane według utworzonej przez nas kolumny liczba_rabatow.

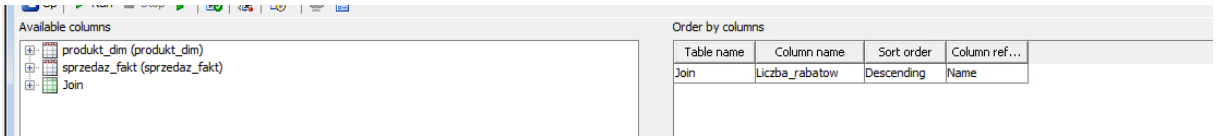
vailable columns

- produkt_dim (produkt_dim)
- sprzedaz_fakt (sprzedaz_fakt)
- Join

Group by columns

Table name	Column name	Column ref…
Join	Podkategoria	Name
Join	Kategoria	Name

Rysunek 37 – funkcja group by



Rysunek 38 – funkcja order by

Po przeładowniu danych w table loaderze otrzymaliśmy następujące dane .

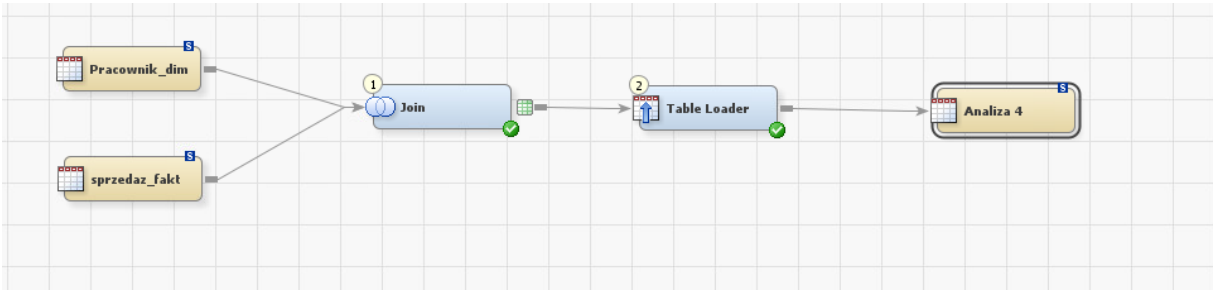
#	Liczba_rabatow	Kategoria	Podkategoria
1	791	Bikes	Touring
2	371	Bikes	Mountain
3	346	Accessor	Helmets
4	326	Clothing	Jerseys
5	247	Bikes	Road Bik
6	220	Clothing	Gloves
7	196	Clothing	Shorts
8	180	Clothing	Vests
9	112	Clothing	Caps
10	91	Clothing	Socks
11	66	Clothing	Tights
12	62	Accessor	Bike Rac
13	55	Accessor	Cleaners
14	55	Accessor	Bottles
15	44	Accessor	Hydratio
16	21	Clothing	Bib-Shor
17	15	Componen	Mountain
18	13	Componen	Touring
19	12	Componen	Wheels
20	9	Componen	Headsets
21	9	Componen	Road Fra
22	7	Accessor	Locks
23	7	Componen	Handleba
24	5	Accessor	Pumps
25	4	Componen	Saddles
26	4	Componen	Pedals
27	4	Componen	Deraille
28	3	Componen	Brakes
29	3	Componen	Chains
30	2	Componen	Crankset
31	1	Accessor	Tires an
32	1	Componen	Forks

Rysunek 39- dane wynikowe analizy 3

Analiza danych dotyczących liczby udzielonych rabatów w latach 2001-2004 pokazuje, że obniżki były najczęściej stosowane w kategorii rowerów ("Bikes"), gdzie podkategorie "Touring" (791 rabatów) i "Mountain" (371 rabatów) dominowały. Wskazuje to na dużą popularność tych produktów, a rabaty mogły znacznie zwiększać ich atrakcyjność. Podobnie

w kategorii odzieży ("Clothing") najwięcej rabatów dotyczyło "Jerseys" (326), "Gloves" (220) i "Shorts" (196), co sugeruje, że klienci chętnie korzystali z promocji na produkty poprawiające komfort jazdy. W kategorii akcesoriów ("Accessor") największą liczbę rabatów odnotowano na kaski ("Helmets" – 346), co wskazuje na znaczenie ochrony podczas jazdy. W przypadku komponentów rowerowych ("Componen") liczba rabatów była znacznie mniejsza, np. "Wheels" (13) czy "Headsets" (9), co może oznaczać, że rabaty miały ograniczony wpływ na ich sprzedaż lub te produkty są mniej popularne. Ogólnie rabaty wydają się skuteczne w zwiększaniu atrakcyjności produktów podstawowych, takich jak rowery i odzież, ale mniej efektywne w przypadku komponentów i mniej kluczowych akcesoriów.

Analiza 4 – Podczas czwartej analizy skupimy się na wpływie stanu cywilnego oraz płci na wydajność pracowników na ,która będzie wpływać ilość sprzedanych produktów przez pojedynczego pracownika . W procesie ETL zastosowaliśmy tabele pracownik_dim z ,której pobraliśmy takie informacje jak dane osobowe pracownika oraz jego stan cywilny wraz z płcią oraz tabele sprzedaż_fakt ,która udostępniła informację o ilości sprzedanych produktów.



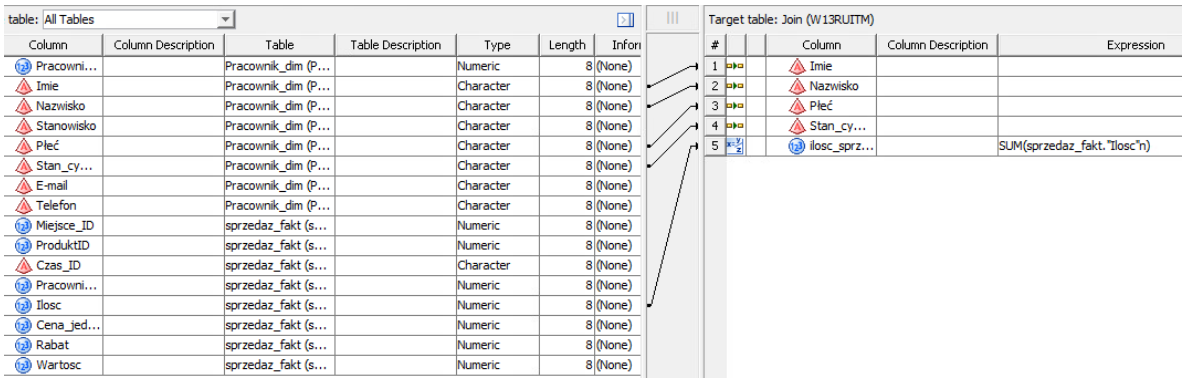
Rysunek 40 – proces ETL dla analizy 4

Tabele zostały scalone za pomocą węzła join za pomocą tabel przedstawionych na poniższym rysunku.

Boolean	(	Operand	Operator	Operand	)
		Pracownik_dim."Pracownik_ID"n	=	sprzedaz_fakt."Pracownik_ID"n	
AND		sprzedaz_fakt."Ilosc"n	<>	0	

Rysunek 41- definiowanie funkcji where

Kolejno przeszliśmy do tworzenia nowych kolumn w węźle SELECT gdzie utworzyliśmy kolumnę ilość_sprzedanych za pomocą funkcji agregującej SUM.



Rysunek 42 – kolumny analizy 4

Dane zostały pogrupowane według stanu cywilnego oraz płci ,natomiast posortowane według ilości_sprzedanych co przedstawiają poniższe rysunki.

Table name	Column name	Column ref...
Join	Stan_cywilny	Name
Join	Płeć	Name

Rysunek 43 – funkcja group by

Table name	Column name	Sort order	Column ref...
Join	ilosc_sprzedanych	Descending	Name

Rysunek 44 – funkcja order by

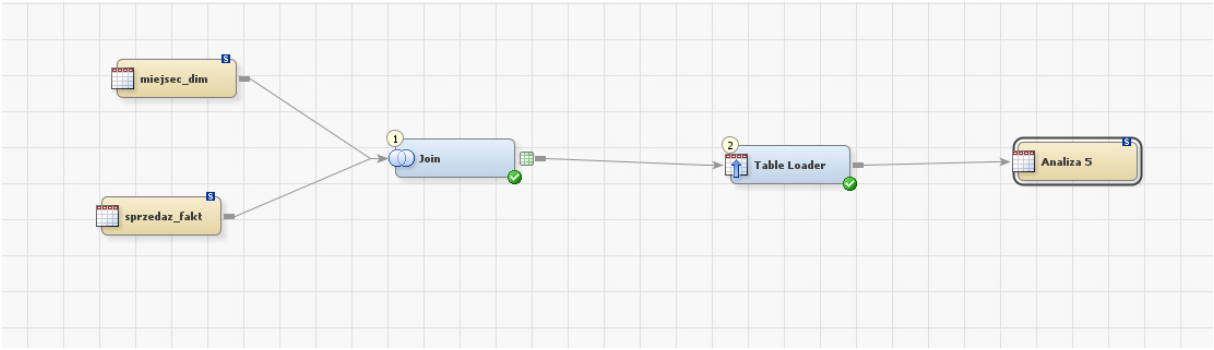
Po rozpoczęciu procesu ETL oraz przeładowaniu danych otrzymujemy dane wynikowe ,które przedstawiają się następująco.

#	Imie	Nazwisko	Płeć	Stan_cywilny	ilosc_sprzedanych
1	Linda	Mitchell	F	M	27229
2	Jillian	Carson	F	S	27051
3	Jae	Pak	F	M	26231
4	Michael	Blythe	M	S	23058
5	Tsvi	Reiter	M	M	16431
6	Shu	Ito	M	M	15397
7	José	Saraiva	M	M	15220
8	Ranjit	Varkey C	M	S	14085
9	Garrett	Vargas	M	M	11544
10	David	Campbell	M	S	8172
11	Pamela	Ansman-W	F	S	7360
12	Rachel	Valdez	F	S	7033
13	Tete	Mensa-An	M	M	5650
14	Lynn	Tsoflias	F	S	4123
15	Stephen	Jiang	M	M	3095
16	Amy	Alberts	F	M	2012
17	Syed	Abbas	M	M	825

Rysunek 45 - tabela wynikowa dla analizy 4

Analiza danych wskazuje, że zarówno płeć, jak i stan cywilny mają wpływ na liczbę sprzedanych produktów. Kobiety osiągają bardziej stabilne i wyższe wyniki sprzedaży w porównaniu z mężczyznami. Przykładowo, Linda Mitchell (27,229) i Jillian Carson (27,051) dominują w wynikach, podczas gdy najniższy wynik dla kobiet to 4,123 (Lynn Tsoflias). U mężczyzn widoczny jest większy rozrzut wyników – najwyższy osiąga Jae Pak (26,231), a najniższy Syed Abbas (825). Analizując wpływ stanu cywilnego, osoby samotne (S) często osiągają lepsze wyniki, jak Jae Pak (26,231) czy Jillian Carson (27,051), co może sugerować, że mają więcej czasu lub energii na rozwój sprzedaży. Żonaci (M) również mogą osiągać wysokie wyniki, czego przykładem jest Linda Mitchell (27,229), ale ich wyniki są bardziej zróżnicowane, z wieloma wynikami w niższych przedziałach, jak Tete Mensa-An (5,650). Po uwzględnieniu obu zmiennych, najbardziej efektywną grupą są kobiety-singielki, które dominują zarówno pod względem stabilności, jak i wysokości wyników. Mężczyźni-singlowie osiągają dobre wyniki, ale ich sprzedaż jest bardziej zróżnicowana, a żonaci mężczyźni częściej występują w niższych przedziałach. Podsumowując, wyniki sugerują, że kobiety, są najbardziej skuteczne w sprzedaży, a singlowie ogólnie osiągają lepsze wyniki niż osoby w związkach, choć różnice te nie są drastyczne.

Analiza 5 – Jako ostatnia analiza zostaną przeanalizowane regiony pod względem najwiekszej sprzedaży .Który z regionów jest najbardziej dochodowy oraz na którym kontynencie firma zyskuje największy dochód. Podczas procesu ETL zastosowalismy tabele sprzedaz_fakt oraz miejsce_dim . Proces ETL jest przedstawiony na rysunku poniżej.



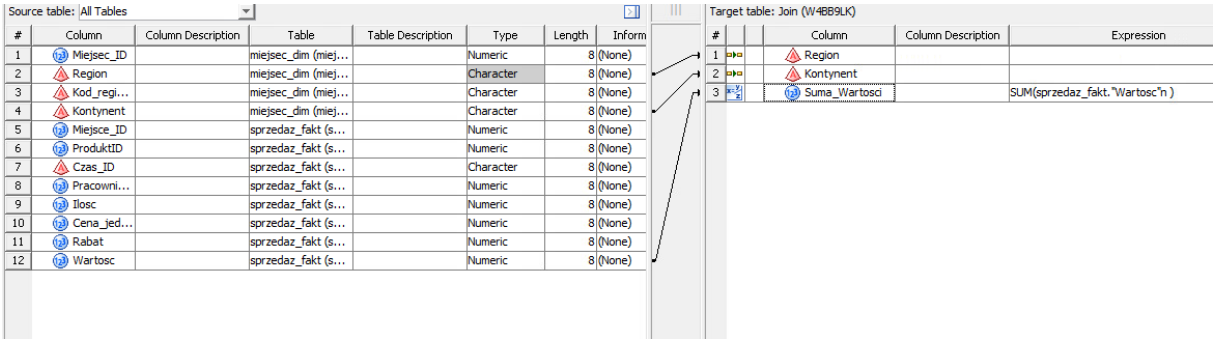
Rysunek 46 – Proces ETL analizy 5

Tak jak tabele w poprzednich analizach ta również została złączona za pomocą węzła join .

#	Boolean	(	Operand	Operator	Operand
1			sprzedaz_fakt."Miejsce_ID"n	=	miejsec_dim."Miejsec_ID"n
2	AND		sprzedaz_fakt."Miejsce_ID"n	=	sprzedaz_fakt."Miejsce_ID"n

Rysunek 47 – połaczenia tabel w analizie 5

Na potrzeby analizy utworzona została nowa kolumna Suma_wartosci opisująca sume wartości dla badanego regionu lub kontynentu.

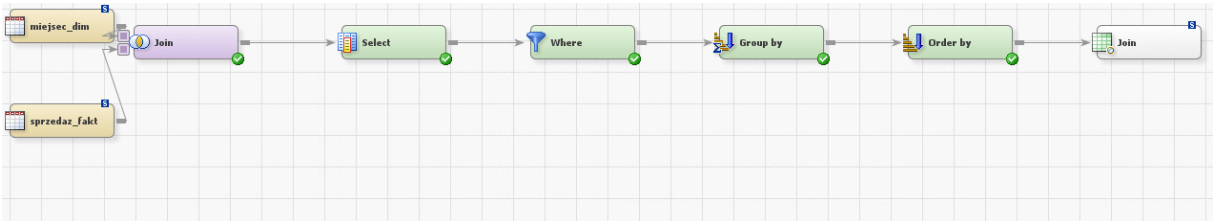


#	Column	Column Description	Table	Table Description	Type	Length	Inform
1	Miejsec_ID		miejsec_dim (miej...		Numeric	8	(None)
2	Region		miejsec_dim (miej...		Character	8	(None)
3	Kod_regi...		miejsec_dim (miej...		Character	8	(None)
4	Kontynent		miejsec_dim (miej...		Character	8	(None)
5	Miejsce_ID		sprzedaz_fakt (s...		Numeric	8	(None)
6	ProduktID		sprzedaz_fakt (s...		Numeric	8	(None)
7	Czas_ID		sprzedaz_fakt (s...		Character	8	(None)
8	Pracowni...		sprzedaz_fakt (s...		Numeric	8	(None)
9	Ilosc		sprzedaz_fakt (s...		Numeric	8	(None)
10	Cena_jed...		sprzedaz_fakt (s...		Numeric	8	(None)
11	Rabat		sprzedaz_fakt (s...		Numeric	8	(None)
12	Wartosc		sprzedaz_fakt (s...		Numeric	8	(None)

#	Column	Column Description	Expression
1	Region		
2	Kontynent		
3	Suma_Wartosci		SUM(sprzedaz_fakt."Wartosc"n)

Rysunek 48 – kolumny w analizie 5

Kolejno dane zostały pogrupowane oraz posortowane według regionu i kontynentu oraz sumy wartości.



Rysunek 49 – węzeł join

Przedstawiony proces ETL generuje następujące dane .

#	Region	Kontynent	Srednia _Wartosc
1	United S	North Am	2801205527.7
2	France	Europe	696149342.11
3	Canada	North Am	212625015.91
4	Australi	Pacific	53276679.797
5	Germany	Europe	34407853.171
6	United K	Europe	7670721.0355

Rysunek 50 – dane wynikowe analizy 5

W celu sprawdzenia kontynentów usuwamy region z tabel loadera oraz SELECT w wyniku czego otrzymujemy dane dotyczące kontynentów.

#	Kontynent	Srednia _Wartosc
1	North Am	3013830543.6
2	Europe	738227916.32
3	Pacific	53276679.797

Rysunek 51 – dane wynikowe analizy 5

Najbardziej dochodowym regionem w zestawieniu jest **United S**, który generuje dochód na poziomie **2801205527.7**. Ten wynik znacząco przewyższa pozostałe regiony i wskazuje na jego kluczowe znaczenie dla działalności firmy. Drugie miejsce zajmuje **France** z dochodem **696149342.11**, który stanowi największy wkład spośród europejskich regionów. Kolejne regiony, takie jak **Canada** z wynikiem **212625015.91** oraz **Australi** z **53276679.797**, generują znacznie niższe dochody, co może wynikać z mniejszego potencjału rynkowego lub ograniczonej skali działalności. **Germany** i **United K**, z dochodami odpowiednio **34407853.171** oraz **7670721.0355**, mają najmniejszy wkład w Europie, co wskazuje na ich marginalne znaczenie w porównaniu do liderów.

Jeśli chodzi o analizę kontynentów, **Ameryka Północna** (North Am) jest zdecydowanie najbardziej dochodowym kontynentem z łącznym wynikiem **3013830543.61**, co zawdzięcza przede wszystkim wkładowi United S oraz w mniejszym stopniu Kanady. **Europa**, z łącznym dochodem **738797916.32**, zajmuje drugie miejsce, a jej największym źródłem dochodu jest Francja, podczas gdy Niemcy i United K mają niewielki wpływ na ogólny wynik kontynentu. **Pacific**, reprezentowany jedynie przez Australię, generuje najmniejszy dochód w wysokości **53276679.80**, co może sugerować ograniczoną skalę działalności lub niższy potencjał rynkowy.

5.Podsumowanie

W praktycznej części mojego projektu skupiłem się na analizie sprzedaż w firme adventure works cycle w latach 2001-2004 co zakończyło się pomyślnie.

Pomyslnie przeprowadzony został również proces budowy hurtowni danych w oparciu o schemat gwiazdy w ,którym jedna tabela faktów (sprzedaż_fakt) oraz cztery tabele wymiarów (czas_dim ,miejsce_dim, produkt_dim ,pracownik_dim).

W pierwszym procesie ETL skupiliśmy się na wysokości całkowitej sprzedaży w latach 2001 -2004 według produktów. Celem procesu było określenie ,które z produktów przynoszą największe zyski .Z danych wynikowych dowiedzieliśmy się ,że największy zyski firma otrzymuje ze sprzedaży rowerów . Może to być spowodowane poprzez to ,że cena jednostkowa roweru jest sporo wyzsza niż pozostałych produktów jak na przykład części z , których taki rower się sklada. Taka analiza może być bardzo potrzebna w kontekście prowadzenia firmy ,ponieważ daje nam bardzo potrzebna wiedza ,która pomaga nam dokonywać prawidłowych inwestycji.

W drugim etapie analizie poddano sprzedaż osiągniętą przez poszczególnych pracowników w latach 2001–2004 oraz sprawdzono, czy istnieją czynniki mogące wpływać na wysokość zysków generowanych przez konkretnego sprzedawcę. Zauważono, że najwyższą sprzedaż osiągnęli pracownicy ze Stanów Zjednoczonych – zarówno liczba zamówień, jak i średnia sprzedaż w ich przypadku utrzymywały się na wysokim poziomie w porównaniu do innych pracowników. Wraz ze wzrostem liczby zamówień obserwowano również wyższe wyniki łącznej sprzedaży. Sugeruje to, że klienci ze Stanów Zjednoczonych częściej dokonują droższych zakupów niż klienci z innych regionów świata, choć średnie wartości zamówień w Kanadzie, Francji czy Niemczech nie odbiegały znacząco. Można zatem uznać, że kluczowymi czynnikami wpływającymi na całkowitą sprzedaż osiąganą przez pracowników firmy AdventureWorks Cycles są region działania oraz liczba realizowanych zamówień, która może zależeć np. od doświadczenia i stażu pracy.

W kolejnym procesie przeanalizowaliśmy ilości udzielonych rabatów na dane produkty w latach 2001-2004. Celem analizy jest sprawdzenie czy obniżki wpływają na atrakcyjność produktów. W przeprowadzonym procesie przeanalizowaliśmy liczbę udzielonych rabatów na poszczególne produkty w latach 2001–2004. Celem tej analizy było sprawdzenie, czy obniżki cen wpływają na atrakcyjność oferowanych produktów. Najwięcej rabatów udzielono w kategorii „Bikes” (Touring i Mountain), co może świadczyć o dużym zainteresowaniu tymi

podkategoriami w połączeniu z wysoką elastycznością cenową klientów. W przypadku akcesoriów, takich jak kaski (Helmets) czy stojaki na rowery (Bike Rac), zauważono także znaczącą liczbę obniżek, co sugeruje, że rabaty mogły wpływać na zwiększenie ich sprzedaży. Z kolei w kategorii „Clothing" największą liczbę rabatów zaobserwowano w podkategoriach takich jak Jerseys, Gloves czy Shorts, co wskazuje, że obniżki cen w tej grupie produktów mogły skutecznie przyciągać klientów. Produkty z kategorii „Components" charakteryzowały się mniejszą liczbą udzielonych rabatów, co może wynikać z ich specyfiki lub mniejszego wpływu obniżek na decyzje zakupowe klientów.

Podsumowując, analiza sugeruje, że w przypadku najpopularniejszych kategorii, takich jak „Bikes" czy „Clothing," obniżki cen mogły pełnić istotną rolę w zwiększaniu atrakcyjności produktów. Natomiast w mniej popularnych grupach, jak „Components," rabaty nie miały równie dużego znaczenia. W czwartym procesie ETL skupiliśmy się na wpływie płci oraz stanu cywilnego na wydajność pracowników, mierzoną liczbą sprzedanych produktów przez każdego z nich. Najwyższą wydajność odnotowano wśród kobiet, gdzie Linda Mitchell oraz Jillian Carson osiągnęły odpowiednio 27 229 i 27 051 sprzedanych produktów. Wyniki te sugerują, że kobiety mogą cechować się wysoką efektywnością sprzedażową, niezależnie od stanu cywilnego. W przypadku mężczyzn najlepszy wynik uzyskał Jae Pak, który sprzedał 26 231 produktów, co również plasuje go w czołówce w zestawieniu ogólnym. Kolejne wysokie wyniki należały do Michaela Blythe (23 061 sprzedanych produktów) i Tsvi Reitera (16 431 sprzedanych produktów). Analiza stanu cywilnego wykazała, że zarówno osoby zamężne/żonate (M), jak i osoby stanu wolnego (S) mogą osiągać wysoką wydajność. Warto jednak zauważyć, że wśród najwyższych wyników dominują osoby stanu wolnego (S), co może wskazywać na ich większą dyspozycyjność lub zaangażowanie w obowiązki zawodowe.

W już ostatnim procesie skupiliśmy się na regionach pod względem wielkości sprzedaży w celu określenia, który z nich jest najbardziej dochodowy, oraz na którym kontynencie firma generuje największe zyski. Najbardziej dochodowym regionem okazały się **Stany Zjednoczone** (United S), z łączną wartością sprzedaży wynoszącą 280 120 552,7. Jest to wynik zdecydowanie wyższy w porównaniu do pozostałych regionów, co czyni ten region kluczowym rynkiem dla firmy. Drugie miejsce zajmuje **Kanada** z wynikiem 212 625 015,91, co również wskazuje na duży potencjał kontynentu północnoamerykańskiego. **Francja** uplasowała się na trzecim miejscu z wartością 69 614 934,11, co pokazuje, że Europa, mimo mniejszych wyników w poszczególnych regionach, także przyczynia się do globalnych zysków firmy. Pod względem

kontynentów **Ameryka Północna** (North Am) generuje największy dochód, co wynika z połączenia wyników Stanów Zjednoczonych i Kanady. Znaczące wyniki osiągnął również kontynent europejski (Europe), choć jego najwyższy rezultat pochodził z Francji (69 614 934,11), a kolejne z Niemiec (34 407 853,17). Region Pacyfiku reprezentowany przez Australię osiągnął sprzedaż na poziomie 53 276 679,797, co jest wyraźnie niższe od liderów. Podsumowując, kluczowym regionem dla firmy są **Stany Zjednoczone**, a najbardziej dochodowym kontynentem – **Ameryka Północna**, która znacząco dominuje nad innymi pod względem wygenerowanego dochodu.