Spis treści

Wstęp 2
Metody prognozowania 3
Dane 3
Przygotowanie Danych 4
Porzucenie Danych 14
Partycjonowanie danych 14
Drzewo decyzyjne 15
Regresja logistyczna 19
Porównanie Modelu 23
Podsumowanie 29

Wstęp

Niniejsza praca została opracowana w ramach realizacji przedmiotu „Inżynieria procesu odkrywania wiedzy”. W celu przeprowadzenia analiz i realizacji założonych celów badawczych wykorzystano dwa narzędzia programistyczne: SAS BASE oraz SAS Enterprise Miner Workstation. Moduł SAS BASE posłużył przede wszystkim do przygotowania środowiska analitycznego, w tym do zaimportowania zbioru danych i przypisania go do odpowiednich bibliotek systemu. Z kolei SAS Enterprise Miner Workstation umożliwił przeprowadzenie szczegółowych analiz porównawczych z wykorzystaniem dwóch technik modelowania: drzewa decyzyjnego oraz regresji logistycznej.

Głównym pytaniem badawczym postawionym w pracy jest ocena skuteczności wspomnianych metod analitycznych w kontekście dostępnego zbioru danych. Celem autora było zidentyfikowanie, która z technik – drzewo decyzyjne czy regresja logistyczna – zapewnia lepsze wyniki predykcyjne i lepiej dopasowuje się do charakterystyki analizowanych danych.



Rysunek 1-Logo SAS

Metody prognozowania

Modele predykcyjne to narzędzia statystyczne i informatyczne, które służą do prognozowania przyszłych zdarzeń na podstawie danych historycznych. Wykorzystuje się je w różnych dziedzinach, takich jak biznes, medycyna, finansach, marketingu czy sporcie. Dają możliwość wystąpienia danego zjawiska dla określonych zmiennych na podstawie badania podmiotów występujących w próbie . Wyróżniamy następujące techniki modelowania predykcyjnego Regresja liniowa/logistyczna do przewidywania wartości liczbowych lub zdarzeń binarnych (tak/nie) Drzewa decyzyjne i lasy losowe (Random Forest) ,Gradient Boosting (np. XGBoost, LightGBM), Sieci neuronowe i deep learning . Niektóre z tych modeli wystąpią w kilku przypadkach pracy .

Dane

Dane wykorzystane w niniejszej pracy pochodzą ze strony internetowej https://www.kaggle.com/datasets/sagnik1511/car-insurance-data gdzie są udostępnione jako otwarty i bezpłatny zestaw danych w formacie CSV (Comma-Separated Values). Plik ten zawiera szczegółowe informacje dotyczące decyzji ubezpieczeniowych oraz danych demograficznych klientów, takich jak wiek, płeć, dochód, historia kredytowa, doświadczenie w prowadzeniu pojazdów czy liczba wcześniejszych wypadków.

Zbiór danych został przygotowany z myślą o analizach predykcyjnych, a jego głównym celem jest umożliwienie budowy modeli, które będą w stanie przewidywać, czy dany klient dostanie ubezpieczenie czy nie . W ramach niniejszej analizy zostaną porównane dwa popularne podejścia z zakresu uczenia maszynowego: regresja logistyczna oraz drzewo decyzyjne. Celem jest wybór najbardziej efektywnego modelu predykcyjnego, który zapewni najwyższą skuteczność prognozowania na podstawie dostępnych danych.

W bazie wystepuja następujące zmienne :

ID - ID

AGE - Wiek

GENDER - Płeć

RACE – Pochodzenie etniczne

DRIVING_EXPERIENCE - Doświadczenie w prowadzeniu pojazdu

EDUCATION - Wykształcenie

INCOME - Dochód

CREDIT_SCORE - Ocena kredytowa

VEHICLE_OWNERSHIP - Własność pojazdu

VEHICLE_YEAR - Rok produkcji pojazdu

MARRIED - Stan cywilny (Jeśli żonaty/zamężna 1 jeśli nie 0)

CHILDREN – Występowanie dzieci (jeśli tak 1 ,jeśli nie 0)

POSTAL_CODE - Kod pocztowy

ANNUAL_MILEAGE - Roczny przebieg

VEHICLE_TYPE - Typ pojazdu

SPEEDING_VIOLATIONS - Wykroczenia za przekroczenie prędkości

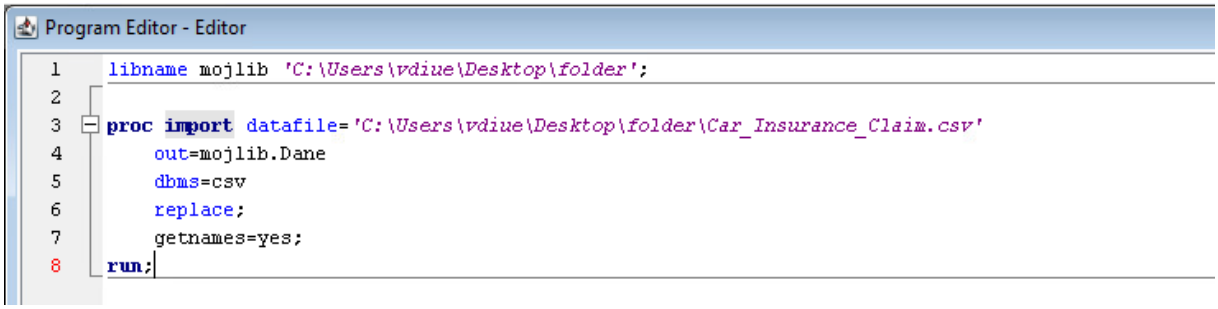
DUIS - Prowadzenie pod wpływem alkoholu/narkotyków (DUI)

PAST_ACCIDENTS - Wcześniejsze wypadki

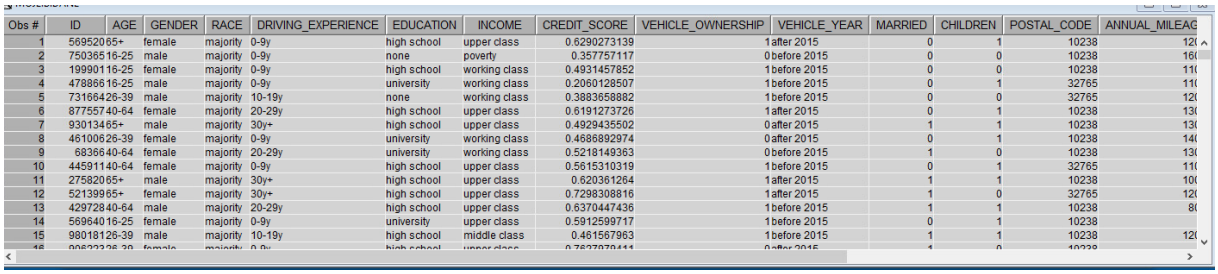
OUTCOME - Wynik wskazuje 1, jeśli klient dostał odszkodowanie z ubezpieczenia, w przeciwnym razie 0.

Przygotowanie Danych

Dane w formacie .csv zostały załadowane do programu SAS Enterpeise Miner poprzez SAS Base z wykorzystaniem kodu pokazanego na rysunku 2.



Rysunek 2-Kod importu danych



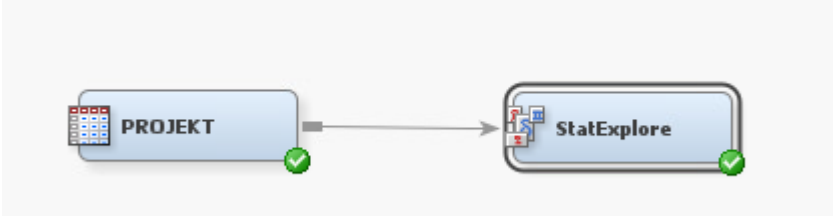
Obs #	ID	AGE	GENDER	RACE	DRIVING_EXPERIENCE	EDUCATION	INCOME	CREDIT_SCORE	VEHICLE_OWNERSHIP	VEHICLE_YEAR	MARRIED	CHILDREN	POSTAL_CODE	ANNUAL_MILEAG
1	569520	65+	female	majority	0-9y	high school	upper class	0.6290273139	1	after 2015	0	1	10238	12(
2	750365	16-25	male	majority	0-9y	none	poverty	0.357757117	0	before 2015	0	0	10238	16(
3	199901	16-25	female	majority	0-9y	high school	working class	0.4931457852	1	before 2015	0	0	10238	11(
4	478886	16-25	male	majority	0-9y	university	working class	0.2060128507	1	before 2015	0	1	32765	11(
5	731664	26-39	male	majority	10-19y	none	working class	0.3883658882	1	before 2015	0	0	32765	12(
6	877557	40-64	female	majority	20-29y	high school	upper class	0.6191273726	1	after 2015	0	1	10238	13(
7	930134	65+	male	majority	30y+	high school	upper class	0.4929435502	0	after 2015	1	1	10238	13(
8	461006	26-39	female	majority	0-9y	university	working class	0.4686892974	0	after 2015	0	1	10238	14(
9	68366	40-64	female	majority	20-29y	university	working class	0.5218149363	0	before 2015	1	0	10238	13(
10	445911	40-64	female	majority	0-9y	high school	upper class	0.5615310319	1	before 2015	0	1	32765	11(
11	275820	65+	male	majority	30y+	high school	upper class	0.620361264	1	after 2015	1	1	10238	10(
12	521399	65+	female	majority	30y+	high school	upper class	0.7298308816	1	after 2015	1	0	32765	12(
13	429728	40-64	male	majority	20-29y	high school	upper class	0.6370447436	1	before 2015	1	1	10238	8(
14	589640	16-25	female	majority	0-9y	university	upper class	0.5912599717	1	before 2015	0	1	10238	
15	980181	26-39	male	majority	10-19y	high school	middle class	0.461567963	1	before 2015	1	1	10238	12(

Rysunek 3 - zaimportowana baza danych

Zmienna celu została zmienna binarna (0,1) „target”,która określa czy ubezpieczenie zostało przyznane danej osobie(1) czy nie(0).Edukacja jest zmienna porządkową ,ponieważ zakładamy ,że rozne etapy edukacji maja rozna range. Jako nominale wybraem płeć , dochód (który określa warstwę społeczną) ,pochodzenie etniczne oraz typ pojazdu. Zmienne przedziałowe to wiek, średni roczny przebieg, ocena kredytowa , doświadczenie w jeździe, DUIS,ID, liczba ostatnich wypadków , wykroczenia z powodu prękośći, oraz rok pojazdu ,a pozostałe to zmienne binarne .

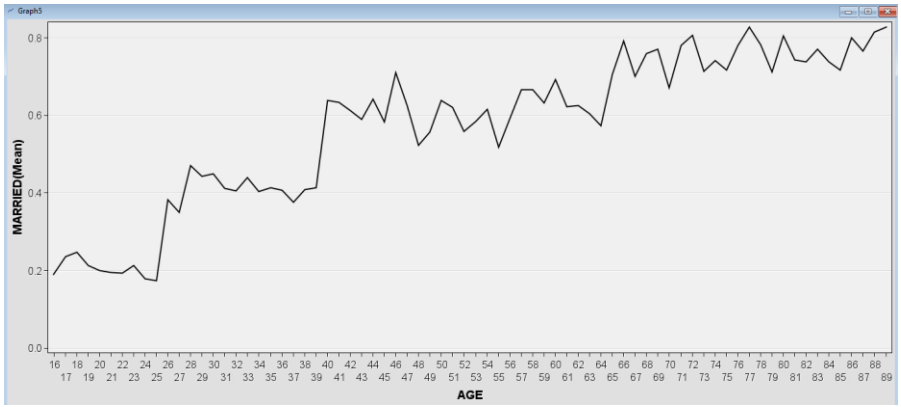
Name	Role	Level	Report	Order	Drop	Lower Limit	Upper Limit
AGE	Input	Interval	No		No	.	.
ANNUAL_MILEA	Input	Interval	No		No	.	.
CHILDREN	Input	Binary	No		No	.	.
CREDIT_SCORE	Input	Interval	No		No	.	.
DRIVING_EXPER	Input	Interval	No		No	.	.
DUIS	Input	Interval	No		No	.	.
EDUCATION	Input	Ordinal	No		No	.	.
GENDER	Input	Nominal	No		No	.	.
ID	ID	Interval	No		No	.	.
INCOME	Input	Nominal	No		No	.	.
MARRIED	Input	Binary	No		No	.	.
OUTCOME	Target	Binary	No		No	.	.
PAST_ACCIDEN	Input	Interval	No		No	.	.
POSTAL_CODE	Input	Ordinal	No		No	.	.
RACE	Input	Nominal	No		No	.	.
SPEEDING_VIOL	Input	Interval	No		No	.	.
VEHICLE_OWNE	Input	Binary	No		No	.	.
VEHICLE_TYPE	Input	Nominal	No		No	.	.
VEHICLE_YEAR	Input	Interval	No		No	.	.

Rysunek 4 - Rola i poziomy zmiennych



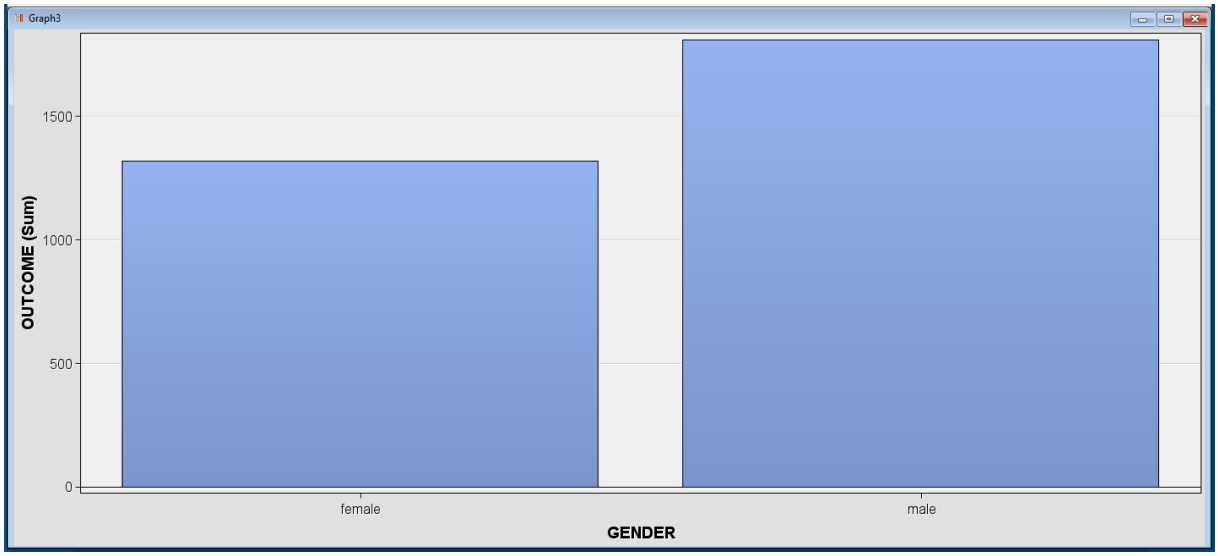
Rysunek 5 - Węzeł -Eksploracja statystyk

Wstępna eksploracja danych została przeprowadzona w celu lepszego zrozumienia danych i ewentualnego wychwycenia nieścisłości ,które mogą się w nich znajdować .



Rysunek 6 Wykres liniowy dla średniej liczby małżeństw w danym wieku

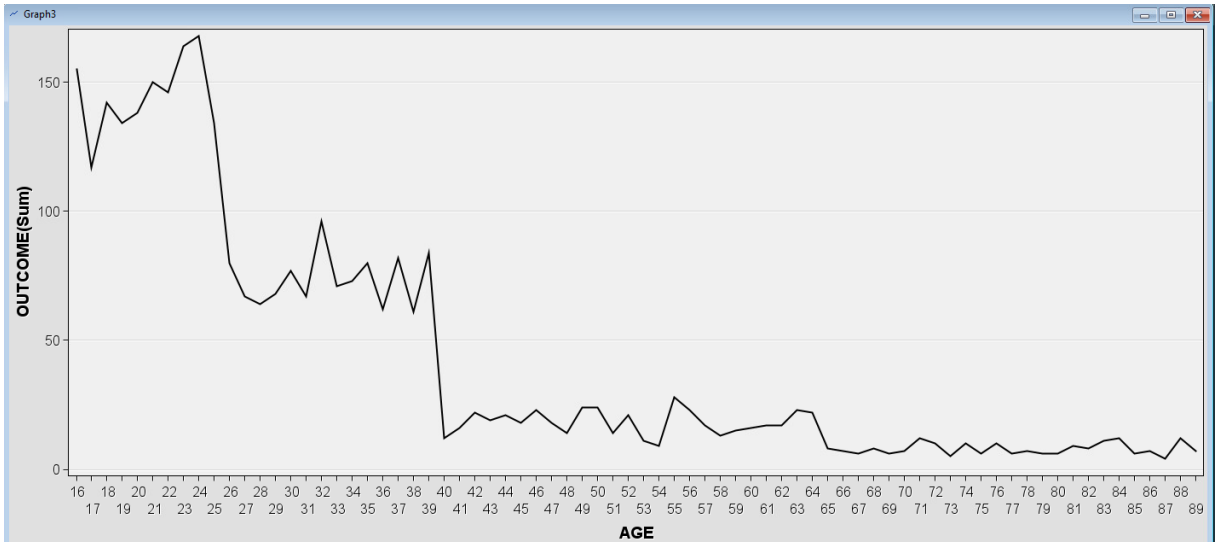
Wykres przedstawiony na rysunku 6 ukazuje wyraźną korelację pomiędzy wiekiem badanych a częstotliwością zawierania małżeństw. Z analizy danych wynika, że wraz ze wzrostem wieku rośnie również odsetek osób decydujących się na ślub. Oznacza to, że starsze grupy wiekowe znacznie częściej wchodzą w związki małżeńskie niż osoby młodsze, co może być związane z większą stabilizacją życiową, dojrzałością emocjonalną czy ugruntowaną sytuacją zawodową.



Rysunek 7 - Wykres słupkowy Płci oraz wyniku

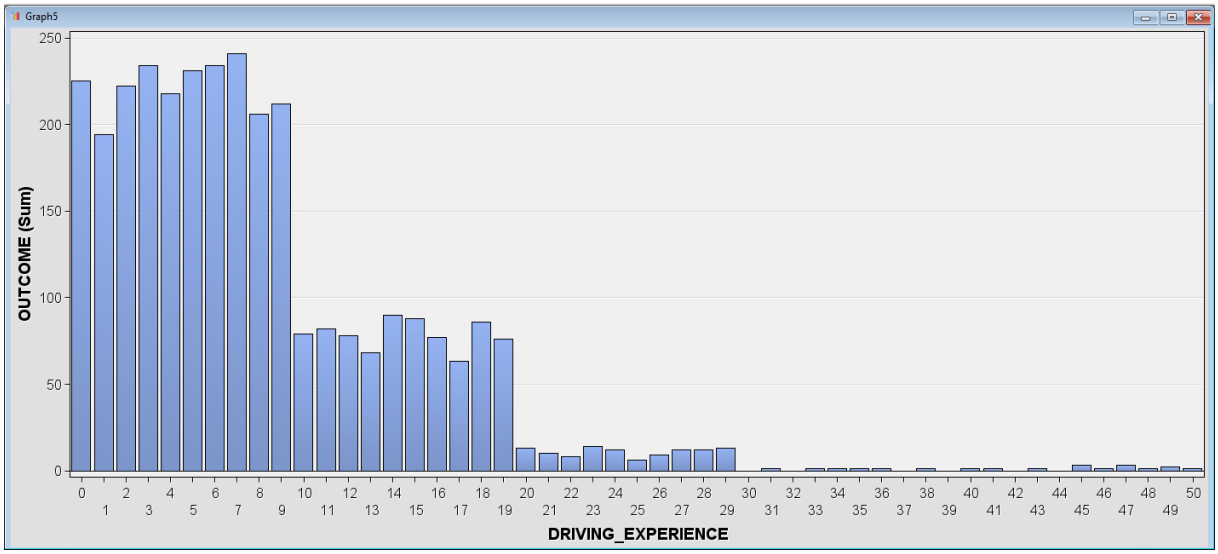
Na podstawie danych przedstawionych na wykresie można zauważyć, że znacznie większa liczba mężczyzn (1812 osób) otrzymała ubezpieczenie w porównaniu do kobiet, spośród których świadczenie to otrzymało jedynie 1312 osób. Pierwsza intuicyjna interpretacja

mogłaby sugerować, że w badaniu wzięło udział więcej mężczyzn niż kobiet, co tłumaczyłoby różnicę w wynikach. Jednak po bliższym przyjrzeniu się okazuje się, że było wręcz przeciwnie — liczba przebadanych kobiet wyniosła 5010, natomiast mężczyzn 4990. Różnica ta jest znikoma i nie wpływa istotnie na ogólny obraz próby, dlatego możemy stwierdzić, że dane pod względem płci zostały dobrze zrównoważone. Tym samym, różnica w liczbie osób objętych ubezpieczeniem wynika najprawdopodobniej z innych czynników, takich jak różnice w rodzaju zatrudnienia, branży czy dostępności świadczeń dla danej płci.



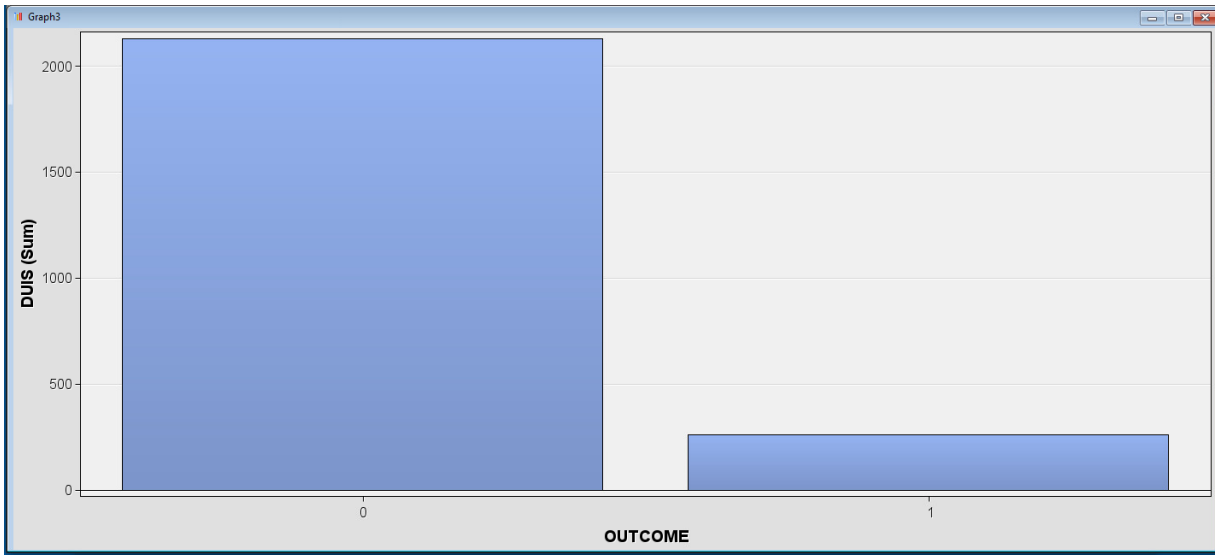
Rysunek 8 - Wykres liniowy wieku to wyniku

Wykres przedstawia zależność między wiekiem klientów a sumą wypłat odszkodowań z ubezpieczenia. Najwyższe wartości wypłat odnotowano wśród osób młodych, szczególnie w przedziale wiekowym 18–26 lat, gdzie suma odszkodowań przekracza 150 jednostek. Wskazuje to, że młodsze osoby częściej otrzymują odszkodowania, co może wynikać z większej podatności na wypadki, ryzykownych zachowań lub intensywniejszego stylu życia. Po 26. roku życia następuje wyraźny spadek wypłat, a od około 40. roku życia suma odszkodowań utrzymuje się już na bardzo niskim poziomie. W grupie wiekowej 40–89 lat wartości te pozostają stabilnie niskie, co sugeruje mniejsze zaangażowanie w sytuacje prowadzące do roszczeń ubezpieczeniowych lub rzadsze korzystanie z ochrony ubezpieczeniowej w starszym wieku. Ogólnie wykres wskazuje na silną zależność między wiekiem a częstością wypłat odszkodowań – im młodszy klient, tym większe prawdopodobieństwo otrzymania świadczenia z ubezpieczenia.



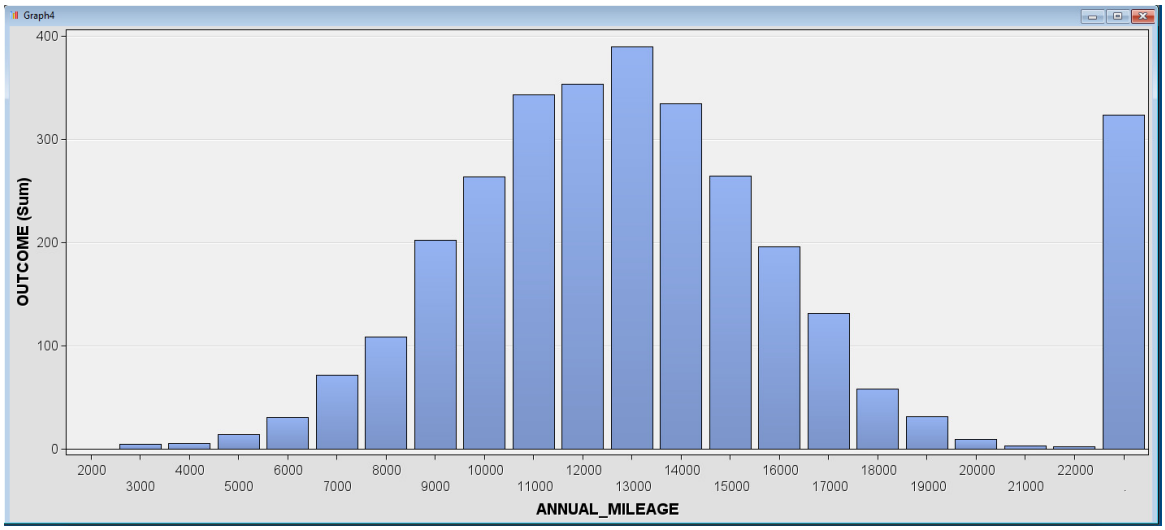
Rysunek 9 - Wykres słupkowu wieku oraz wyniku

Wykres przedstawia zależność między doświadczeniem w prowadzeniu pojazdów (DRIVING_EXPERIENCE) a sumą wypłat odszkodowań z ubezpieczenia (OUTCOME). Najwyższe wartości odszkodowań przypadają na kierowców z niewielkim doświadczeniem – od 0 do 9 lat. W tej grupie suma wypłat utrzymuje się na bardzo wysokim poziomie, przekraczając 200 jednostek, a szczyt przypada na około 7 lat doświadczenia. Po przekroczeniu 9 lat doświadczenia obserwujemy gwałtowny spadek liczby wypłat. W przedziale 10–19 lat wartości są już znacznie niższe (około 50–80 jednostek), a po 20 latach doświadczenia suma odszkodowań staje się marginalna i niemal niezmienna – oscylując wokół zera aż do 50 lat doświadczenia. Wnioski z wykresu są jednoznaczne: im mniejsze doświadczenie za kierownicą, tym większe ryzyko otrzymania odszkodowania, co może wynikać z większej liczby błędów, braku umiejętności lub nieostrożności. Natomiast osoby z wieloletnim doświadczeniem prowadzą pojazdy ostrożniej i rzadziej uczestniczą w zdarzeniach skutkujących roszczeniami ubezpieczeniowymi.



Rysunek 10 - Wykres słupkowy DUIS a wyniku

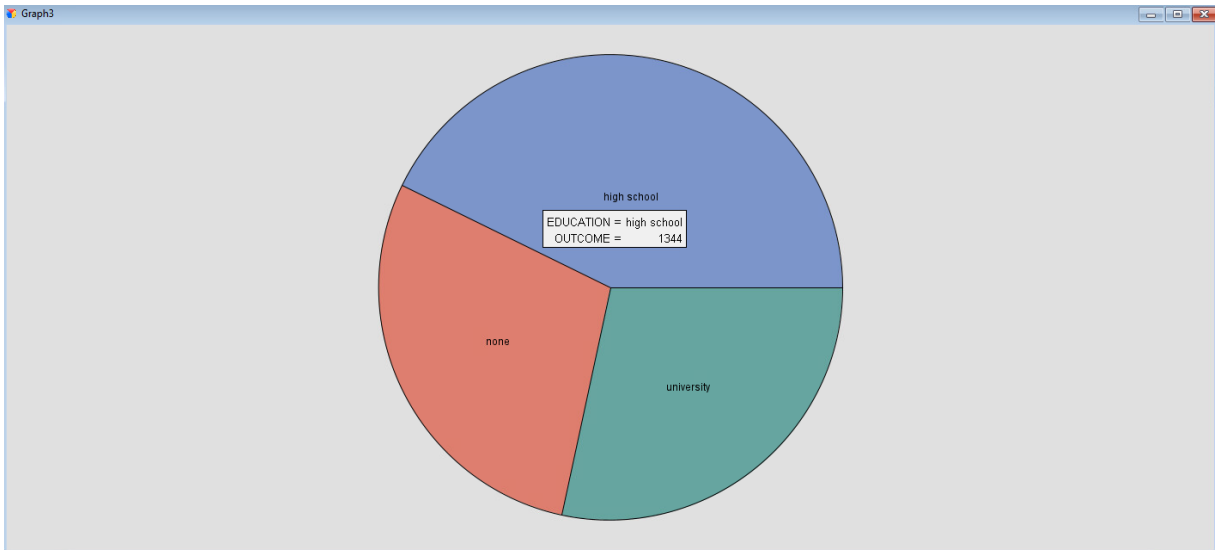
Wykres przedstawia wyraźną zależność pomiędzy byciem pod wpływem narkotyków a otrzymaniem ubezpieczenia. Z danych wynika, że aż 2130 osób, które znajdowały się pod wpływem substancji odurzających w momencie zdarzenia, nie otrzymało ubezpieczenia, podczas gdy jedynie 262 osoby w takiej sytuacji zostały objęte świadczeniem. Tak znacząca różnica sugeruje, że badana instytucja ubezpieczeniowa zdecydowanie odmawia wypłaty odszkodowania osobom, które w chwili wypadku były pod wpływem narkotyków lub innych środków psychoaktywnych. Może to wynikać z zapisów w regulaminie ubezpieczenia, które wykluczają ochronę w przypadku, gdy zachowanie ubezpieczonego narusza zasady bezpieczeństwa lub prawa.



Rysunek 11- Wykres słupkowy średniego rocznego przebiegu ,a wyniku

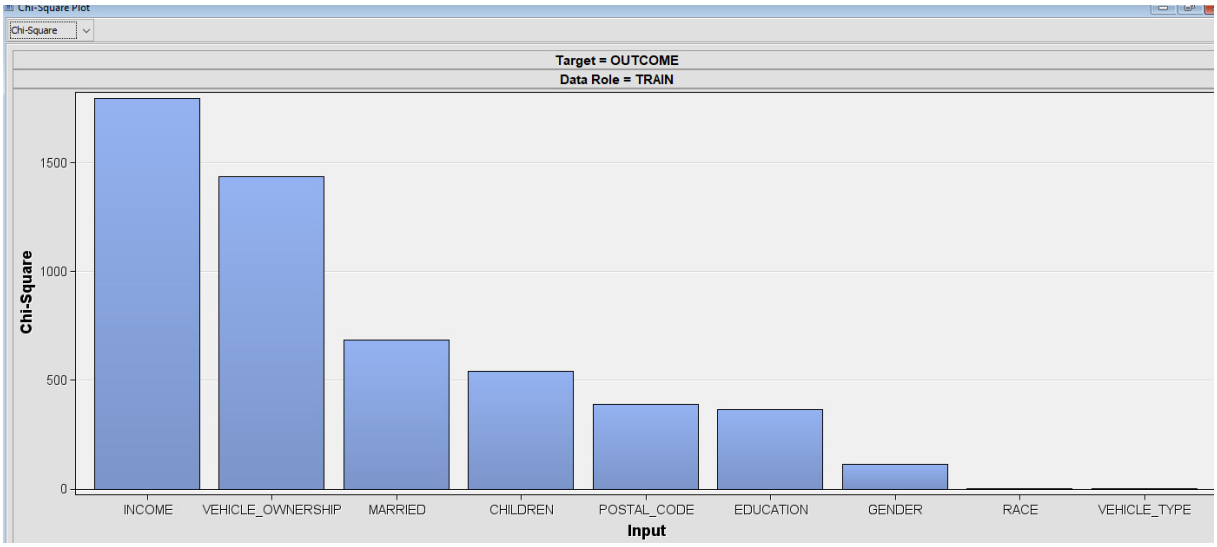
Z wykresu można z łatwością odczytać, że osoby pokonujące rocznie od około 10 000 do 14 000 kilometrów najczęściej otrzymują odszkodowanie. W tym przedziale przebiegu obserwujemy najwyższą liczbę wypłaconych świadczeń, co może sugerować, że jest to grupa kierowców najbardziej narażona na ryzyko wypadków drogowych – być może z powodu częstej jazdy, ale jeszcze nie na tyle intensywnej, by wykształcić w pełni profesjonalne nawyki za kierownicą. Warto również zwrócić uwagę na nagły wzrost liczby wypłat ubezpieczenia przy przebiegach przekraczających 22 000 kilometrów rocznie. Taka tendencja może wskazywać, że osoby pokonujące tak duże dystanse zawodowo – na przykład kierowcy ciężarówek, kurierzy czy przedstawiciele handlowi – są bardziej narażone na ryzyko wypadków ze względu na długie godziny spędzane za kierownicą, zmęczenie lub stres

związany z pracą. Tym samym, wzrost liczby wypłacanych odszkodowań w tej grupie może być bezpośrednio związany z charakterem wykonywanego zawodu.



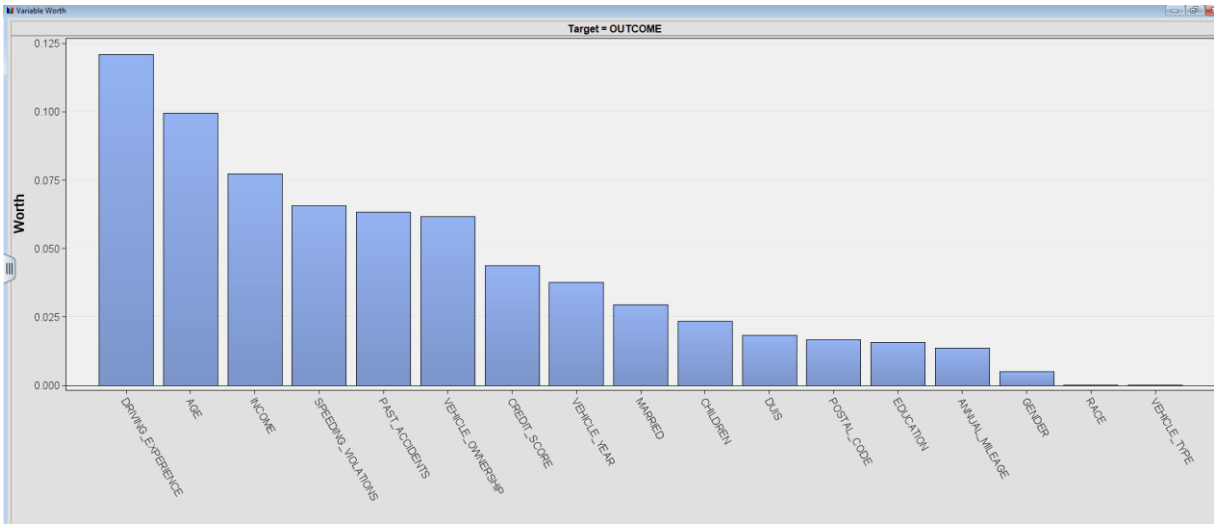
Rysunek 12 - Wykształcenie , a wynik

Na wykresie kołowym można zauważyć, że największy odsetek osób, które otrzymały odszkodowanie, stanowią osoby z wykształceniem średnim. Choć na pierwszy rzut oka mogłoby się wydawać, że to właśnie ta grupa jest najczęściej obejmowana świadczeniem, warto zwrócić uwagę na pewne ograniczenia w interpretacji tych danych. Przede wszystkim, próba badawcza nie została równomiernie rozłożona pomiędzy grupy o różnym poziomie wykształcenia. Osób z wykształceniem średnim przebadano znacznie więcej – aż 4157 – w porównaniu na przykład do osób bez wykształcenia, których liczba była znacznie mniejsza. Tak nierównomierny rozkład może wpływać na ogólny obraz wyników i sugerować dominację jednej grupy, mimo że niekoniecznie odzwierciedla ona rzeczywistą zależność między poziomem wykształcenia a uzyskaniem odszkodowania. Dlatego, aby wyciągnąć bardziej wiarygodne wnioski, należałoby przeprowadzić analizę z uwzględnieniem proporcji badanych w każdej kategorii oraz ich udziału w ogólnej liczbie wypłat ubezpieczenia.



Rysunek 13 -Chi-kwadrat dla zmiennych

Węzeł eksploracji statystyk generuje statystyki opisowe, które pomagają w analizie wpływu poszczególnych zmiennych na zmienną celu. W ramach tego procesu tworzony jest wykres chi-kwadrat oraz zestawienie wartości zmiennych, które pozwalają określić, które cechy mają największe znaczenie predykcyjne. W analizowanym przypadku największy wpływ na zmienną celu wykazują zmienne **„income”** (dochód) oraz **„vehicle_ownership”** (posiadanie pojazdu). Oznacza to, że osoby o różnym poziomie dochodów oraz te posiadające lub nieposiadające pojazdu znacząco różnią się pod względem przewidywanej zmiennej wyjściowej, co może być istotne przy budowie modelu predykcyjnego. Z kolei takie zmienne jak **pochodzenie etniczne** oraz **typ pojazdu** wykazały najsłabszy wpływ na zmienną celu, co sugeruje, że ich znaczenie w kontekście przewidywania wyników jest marginalne. W praktyce może to oznaczać, że nie wnoszą istotnej informacji i mogą być pominięte przy dalszym modelowaniu, jeśli celem jest uproszczenie modelu bez utraty dokładności.



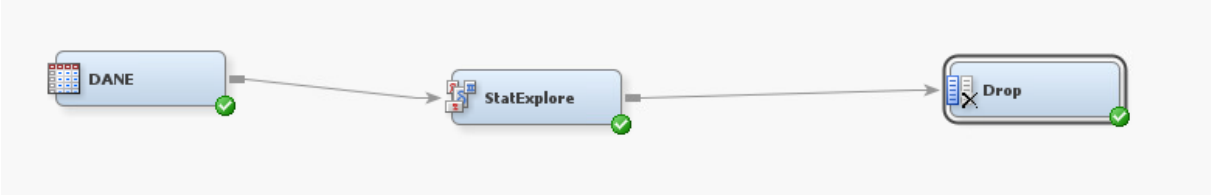
Rysunek 14 -Wykres istotnosci zmiennych

)ata Role	Variable Name	Role	Number of Levels	Missing	Mode	Mode Percentage	Mode2	Mode2 Percentage
TRAIN	CHILDREN	INPUT	2	0	1	68.88	0	31.12
TRAIN	EDUCATION	INPUT	3	0	high school	41.57	university	39.28
TRAIN	GENDER	INPUT	2	0	female	50.10	male	49.90
TRAIN	INCOME	INPUT	4	0	upper class	43.36	middle class	21.38
TRAIN	MARRIED	INPUT	2	0	0	50.18	1	49.82
TRAIN	POSTAL_CODE	INPUT	4	0	10238	69.40	32765	24.56
TRAIN	RACE	INPUT	2	0	majority	90.12	minority	9.88
TRAIN	VEHICLE_OWNERSHIP	INPUT	2	0	1	69.70	0	30.30
TRAIN	VEHICLE_TYPE	INPUT	2	0	sedan	95.23	sport	4.77
TRAIN	OUTCOME	TARGET	2	0	0	68.67	1	31.33

Rysunek 15 - Podsumowanie statystyczne dla zmiennych

Na podstawie statystyk podsumowujących zmienne, dalsza analiza wykazała, że procentowy udział dominującej wartości — czyli mody — dla zmiennych takich jak **typ pojazdu (sedan)** oraz **rasa (mniejszość)** jest wyjątkowo wysoki i wynosi odpowiednio **90,12%** oraz **95,23%**. Tak wysoki odsetek jednej kategorii w obrębie danej zmiennej oznacza bardzo niską zmienność, co z kolei przekłada się na ich niewielką wartość informacyjną. To właśnie ta dominacja jednej wartości w każdej z tych zmiennych jest głównym powodem, dla którego zarówno w **wykresie chi-kwadrat**, jak i w analizie **Variable Worth**, zmienne te zostały ocenione jako mające najniższy wpływ na zmienną celu. Warto również zaznaczyć, że na podstawie uzyskanych danych można stwierdzić brak brakujących wartości w analizowanym zbiorze danych, co pozytywnie wpływa na wiarygodność i spójność wyników.

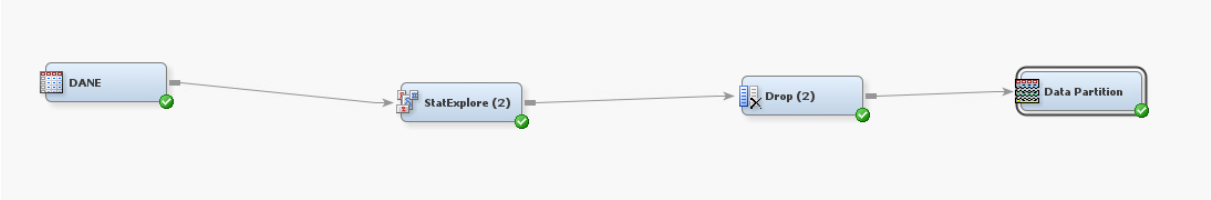
Porzucenie Danych



Rysunek 16 - Węzeł porzucenie

Ponieważ zmienne ID oraz postal code składają się wyłącznie z unikalnych wartości, które nie wnoszą istotnych informacji do analizy, podjęta została decyzja o ich usunięciu w celu zmniejszenia złożoności modelu końcowego.

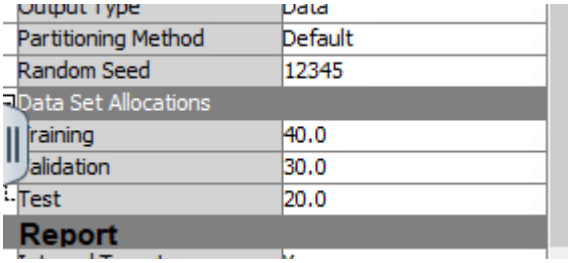
Partycjonowanie danych



Rysunek 17 - Węzeł partycjonowanie

Kolejnym krokiem w przygotowaniu modelu jest określenie jaki zbiór danych będzie używany do uczenia,walidacji,testów .Do tego używamy partycjonowania

Dane zostały podzielone na zestaw do uczenia 40% , zestaw do walicaji 30% i zestaw do testów 20%



Rysunek 18- Ustawienia wezla partycjonowanie

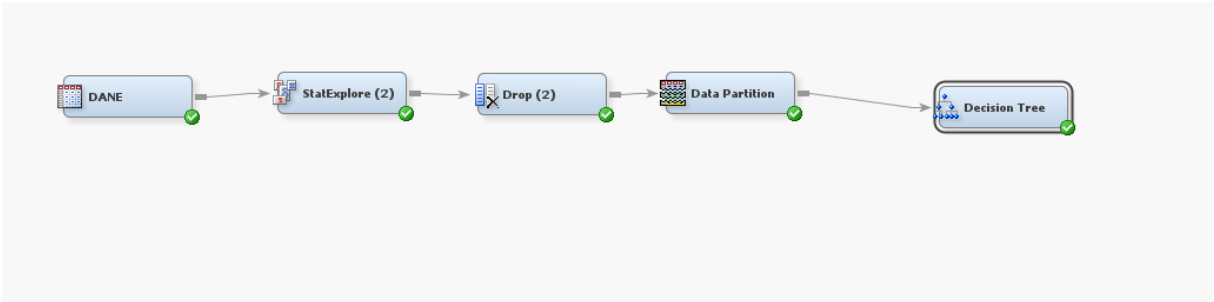
Partition Summary

Type	Data Set	Number of Observations
DATA	EMWS2.Drop2_TRAIN	10000
TRAIN	EMWS2.Part_TRAIN	4443
VALIDATE	EMWS2.Part_VALIDATE	3333
TEST	EMWS2.Part_TEST	2224

Rysunek 19 - Podsumowanie partycjonowania

Drzewo decyzyjne

Celem niniejszej pracy jest porównanie dwóch popularnych modeli uczenia maszynowego: drzewa decyzyjnego oraz regresji logistycznej. Analiza opiera się na ocenie ich skuteczności w zadaniu klasyfikacji danych. Dane zostały rozdzielone po węźle partycjonowania na dwie ścieżki: pierwszą skierowaną do modelu drzewa decyzyjnego, a drugą – do regresji logistycznej. Taki podział umożliwia niezależną ocenę działania obu metod. Model drzewa decyzyjnego został zbudowany w oparciu o domyślne ustawienia. Wszystkie parametry, takie jak głębokość drzewa, kryterium podziału czy minimalna liczba próbek w węźle, przyjęły wartości domyślne oferowane przez zastosowane narzędzie analityczne. Dzięki temu możliwe jest uzyskanie bazowej oceny wydajności modelu przed ewentualną optymalizacją.

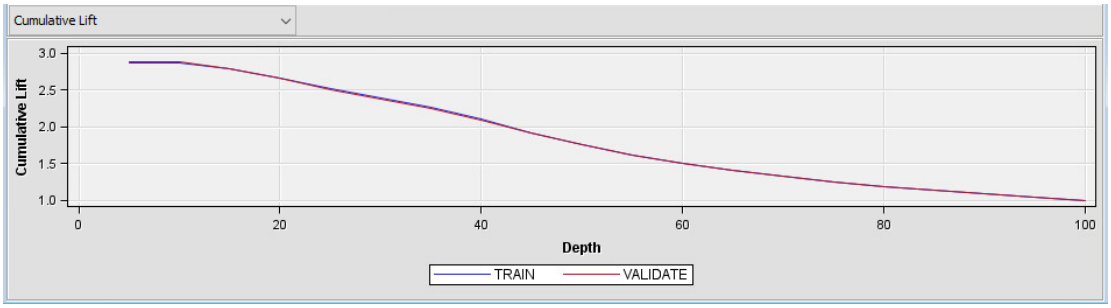


Rysunek 20 - Węzeł drzewa decyzyjnego

Property	Value
Node	
Leaf Size	5
Number of Rules	5
Number of Surrogate Rules	0
Split Size	.
Split Search	
Use Decisions	No
Use Priors	No
Exhaustive	5000
Node Sample	20000
Subtree	
Method	Assessment
Number of Leaves	1
Assessment Measure	Decision
Assessment Fraction	0.25
Cross Validation	
Perform Cross Validation	No
Number of Subsets	10
Number of Repeats	1
Seed	12345

Rysunek 21 - Ustawienia dla drzewa decyzyjnego

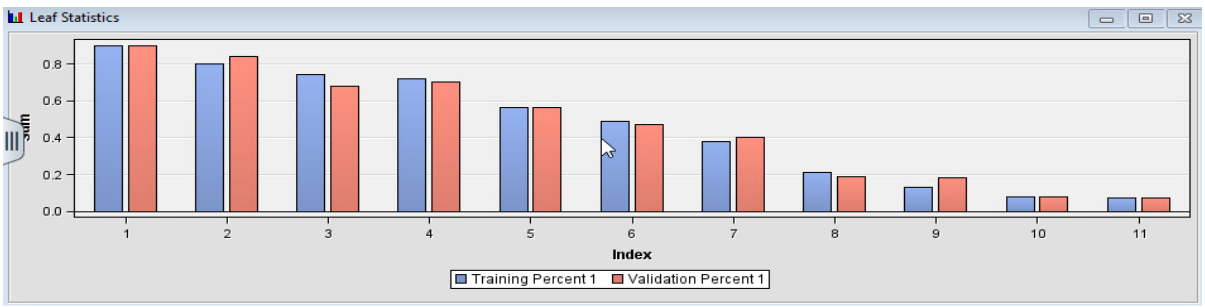
Rezultaty:



Rysunek 22- Nakładka rankingów wyników punktowych: drzewo

Skumulowany wykres rozrzutu wskazuje na zgodność rozkładów danych w zbiorze treningowym i walidacyjnym, co świadczy o poprawnym dopasowaniu modelu. Brak istotnych różnic między tymi rozkładami sugeruje, że model dobrze generalizuje i nie wykazuje oznak przetrenowania ani niedouczenia.

W przypadku, gdyby wykresy znacząco się różniły, mogłoby to świadczyć o zbyt małym dopasowaniu modelu do danych (niedotrenowaniu) lub odwrotnie – o zbyt silnym dopasowaniu do danych treningowych kosztem zdolności generalizacji (przetrenowaniu).



Rysunek 23 - Statystyki liściowe

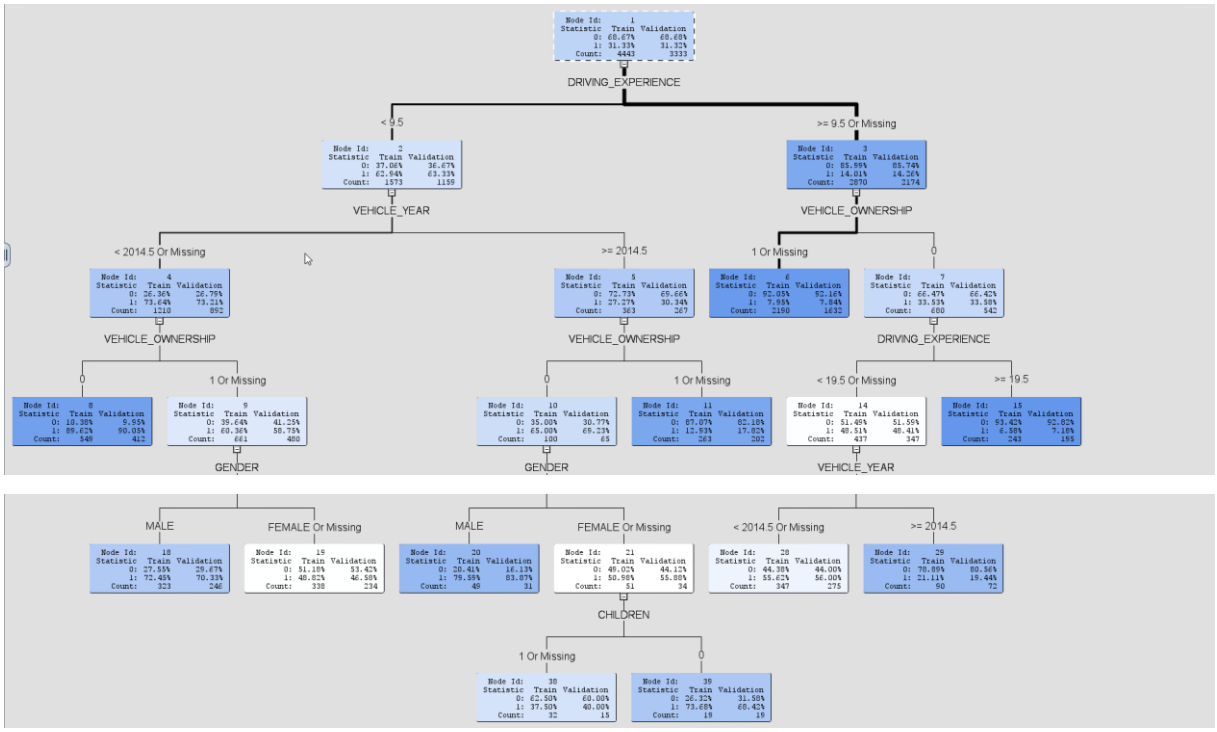
Powyższy wykres umożliwia porównanie procentowego udziału wartości zmiennej celu równej 1 we wszystkich liściach modelu, zarówno dla zbioru treningowego, jak i walidacyjnego. Dzięki temu możliwa jest ocena, czy model zachowuje spójność predykcji pomiędzy etapem uczenia a walidacją. Duże różnice w wysokościach słupków między oboma zbiorami mogą wskazywać na niestabilność modelu i konieczność przycięcia odpowiedniego liścia, aby poprawić ogólność predykcji. W analizowanym przypadku nie zaobserwowano istotnych odchyleń, dlatego nie ma potrzeby wprowadzania zmian w strukturze drzewa.

Fit Statistics

Target	Target Label	Fit Statistics	Statistics Label	Train	Validation	Test
OUTCOME		_NOBS_	Sum of Fre...	4443	3333	2224
OUTCOME		_MISC_	Misclassific...	0.165429	0.165917	0.181205
OUTCOME		_MAX_	Maximum A...	0.934156	0.934156	0.934156
OUTCOME		_SSE_	Sum of Squ...	1049.049	797.6612	563.9294
OUTCOME		_ASE_	Average Sq...	0.118056	0.119661	0.126783
OUTCOME		_RASE_	Root Avera...	0.343593	0.345921	0.356066
OUTCOME		_DIV_	Divisor for A...	8886	6666	4448
OUTCOME		_DFT_	Total Degre...	4443	.	.

Rysunek 24- Statystyki dopasowania

Powyższe okno przedstawia statystyki dopasowania modelu dla trzech zbiorów: uczącego, walidacyjnego oraz testowego. Porównanie tych wartości pozwala ocenić, jak dobrze model radzi sobie z generalizacją poza danymi treningowymi. Znaczące różnice w wartościach statystyk mogą wskazywać na przetrenowanie (overfitting) lub niedotrenowanie (underfitting) modelu. W analizowanym przypadku odsetek błędnych klasyfikacji wynosi około 16,5% i jest najniższy dla zbioru testowego, co sugeruje stabilne i dobrze dopasowane rozwiązanie.



Rysunek 25 - Drzewo decyzyjne

Pierwszą zmienną, na podstawie której dokonano podziału, jest zmienna DRIVING_EXPERIENCE. Obserwacje zostały rozdzielone na dwie grupy: osoby z doświadczeniem mniejszym niż 9.5 roku oraz osoby z doświadczeniem równym lub większym niż 9.5 roku (lub brak danych). W przypadku węzła odpowiadającego doświadczeniu < 9.5, 62.94% przypadków z danych treningowych to klasa 0, a 37.06% to klasa 1. Dla zbioru walidacyjnego proporcje te są zbliżone i wynoszą odpowiednio 63.33% i 36.67%.

W kolejnych podziałach w tej gałęzi drzewa istotnymi zmiennymi były VEHICLE_YEAR, VEHICLE_OWNERSHIP oraz GENDER. Na przykład, dla pojazdów z rokiem produkcji < 2014.5 lub brak danych, zauważono, że osoby nieposiadające pojazdu (VEHICLE_OWNERSHIP = 0) mają aż 89.62% przypadków klasy 1 w danych treningowych oraz 90.05% w danych walidacyjnych.

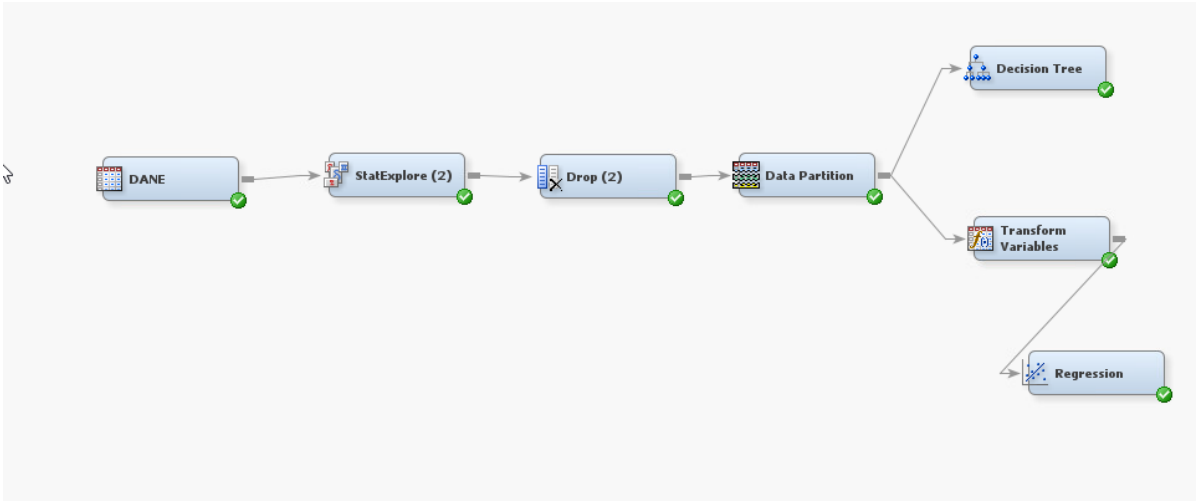
Z kolei w drugiej gałęzi, gdzie DRIVING_EXPERIENCE ≥ 9.5 lub brak danych, następny podział nastąpił względem zmiennej VEHICLE_OWNERSHIP. Osoby posiadające pojazd (VEHICLE_OWNERSHIP = 1 lub brak danych) miały bardzo wysoki odsetek klasy 0: 92.05% w danych treningowych oraz 92.16% w walidacyjnych.

Kolejne podziały w tej części drzewa wykorzystywały m.in. zmienne DRIVING_EXPERIENCE (z progiem 19.5 roku) i VEHICLE_YEAR. W jednym z końcowych węzłów, dla przypadków z dużym doświadczeniem (DRIVING_EXPERIENCE ≥ 19.5) i brakiem posiadania pojazdu (VEHICLE_OWNERSHIP = 0), aż 93.42% obserwacji w danych treningowych i 92.82% w walidacyjnych należało do klasy 0.

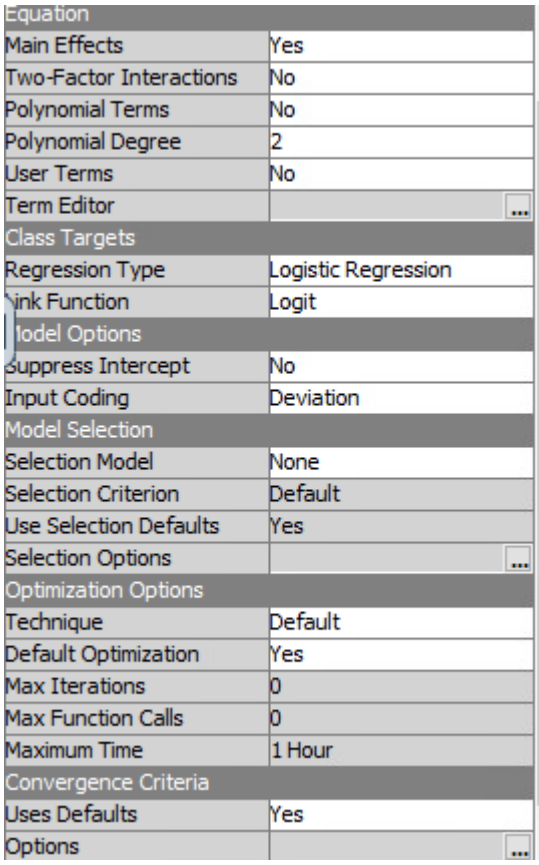
Wyniki na zbiorze walidacyjnym są w większości zbliżone do wyników uzyskanych na zbiorze treningowym, co świadczy o dobrej generalizacji modelu na nowych danych.

Regresja logistyczna

Dla regresji logistycznej został wprowadzony węzeł przekształcenia przez węzłem regresji logistycznej. Węzeł przekształcenia został użyty do stabilizacji wariancji, usunięcia nieliniowości, poprawy addytywności i dążeniu do normalności rozdkładu



Rysunek 26 - Węzeł regresji logistycznej

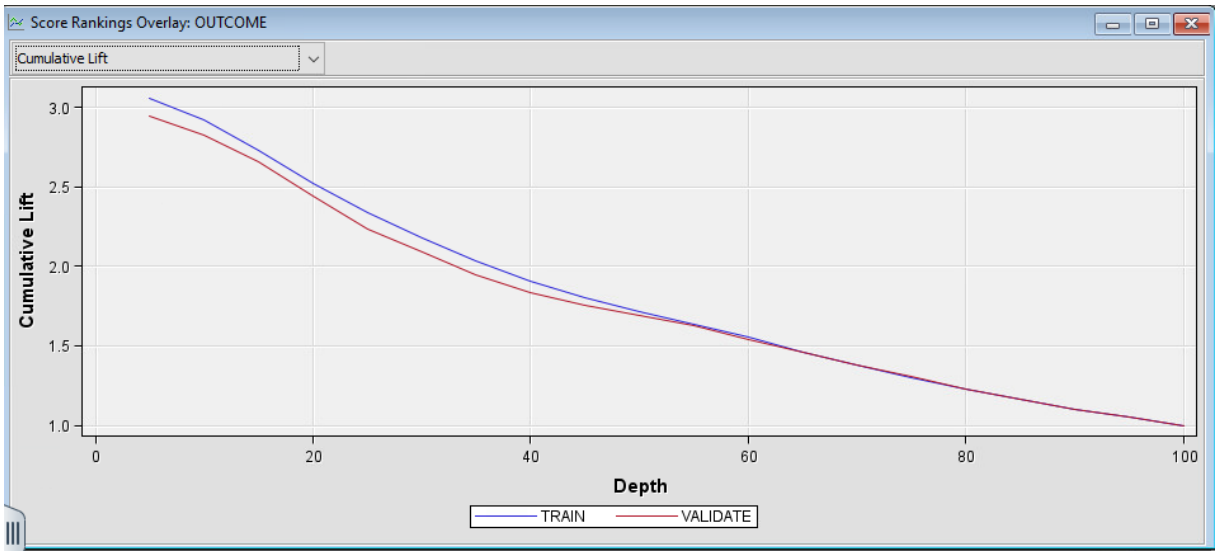


Equation	
Main Effects	Yes
Two-Factor Interactions	No
Polynomial Terms	No
Polynomial Degree	2
User Terms	No
Term Editor	...
Class Targets	
Regression Type	Logistic Regression
ink Function	Logit
lodel Options	
uppress Intercept	No
Input Coding	Deviation
Model Selection	
Selection Model	None
Selection Criterion	Default
Use Selection Defaults	Yes
Selection Options	...
Optimization Options	
Technique	Default
Default Optimization	Yes
Max Iterations	0
Max Function Calls	0
Maximum Time	1 Hour
Convergence Criteria	
Uses Defaults	Yes
Options	...

Rysunek 27 - Ustawienia do regresji logistycznej

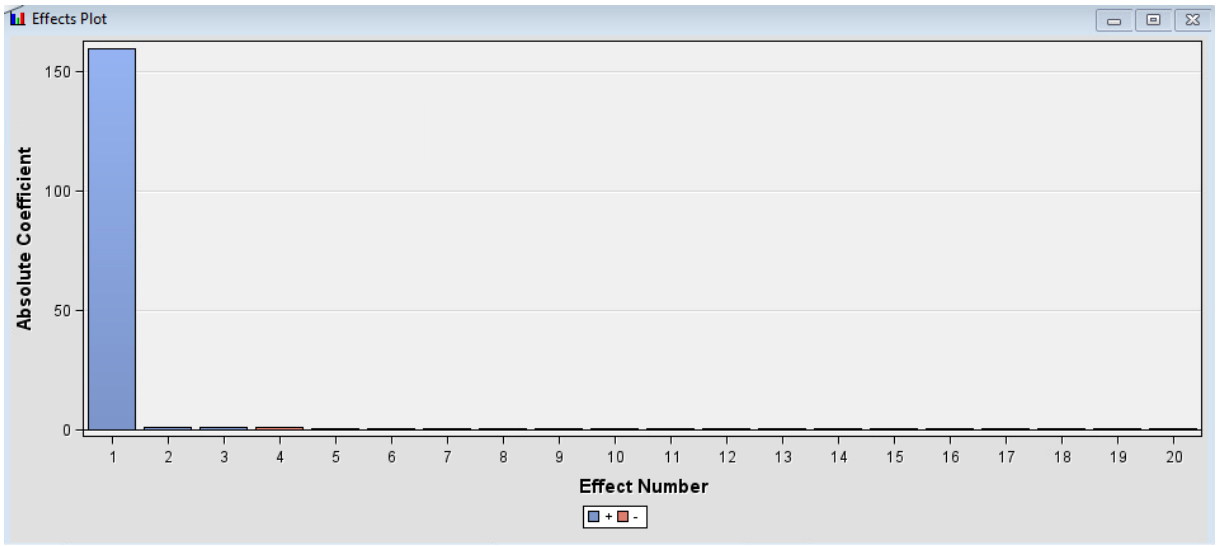
Zarówno w przypadku węzła odpowiedzialnego za przekształcenie zmiennych, jak i modelu regresji, pozostawiono domyślne ustawienia parametrów. Takie podejście pozwala ocenić działanie modelu w jego podstawowej konfiguracji, bez wpływu dodatkowej ingerencji użytkownika. W szczególności, dla modelu regresji zastosowano ustawienia domyślnie dostosowane do regresji logistycznej. Oznacza to, że algorytm automatycznie uwzględnił specyfikę tego typu analizy – m.in. zastosowanie funkcji logistycznej jako funkcji łącza, właściwe kodowanie zmiennych oraz sposób estymacji współczynników. Dzięki temu możliwe było prawidłowe przeprowadzenie klasyfikacji binarnej bez potrzeby ręcznej modyfikacji parametrów.

Rezultaty:



Rysunek 28 - Nakładka rankingów punktowych

Nakładka rankingów wyników punktowych na wykresie skumulowanego liftu wskazuje na wysoką zgodność między zbiorem treningowym a walidacyjnym. Linie dla obu zbiorów przebiegają w sposób zbliżony, co sugeruje, że model działa spójnie i przewiduje z podobną skutecznością na danych, których wcześniej nie widział. Taka zgodność oznacza dobre dopasowanie modelu i świadczy o jego zdolności do generalizacji. Gdyby krzywe znacząco się różniły, mogłoby to sugerować problem z przetrenowaniem lub niedotrenowaniem modelu. W analizowanym przypadku brak takiej rozbieżności potwierdza stabilność predykcji i poprawną konstrukcję modelu.



Rysunek 29 - Wykres efektów

W oknie wykresów efektów przedstawione są współczynniki regresji, uporządkowane według malejącej wartości bezwzględnej. Kolor czerwony oznacza współczynniki dodatnie, natomiast kolor niebieski – współczynniki ujemne.

Fit Statistics

Target	Target Label	Fit Statistics	Statistics Label	Train	Validation	Test
OUTCOME		_AIC_	Akaike's Inf...	3770.34	.	.
OUTCOME		_ASE_	Average Sq...	0.134783	0.141707	0.1481
OUTCOME		_AVERR_	Average Err...	0.4198	0.436811	0.448685
OUTCOME		_DFE_	Degrees of ...	4423	.	.
OUTCOME		_DFM_	Model Degr...	20	.	.
OUTCOME		_DFT_	Total Degre...	4443	.	.
OUTCOME		_DIV_	Divisor for A...	8886	6666	4448
OUTCOME		_ERR_	Error Functi...	3730.34	2911.779	1995.752
OUTCOME		_FPE_	Final Predic...	0.136002	.	.
OUTCOME		_MAX_	Maximum A...	0.998815	0.998502	0.994782
OUTCOME		_MSE_	Mean Squa...	0.135393	0.141707	0.1481
OUTCOME		_NOBS_	Sum of Fre...	4443	3333	2224
OUTCOME		_NW_	Number of ...	20	.	.
OUTCOME		_RASE_	Root Avera...	0.367129	0.37644	0.384838
OUTCOME		_RFPE_	Root Final ...	0.368785	.	.
OUTCOME		_RMSE_	Root Mean ...	0.367958	0.37644	0.384838
OUTCOME		_SBC_	Schwarz's ...	3898.322	.	.
OUTCOME		_SSE_	Sum of Squ...	1197.686	944.6199	658.75
OUTCOME		_SUMW_	Sum of Cas...	8886	6666	4448
OUTCOME		_MISC_	Misclassific...	0.197614	0.208521	0.214478

Rysunek 30 - Statystyki dopasowania

Okno wynikowe przedstawione na rysunku 30 zawiera podsumowanie statystyk dopasowania modelu dla trzech kluczowych zbiorów danych: uczącego, walidacyjnego oraz testowego. Analiza tych wskaźników pozwala na kompleksową ocenę skuteczności modelu oraz jego zdolności do prawidłowego generalizowania na nowych, niewidzianych wcześniej danych. Odsetek błędnych klasyfikacji jest bardzo zbliżony we wszystkich trzech zbiorach – wynosi około 20% dla zbioru uczącego, 21% dla walidacyjnego oraz 21,5% dla testowego. Tak niewielkie różnice świadczą o tym, że model został odpowiednio wytrenowany i nie wykazuje

symptomów ani przetrenowania, ani niedotrenowania. Spójność wyników na danych testowych potwierdza stabilność modelu i jego właściwe dopasowanie do problemu.

Analysis of Maximum Likelihood Estimates

Parameter		DF	Estimate	Standard Error	Wald Chi-Square	Pr > ChiSq	Standardized Estimate	Exp(Est)
Intercept		1	159.8	15.9959	99.86	<.0001		999.000
AGE		1	-0.00636	0.00359	3.14	0.0763	-0.0716	0.994
ANNUAL_MILEAGE		1	0.000022	0.000021	1.11	0.2921	0.0343	1.000
CHILDREN	0	1	0.0572	0.0566	1.02	0.3118		1.059
CREDIT_SCORE		1	0.8997	0.5239	2.95	0.0859	0.0690	2.459
DRIVING_EXPERIENCE		1	-0.1028	0.00906	128.85	<.0001	-0.6622	0.902
DUIS		1	-0.1220	0.1284	0.90	0.3421	-0.0366	0.885
EDUCATION	high school	1	0.0321	0.0657	0.24	0.6250		1.033
EDUCATION	none	1	-0.0502	0.0887	0.32	0.5715		0.951
GENDER	female	1	-0.5563	0.0519	114.89	<.0001		0.573
INCOME	middle class	1	-0.0948	0.0905	1.10	0.2953		0.910
INCOME	poverty	1	0.2758	0.1284	4.61	0.0317		1.318
INCOME	upper class	1	-0.2733	0.1311	4.34	0.0371		0.761
MARRIED	0	1	0.2143	0.0565	14.41	0.0001		1.239
PAST_ACCIDENTS		1	-0.4177	0.0605	47.60	<.0001	-0.3835	0.659
RACE	majority	1	0.1197	0.0789	2.30	0.1295		1.127
SPEEDING_VIOLATIONS		1	0.00225	0.0405	0.00	0.9558	0.00282	1.002
VEHICLE_OWNERSHIP	0	1	0.8876	0.0540	270.44	<.0001		2.429
VEHICLE_TYPE	sedan	1	0.0663	0.1195	0.31	0.5793		1.069
VEHICLE_YEAR		1	-0.0793	0.00796	99.32	<.0001	-0.2894	0.924

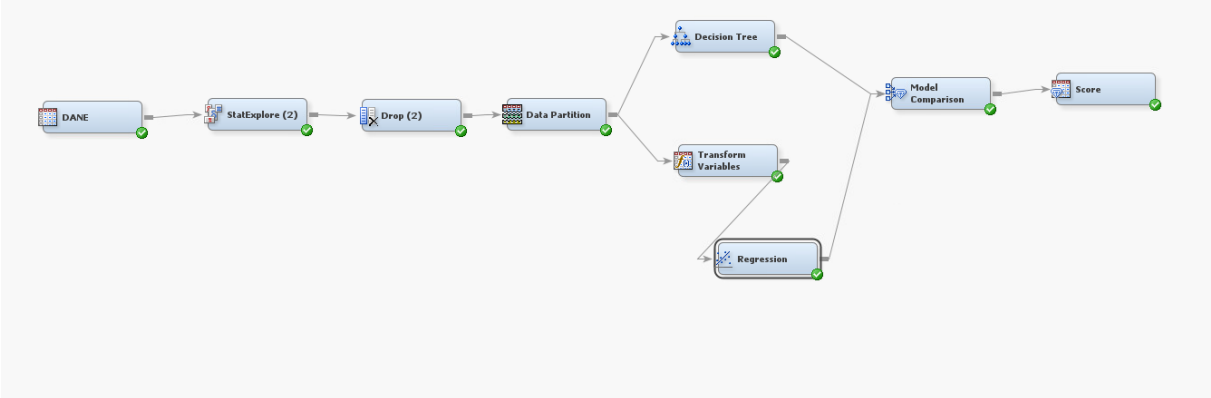
Rysunek 31 Analiza ocen maksymalnej wiarygodności

W oknie wynikowym można odczytać szereg istotnych informacji statystycznych dotyczących modelu. Do najważniejszych należą: oceny parametrów (współczynniki), błędy standardowe, statystyka Walda, poziomy istotności (wartości p) oraz – w przypadku zmiennych ciągłych – również oceny standaryzowane. Przykładowo, dla zmiennej **Intercept** (wyraz wolny) błąd standardowy wynosi **15,9959**, co oznacza, że oszacowanie tego parametru może się w przybliżeniu zmieniać o tę wartość. Wartość błędu standardowego informuje o precyzji estymacji parametru – im mniejszy błąd, tym dokładniejszy szacunek. Dodatkowo, dla tej samej zmiennej (Intercept) zaprezentowano wartość statystyki chi-kwadrat Walda oraz odpowiadającą jej wartość p. Statystyka Walda służy do oceny istotności danego parametru w modelu – w tym przypadku testuje się hipotezę zerową mówiącą, że współczynnik Intercept jest równy zero. Wartość p pozwala na ocenę istotności zmiennej w modelu – jeśli jest wystarczająco niska (np. mniejsza niż przyjęty poziom istotności, zwykle 0,05), to możemy uznać, że zmienna **Intercept** jest statystycznie istotna i ma wpływ na zmienną objaśnianą.

Porównanie Modelu

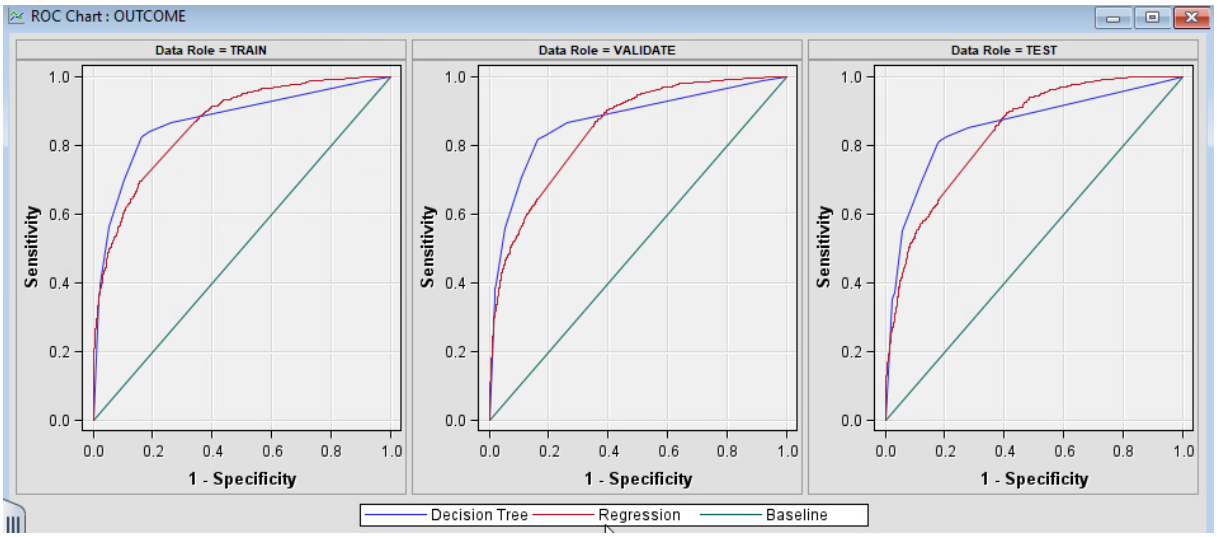
Ostatnim etapem analizy jest porównanie utworzonych modeli pod kątem ich skuteczności i jakości predykcji. W tym celu do diagramu zostały dodane węzły odpowiedzialne za porównywanie modeli oraz obliczanie wyniku punktowego. Parametry obu tych węzłów

zostały pozostawione na ustawieniach domyślnych.



Rysunek 32 - Węzeł porównanie modeli i wynik punktowy

Rezultaty:

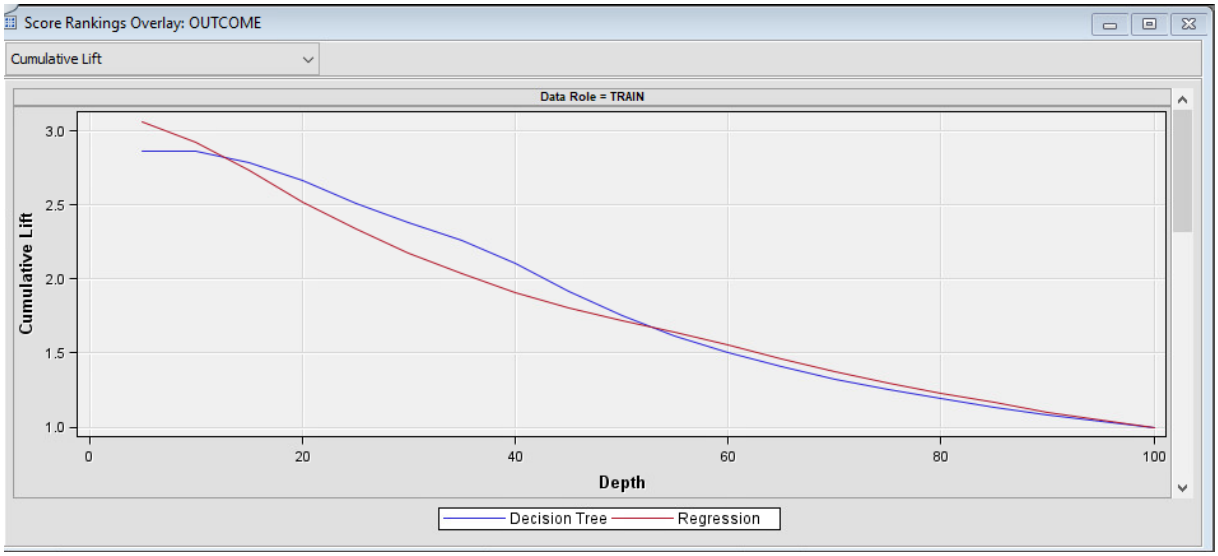


Rysunek 33 - Wykres ROC

Na podstawie analizy krzywej ROC dla obu modeli można stwierdzić, że ich dokładność wynosi około 0,90, co jest uznawane za bardzo dobry wynik. Regresja logistyczna wypada

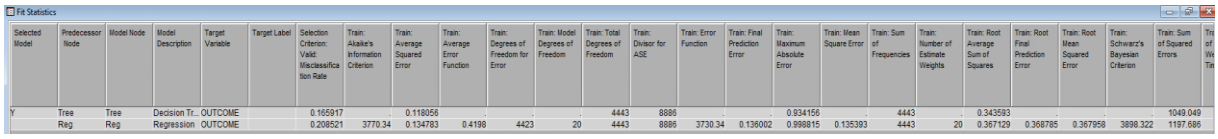
nieco lepiej – jej krzywa (oznaczona czerwoną linią) jest bardziej przesunięta w kierunku lewego górnego rogu wykresu, co świadczy o wyższej czułości i specyficzności modelu.

Na wykresie znajduje się również linia diagonalna, która reprezentuje model bazowy działający na poziomie losowego przypisania klas. Odległość krzywych modeli od tej linii pozwala ocenić przewagę predykcyjną obu podejść.



Rysunek 34 - Nakładka rankingów wyników punktowych

Analiza porównawcza krzywych wzrostu wskazuje, że model regresji logistycznej wypada nieco lepiej niż drzewo decyzyjne. Świadczy o tym fakt, że linia czerwona, reprezentująca regresję logistyczną, znajduje się nieco powyżej linii niebieskiej, która odpowiada drzewu decyzyjnemu, zwłaszcza dla wartości początkowych i środkowych na wykresie. Taki układ krzywych sugeruje, że regresja logistyczna oferuje lepszą skuteczność klasyfikacji w tych zakresach.



Rysunek 35 - Statystyki dopasowania

Valid: Gain	Train: Lift	Train: Cumulative Lift	Valid: Lift	Valid: Cumulative Lift	Train: Percent Response	Train: Cumulative Percent Response	Valid: Percent Response	Valid: Cumulative Percent Response	Train: Percent Captured Response	Train: Cumulative Percent Captured Response	Valid: Percent Captured Response	V C P C R
187.4826	2.86042	2.86042	2.874826	2.874826	89.61749	89.61749	90.04854	90.04854	14.29244	28.64927	14.40432	
182.9307	2.774862	2.919251	2.714605	2.829307	86.93694	91.46067	85.02994	88.62275	13.86494	29.23851	13.60153	

Rysunek 36 - Statystyki dopasowania

Walidacja odsetek błędnych klasyfikacji dla drzewa decyzyjnego wynosił 0.165917, a dla regresji logistycznej 0.208521. Możemy powiedzieć ,że drzewo decyzyjne wykonuje o 4,25% lepsze dopasowania niż regresja logistyczna.

Statistics	Tree	Reg
Train: Bin-Based Two-Way Kolmogorov-Smirnov Probability Cutoff	0.49	0.34
Train: Kolmogorov-Smirnov Statistic	0.66	0.54
Train: Akaike's Information Criterion	.	3770.34
Train: Average Squared Error	0.12	0.13
Train: Roc Index	0.87	0.86
Train: Average Error Function	.	0.42
Train: Cumulative Percent Captured Response	28.65	29.24
Train: Percent Captured Response	14.29	13.86
Selection Criterion: Valid: Misclassification Rate	0.17	0.21
Train: Degrees of Freedom for Error	.	4423.00
Train: Model Degrees of Freedom	.	20.00
Train: Total Degrees of Freedom	4443.00	4443.00
Train: Divisor for ASE	8886.00	8886.00
Train: Error Function	.	3730.34
Train: Final Prediction Error	.	0.14
Train: Gain	186.04	191.93
Train: Gini Coefficient	0.74	0.72
Train: Bin-Based Two-Way Kolmogorov-Smirnov Statistic	0.64	0.53
Train: Kolmogorov-Smirnov Probability Cutoff	0.21	0.33
Train: Cumulative Lift	2.86	2.92
Train: Lift	2.86	2.77
Train: Maximum Absolute Error	0.93	1.00
Train: Misclassification Rate	0.17	0.20
Train: Mean Square Error	.	0.14
Train: Sum of Frequencies	4443.00	4443.00
Train: Number of Estimate Weights	.	20.00
Train: Root Average Sum of Squares	0.34	0.37
Train: Cumulative Percent Response	89.62	91.46
Train: Percent Response	89.62	86.94
Train: Root Final Prediction Error	.	0.37
Train: Root Mean Squared Error	.	0.37
Train: Schwarz's Bayesian Criterion	.	3898.32
Train: Sum of Squared Errors	1049.05	1197.69
Train: Sum of Case Weights Times Freq	.	8886.00

Rysunek 37 - Tabela dopasowania statystyk dla zbioru treningowego

Statistics	Tree	Reg
Valid: Kolmogorov-Smirnov Statistic	0.65	0.51
Valid: Average Squared Error	0.12	0.14
Valid: Roc Index	0.87	0.85
Valid: Average Error Function	.	0.44
Valid: Bin-Based Two-Way Kolmogorov-Smirnov Probability Cutoff	0.49	0.32
Valid: Cumulative Percent Captured Response	28.81	28.35
Valid: Percent Captured Response	14.40	13.60
Valid: Divisor for VASE	6666.00	6666.00
Valid: Error Function	.	2911.78
Valid: Gain	187.48	182.93
Valid: Gini Coefficient	0.73	0.69
Valid: Bin-Based Two-Way Kolmogorov-Smirnov Statistic	0.64	0.50
Valid: Kolmogorov-Smirnov Probability Cutoff	0.21	0.31
Valid: Cumulative Lift	2.87	2.83
Valid: Lift	2.87	2.71
Valid: Maximum Absolute Error	0.93	1.00
Valid: Misclassification Rate	0.17	0.21
Valid: Mean Square Error	.	0.14
Valid: Sum of Frequencies	3333.00	3333.00
Valid: Root Average Squared Error	0.35	0.38
Valid: Cumulative Percent Response	90.05	88.62
Valid: Percent Response	90.05	85.03
Valid: Root Mean Square Error	.	0.38
Valid: Sum of Square Errors	797.66	944.62
Valid: Sum of Case Weights Times Freq	.	6666.00

Rysunek 38 - Tabela dopasowania statystyk dla zbioru walidacyjnego

Statistics	Tree	Reg
Test: Kolmogorov-Smirnov Statistic	0.63	0.49
Test: Average Squared Error	0.13	0.15
Test: Roc Index	0.85	0.83
Test: Average Error Function	.	0.45
Test: Bin-Based Two-Way Kolmogorov-Smirnov Probability Cutoff	0.35	0.29
Test: Cumulative Percent Captured Response	28.07	26.69
Test: Percent Captured Response	13.97	12.05
Test: Divisor for TASE	4448.00	4448.00
Test: Error Function	.	1995.75
Test: Gain	179.92	166.14
Test: Gini Coefficient	0.70	0.67
Test: Bin-Based Two-Way Kolmogorov-Smirnov Statistic	0.62	0.48
Test: Kolmogorov-Smirnov Probability Cutoff	0.21	0.27
Test: Cumulative Lift	2.80	2.66
Test: Lift	2.80	2.41
Test: Maximum Absolute Error	0.93	0.99
Test: Misclassification Rate	0.18	0.21
Test: Lower 95% Conf. Limit for TMISC	.	0.20
Test: Upper 95% Conf. Limit for TMISC	.	0.23
Test: Mean Square Error	.	0.15
Test: Sum of Frequencies	2224.00	2224.00
Test: Root Average Squared Error	0.36	0.38
Test: Cumulative Percent Response	87.73	83.41
Test: Percent Response	87.73	75.68
Test: Root Mean Square Error	.	0.38
Test: Sum of Square Errors	563.93	658.75
Test: Sum of Case Weights Times Freq	4448.00	4448.00

Rysunek 39 - Tabela statystyk dla zbioru testowego

	Drzewo decyzyjne	Regresja logistyczna
Rola danych: Valid		
Statystyka Kołmogorowa-smirnowa	0,65	0,51
Indeks ROC	0,87	0,85
Współczynnik Giniego	0,73	0,69
Średni błąd kwadratowy	.	0,14
Rola danych: Test		
Statystyka Kołmogorowa smirnowa	0,63	0,49
Indeks ROC	0,85	0,83
Współczynnik Giniego	0,70	0,67

Średni błąd kwadratowy	.	0,15

-Statystyka Kołmogorowa-Smirnowa – liczy zgodność empiryczną rozkładu z teoretycznym normalnym – im wyższy tym lepszy;

-Indeks ROC – najwyższa wartość, ocenia jakość dopasowania modelu

-Współczynnik Giniego – miara koncentracji (nierównomierności) rozkładu zmiennej losowej

-Średni błąd kwadratowy – ocena błędu prognozy ex-post, im mniejszy tym lepszy

W oparciu o powyższe wskaźniki można stwierdzić, że regresja liniowa i drzewo decyzyjne mają dobrą wydajność. Jednak regresja liniowa jest nieco lepsza niż drzewo decyzyjne.

Podsumowanie

Celem niniejszej pracy była analiza danych w kontekście doboru odpowiedniego modelu służącego do przewidywania, którym klientom zostanie przyznane odszkodowanie.

Na początku dane zostały zaimportowane do tabeli w środowisku SAS, a następnie dodane jako źródło danych w ramach projektu analitycznego. Przed przystąpieniem do właściwego modelowania przeprowadzono wstępną eksplorację danych w celu ich lepszego zrozumienia.

Kolejnym krokiem było oczyszczenie zbioru danych z brakujących wartości, przygotowanie ich do analizy, usunięcie zmiennych nieistotnych dla dalszych etapów oraz podział danych na zbiory uczący, walidacyjny i testowy.

Następnie utworzono modele predykcyjne z wykorzystaniem drzewa decyzyjnego oraz regresji logistycznej. W końcowej fazie porównano skuteczność obu podejść.

Z przeprowadzonej analizy wynika, że regresja logistyczna lepiej dopasowuje się do charakterystyki danych w kontekście prognozowania. Niemniej jednak, oba modele osiągnęły niezadowalające wyniki. Może to być spowodowane ograniczoną liczebnością próby, co przełożyło się na niewystarczającą ilość danych treningowych dla algorytmu. W związku z tym, przed rozpoczęciem rzeczywistego procesu prognozowania, wskazane byłoby zebranie większego zbioru danych oraz ponowne opracowanie modeli.