ANALIZA NAJCZEŚCIEJ ODWTWARZANYCH UTWORÓW NA PLATFORMACH STREAMINGOWYCH



Tobiasz Mazur

UE KATOWICE

Spis treści

Wprowadzenie do problematyki 2

Prezentacja danych źródłowych 3

Analiza nr. 1— Analiza roku wydania najbardziej trendujacych utworów 5

Analiza nr. 2— Analiza tempa utworów w kontekście ich popularności 10

Analiza nr. 3— Analiza tonacji utworów w kontekście daty ich wydania pośród najpopularniejszych 14

Analiza nr. 4— Analiza artystów najczęściej występujących na playlistach Spotify oraz Apple music. 18

Analiza nr. 5— Analiza wpływu energiczności piosenek na ich taneczność 23

Podsumowanie analiz 26

Wprowadzenie do problematyki

Muzyka jest istotnym elementem naszego życia codziennego i kultury współczesnej. Towarzyszy nam w różnych momentach życia, oddziałując na nasze emocje, wspomnienia oraz poczucie estetyki. Dzięki platformom streamingowym, takim jak Spotify , apple music mamy możliwość łatwego dostępu do milionów utworów z całego świata, co przyczynia się do zmiany sposobu konsumpcji muzyki i kształtowania trendów w branży muzycznej.

Przeprowadzona analiza danych dotyczy najczęściej odtwarzanych utworów na Spotify. Celem badania jest zrozumienie dynamiki popularności utworów, identyfikacja kluczowych cech wpływających na ich sukces oraz określenie, jakie trendy dominują w preferencjach słuchaczy na przestrzeni czasu. Dzięki analizie tych danych możemy uzyskać cenne informacje na temat:

Dominujących gatunków muzycznych wśród najczęściej odtwarzanych utworów, Popularności artystów i ich wkładu w kulturę muzyczną, Zmian trendów muzycznych w czasie, Wpływu współczesnych technologii na sposób, w jaki ludzie konsumują muzykę. Analiza będzie podzielona na następujące cele szczegółowe.

Cele szczegółowe:

1. Analiza roku wydania najbardziej trendujacych utworów

2. Analiza tępa utworu w kontekście jego popularności

3. Analiza tonacji utworów w kontekście daty ich wydania.

4. Analiza ilości najbardziej tanecznych utworów w trendujacych

5. Analiza wpływu energiczności piosenek na ich taneczność

W celu zapewnienia przejrzystości, dane i wyniki zostaną przedstawione za pomocą tabel, wykresów oraz interpretacji. Każdy etap analizy zostanie szczegółowo opisany, by uzyskać kompleksowy obraz obecnych trendów muzycznych. Na końcu przedstawione zostaną wnioski, które mogą służyć jako podstawa do dalszych badań lub zastosowań praktycznych w branży muzycznej i marketingu.

Prezentacja danych źródłowych

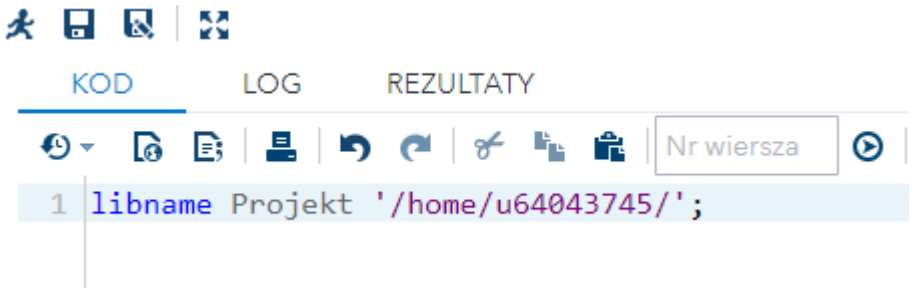
Dane obejmują utwory z lat od 1930-2023 Dane, wykorzystane w niniejszej pracy, pochodzą ze stronny https://www.kaggle.com/ gdzie są dostępne jako bezpłatny plik w formacie .csv (comma-seperated-values) . Plik w formacie .csv został dostarczony w ramach analizy zawierającej szczegółowe dane dotyczące utworów muzycznych, które osiągnęły największą popularność na platformach streamujących muzykę.

Dane obejmują okres do 2023 roku, a zawarte informacje pozwalają na analizę zarówno historycznych, jak i bieżących trendów związanych z muzyką cyfrową. Zawarte są m.in. dane o artystach, liczbie streamów, dostępności utworów na różnych platformach muzycznych (Spotify, Apple Music, Deezer) oraz szczegółowe metryki opisujące właściwości muzyczne poszczególnych utworów (takie jak tempo, tonacja, energia, taneczność).

Dane zostały podzielone na różne kategorie, m.in.:

- Charakterystyka utworów (np. energie , bpm).
- Popularność na platformach streamingowych (liczba streamów, obecność na playlistach i listach przebojów).
- Informacje o artystach (liczba współpracy, nazwa wykonawcy).

Przed rozpoczęciem analiz w systemie SAS tworzymy bibliotekę o nazwie Projekt, żeby zaimportować tam swoje dane za pomocą poniższego kodu.



Kod 1 – Utworzenie biblioteki projekt

W kolejnym kroku zaimportowałem baze w formacie .csv do biblioteki Projekt . W celu importu danych zastosowałem kod 2 .

KOD LOG REZULTATY DANE WYNIKOWE

Nr wiersza

```
1  libname Projekt '/home/u64043745/';
2
3  PROC IMPORT OUT= projekt
4      FILE= "/home/u64043745/student/CSV/Spotify Most Streamed Songs.csv"
5      DBMS=CSV
6      REPLACE;
7      GETNAMES=YES;
8  RUN;
```

Kod 2 -Import danych do biblioteki Projekt

KOD LOG REZULTATY DANE WYNIKOWE

Tabela: WORK.PROJEKT | Wyświetlanie: Nazwy kolumn | Filtr: (brak)

Kolumny

- Wybierz wszystko
- track_name
- artist(s)_name
- artist_count
- released_year
- released_month
- released_day
- in_spotify_playlists
- in_spotify_charts
- streams
- in_apple_playlists
- in_apple_charts
- in_deezer_playlists
- in_deezer_charts
- in_shazam_charts

Właściwość	Wartość
Etykieta	
Nazwa	
Długość	
Typ	
Format	
Informat	

Wierszy razem: 953 Kolumn razem: 25 Wiersze 1-100

	track_name	artist(s)_name	artist_count
1	Seven (feat. Latto) (Explicit Ver.)	Latto, Jung Kook	2
2	LALA	Myke Towers	1
3	vampire	Olivia Rodrigo	1
4	Cruel Summer	Taylor Swift	1
5	WHERE SHE GOES	Bad Bunny	1
6	Sprinter	Dave, Central Cee	2
7	Ella Baila Sola	Eslabon Armado, Peso Pluma	2
8	Columbia	Quevedo	1
9	fukumean	Gunna	1
10	La Bebe - Remix	Peso Pluma, Yng Lvcas	2
11	un x100to	Bad Bunny, Grupo Frontera	2
12	Super Shy	NewJeans	1
13	Flowers	Miley Cyrus	1
14	Daylight	David Kushner	1
15	As It Was	Harry Styles	1
16	Kill Bill	SZA	1
17	Cupid - Twin Ver.	Fifty Fifty	1
18	What Was I Made For? [From The Motion Picture "Barbie"]	Billie Eilish	1
19	Classy 101	Feid, Young Miko	2
20	Like Crazy	Jimin	1
21	LADY GAGA	Gabito Ballesteros, Junior H	3
22	I Can See You (Taylorï¿½ï¿½s Version) (From The	Taylor Swift	1
23	I Wanna Be Yours	Arctic Monkeys	1
24	Peso Pluma: Bzrp Music Sessions, Vol. 55	Bizarrap, Peso Pluma	2

Tabela 1 – Zaimportowane dane

Analiza nr. 1— Analiza roku wydania najbardziej trendujacych utworów

1.Wyjaśnienie celu szczegółowego

Celem szczegółowym analizy roku wydania najbardziej trendujących utworów jest zidentyfikowanie, które lata są najbardziej reprezentowane w zestawieniu popularnych piosenek. Analiza ta pozwala zrozumieć, czy istnieje preferencja słuchaczy względem nowszych utworów, czy może starsze piosenki również utrzymują swoją popularność. Ponadto, pozwala to na ocenę wpływu roku wydania na liczbę odtworzeń, co może być przydatne dla strategii marketingowych w branży muzycznej oraz przewidywania trendów w przyszłości.

2. Opis procesu uzyskania danych wynikowych

Pierwszą czynnością jest utworzenie tabeli z interesującymi nas kolumnami (w moim przypadku są to : „released_year” , „streams” oraz „track_name”), które musimy połączyć żeby rozpocząć analizę.

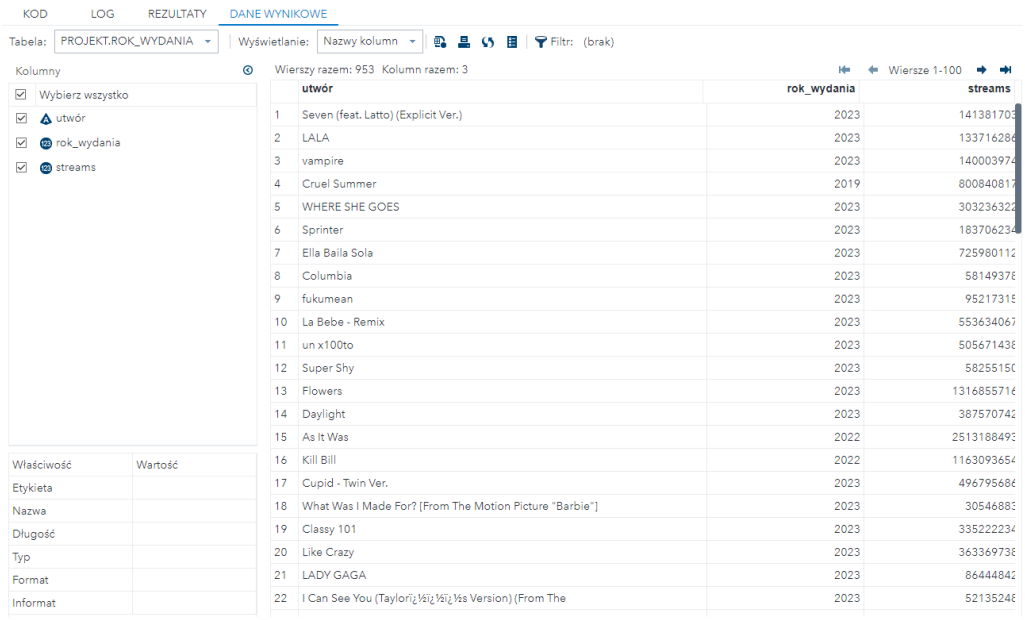
KOD LOG REZULTATY DANE WYNIKOWE

Nr wiersza

```
1  PROC SQL;
2  CREATE TABLE PROJEKT.rok_wydania AS
3  SELECT track_name as utwór ,released_year as rok_wydania,streams FROM PROJEKT.PROJEKT;
4  RUN;
5  QUIT;
6
7  PROC DATASETS NOLIST NODETAILS;
8  CONTENTS DATA=WORK.query OUT=WORK.details;
9  RUN;
10
11 PROC PRINT DATA=WORK.details;
12 RUN;
```

Kod 3 – Utworzenie tabeli do analizy 1

Jako dane wynikowe otrzymujemy tabele z trzema kolumnami.



KOD LOG REZULTATY DANE WYNIKOWE

Tabela: PROJEKT.ROK_WYDANIA | Wyświetlanie: Nazwy kolumn | Filtr: (brak)

Kolumny

Wybierz wszystko
utwór
rok_wydania
streams

Wiersze razem: 953 Kolumn razem: 3 Wiersze 1-100

	utwór	rok_wydania	streams
1	Seven (feat. Latto) (Explicit Ver.)	2023	141381703
2	LALA	2023	133716286
3	vampire	2023	140003974
4	Cruel Summer	2019	800840817
5	WHERE SHE GOES	2023	303236322
6	Sprinter	2023	183706234
7	Ella Baila Sola	2023	725980112
8	Columbia	2023	58149378
9	fukumean	2023	95217315
10	La Bebe - Remix	2023	553634067
11	un x100to	2023	505671438
12	Super Shy	2023	58255150
13	Flowers	2023	1316855716
14	Daylight	2023	387570742
15	As It Was	2022	2513188493
16	Kill Bill	2022	1163093654
17	Cupid - Twin Ver.	2023	496795686
18	What Was I Made For? [From The Motion Picture "Barbie"]	2023	30546883
19	Classy 101	2023	335222234
20	Like Crazy	2023	363369738
21	LADY GAGA	2023	86444842
22	I Can See You (Taylor¿½ï¿½ï¿½s Version) (From The	2023	52135248

Właściwość	Wartość
Etykieta	
Nazwa	
Długość	
Typ	
Format	
Informat	

Tabela 2 - Dane wejściowe do analizy 1

Kolejno przystępując do zbadania siły zależności, musimy odpowiedzieć na pytanie, czy pomiędzy analizowanymi zmiennymi istnieje zależność przyczynowo skutkowa. W tym celu postanowiłem użyć współczynnik korelacji Pearsona pozwalający szybką ocenę siły i kierunku zależności.

```
proc corr data=PROJEKT.rok_wydania pearson spearman;
    var rok_wydania streams;
    title 'Korelacja między rokiem wydania a liczbą odtworzeń';
run;
```

Kod 4 – Obliczenie korelacji między rokiem wydania a liczbą odtworzeń

```
proc sgplot data=PROJEKT.rok_wydania;
   scatter x=rok_wydania y=streams/
      markerattrs=(symbol=circlefilled color=blue size=8)
      transparency=0.5;

   xaxis label="rok_wydania" grid;
   yaxis label="streams" grid;

   title "Wykres Rozrzutu Zmiennych X i Y";
run;
```

Kod 5 - Wykres Scatter plot

W efekcie powyższych kodów otrzymaliśmy obliczone dane oraz mapę rozrzutu pomagającą interpretować dane korelacji Pearsona:

Korelacja między rokiem wydania a liczbą odtworzeń

Procedura CORR

2 Zmienne:	rok_wydania streams

Statystyki proste

Zmienna	N	Średnia	Odch. std.	Mediana	Minimum	Maksimum
rok_wydania	953	2018	11.11622	2022	1930	2023
streams	952	514137425	566856949	290530915	2762	3703895074

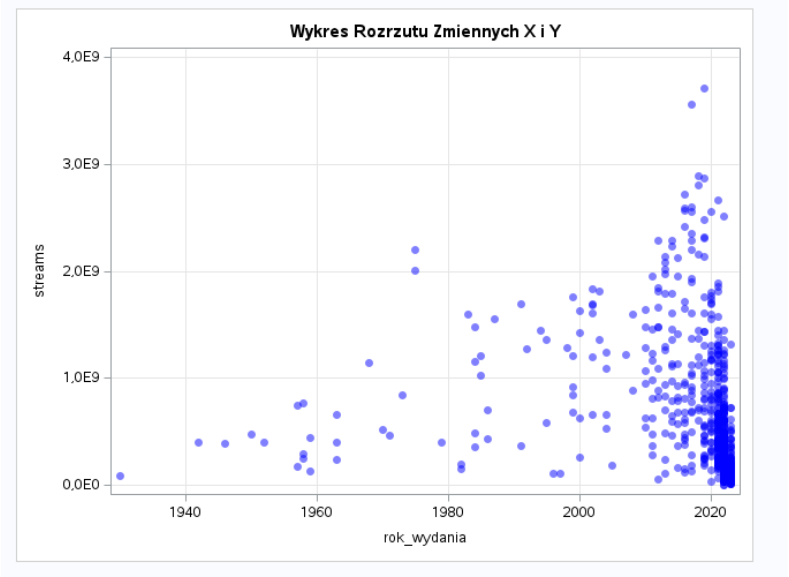
Współczynniki korelacji Pearsona
Prawd. > |r| przy H0: rho=0
Liczba obserwacji

	rok_wydania	streams
rok_wydania	1.00000 953	-0.23080 <.0001 952
streams	-0.23080 <.0001 952	1.00000 952

Współczynniki korelacji Spearmana
Prawd. > |r| przy H0: rho=0
Liczba obserwacji

	rok_wydania	streams
rok_wydania	1.00000 953	-0.68152 <.0001 952
streams	-0.68152 <.0001 952	1.00000 952

Rezultat - Wynik zapytania dotyczącego korelacji Pearsona i Spearmana.

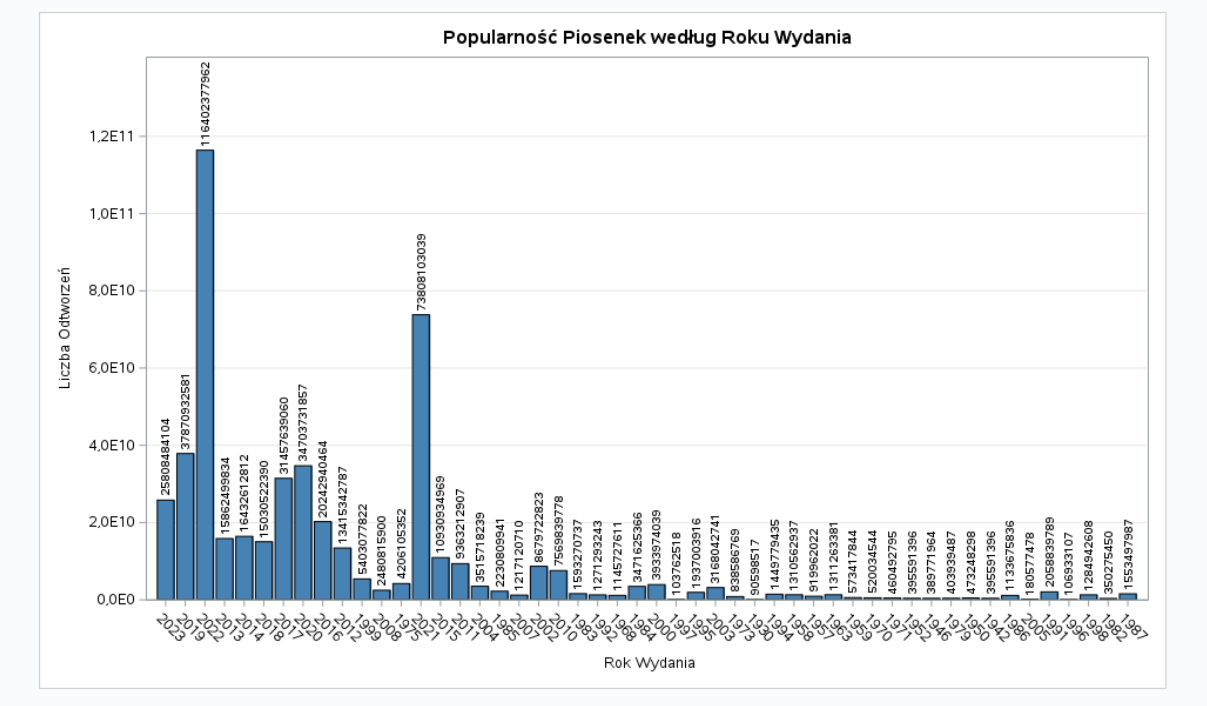


Wykres 1 - Rozrzut korelacji Pearsona

W celu zobrazowania sobie roku ,który dominuje pod względem utworów o największej popularności postanowiłem wygenerować wykres słupkowy przedstawiony na wykresie 2

```
ods graphics / height=6in width=10in;
proc sgplot data=PROJEKT.rok_wydania;
    vbar rok_wydania / response=streams stat=sum datalabel fillattrs=(color=steelblue);
    xaxis label='Rok Wydania' discreteorder=data;
    yaxis label='Liczba Odtworzeń' grid;
    title 'Popularność Piosenek według Roku Wydania';
run;
ods graphics / reset;
```

Kod 6 - Wykres słupkowy



Wykres 2 – Popularność piosenek według roku ich wydania

3.Wnioski z przeprowadzonej analizy

Podsumowując , Analiza pokazuje, że starsze utwory mają przewagę w liczbie odtworzeń w porównaniu z nowszymi, co jest szczególnie widoczne w silnej korelacji rangowej (Spearmana). Może to być związane z tym, że starsze utwory mają dłuższą historię odbioru, zdążyły zyskać status kultowych hitów, lub są przedmiotem nostalgii. Dodatkowo, wiele starszych utworów może być częścią playlist tematycznych, co również zwiększa ich odtworzenia.

Jednocześnie warto zauważyć, że różnica w wynikach współczynników korelacji (Pearsona i Spearmana) sugeruje, że relacja między rokiem wydania a liczbą odtworzeń nie jest liniowa. Chociaż starsze utwory mają więcej odtworzeń, istnieje duże zróżnicowanie wyników, co wskazuje na wpływ innych czynników (np. trendów muzycznych, promocji, czy obecności utworów w kulturze masowej).

Podsumowując, starsze utwory, zwłaszcza te wydane przed 2000 rokiem, są wyraźnie bardziej popularne w streamingu, co może świadczyć o ich ponadczasowej wartości i ich miejscu w kanonie muzyki popularnej. Nowsze utwory, choć często obecne w większej liczbie, mają trudności z dorównaniem klasykom pod względem liczby odtworzeń.

Analiza nr. 2— Analiza tempa utworów w kontekście ich popularności

1.Wyjaśnienie celu szczegółowego

Celem szczegółowym analizy jest zbadanie, jak tempo utworu (mierzone w BPM – Beats Per Minute) wpływa na jego popularność. Popularność może być mierzona na podstawie liczby odtworzeń, ocen użytkowników lub innych wskaźników. Analiza ma na celu odpowiedź na takie pytania jak: Czy istnieje związek między tempem utworu a jego popularnością? Czy utwory o szybkim tempie są bardziej popularne niż te o wolniejszym? Czy istnieją optymalne zakresy tempa (np. ballady vs. energiczne hity)?

2. Opis procesu uzyskania danych wynikowych

Podobnie jak poprzednio jako pierwsze przygotowujemy tabele z interesującymi nas danymi (w tym przypadku użyjemy kolumny streams ,track_name oraz bpm) pomoże nam w tym poniższy kod.

```
PROC SQL ;
CREATE TABLE PROJEKT.tepo as
SELECT track_name as utwór , streams ,bpm from PROJEKT.PROJEKT;
RUN;
QUIT;

PROC DATASETS NOLIST NODETAILS;
CONTENTS DATA= WORK.query OUT= WORK.details;
RUN;

PROC PRINT DATA=WORK.details;
Run;
```

Kod 7 – Utworzenie tabeli do analizy 2

Dane przedstawiają się następująco.

KOD | LOG | REZULTATY | DANE WYNIKOWE

Tabela: PROJEKT.TEPO | Wyświetlanie: Nazwy kolumn | Filtr: (brak)

Kolumny: Wybierz wszystko; utwór; streams; bpm

Wierszy razem: 953 Kolumn razem: 3 | Wiersze 1-100

	utwór	streams	bpm
1	Seven (feat. Latto) (Explicit Ver.)	141381703	125
2	LALA	133716286	92
3	vampire	140003974	138
4	Cruel Summer	800840817	170
5	WHERE SHE GOES	303236322	144
6	Sprinter	183706234	141
7	Ella Baila Sola	725980112	148
8	Columbia	58149378	100
9	fukumean	95217315	130
10	La Bebe - Remix	553634067	170
11	un x100to	505671438	83
12	Super Shy	58255150	150
13	Flowers	1316855716	118
14	Daylight	387570742	130
15	As It Was	2513188493	174
16	Kill Bill	1163093654	89
17	Cupid - Twin Ver.	496795686	120
18	What Was I Made For? [From The Motion Picture "Barbie"]	30546883	78
19	Classy 101	335222234	100
20	Like Crazy	363369738	120

Właściwość | Wartość

Etykieta | Nazwa | Długość | Typ

Tabela 3 – Dane wejściowe do analizy 2

Kolejno będziemy obliczać średnią oraz medianę w grupach o różnej popularności.

```
PROC SQL;
    SELECT
        CASE
            WHEN streams < 40 THEN 'mało'
            WHEN streams BETWEEN 40 AND 70 THEN 'średnio'
            ELSE 'dużo'
        END AS streams_Group,
        AVG(BPM) AS srednie_Tempo,
        MEDIAN(BPM) AS mediana_Tempo,
        COUNT(*) AS wszystkie_Piosenki
    FROM PROJEKT.tepo
    GROUP BY streams_Group;
QUIT;
```

Kod 8 - Obliczanie średniej i mediany

W wyniku kodu otrzymujemy taki rezultat.

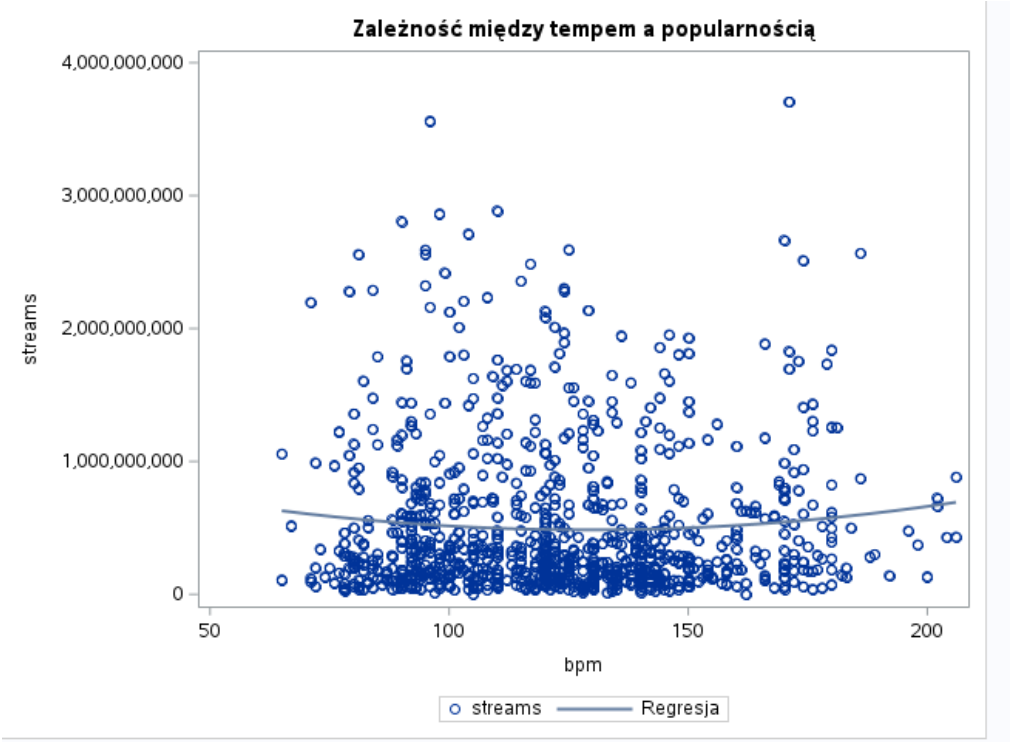
streams_Group	srednie_Tempo	mediana_Tempo	wszystkie_Piosenki
dużo	122.5536	121	952
mało	110	110	1

Rezultat 2 – Średnia oraz mediana

W celu lepszej interpretacji korelacji popularności z tempem wykorzystamy wykres rozrzutu z regresją „scatter plot” , który pokaże zależność między tempem (BPM) a popularnością, jednocześnie uwzględniając linię trendu. Podczas pisania kodu zmieniłem przedstawianie wartości streams ponieważ system SAS uwzględni nam duże liczby przykładowo, jako 4,0E9.

```
PROC SGPLOT DATA=PROJEKT.tempo;
    SCATTER X=BPM Y=streams;
    FORMAT Streams COMMA15.;
    REG X=BPM Y=streams / DEGREE=2;
    TITLE "Zależność między tempem a popularnością";
RUN;
```

Kod 9 - Wykres Scatter plot



Wykres 3 – Zależność między tempem ,a popularnością

Jeszcze przed wystawieniem wniosków grupuje streamy na trzy różne grupy tempa wolne (dla bpm<90) umiarkowane (dla bpm od <=90 do >= 120) oraz szybkie (dla bpm <120). Taki zabieg pomaga w ujrzeniu dominacji jednej z tych grup nad innymi .

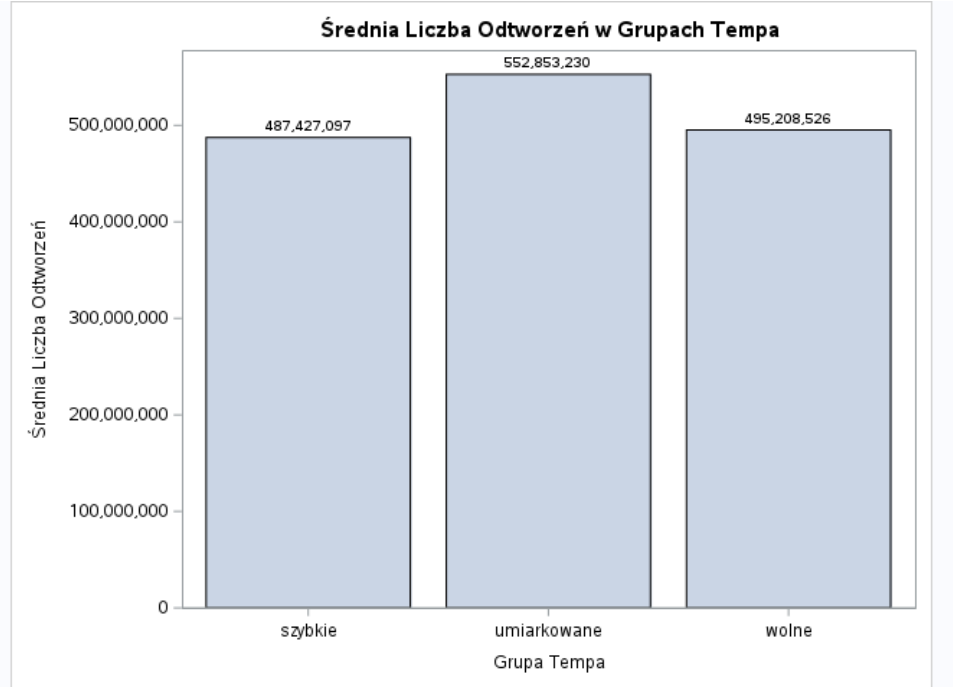
```
DATA spotify_binned;
    SET PROJEKT.tempo;
    LENGTH Tempo_Group $15;
    IF BPM < 90 THEN Tempo_Group = "wolne";
    ELSE IF 90 <= BPM <= 120 THEN Tempo_Group = "umiarkowane";
    ELSE Tempo_Group = "szybkie";
RUN;

PROC MEANS DATA=spotify_binned NOPRINT;
    CLASS Tempo_Group;
    VAR Streams;
    OUTPUT OUT=tempo_stats MEAN=Mean_Streams;
RUN;

PROC SGPLOT DATA=tempo_stats;
    VBAR Tempo_Group / RESPONSE=Mean_Streams DATALABEL;
    FORMAT Mean_Streams COMMA15.;
    TITLE "Średnia Liczba Odtworzeń w Grupach Tempa";
    XAXIS LABEL="Grupa Tempa";
    YAXIS LABEL="Średnia Liczba Odtworzeń";
RUN;
```

Kod 10 – Wykres słupkowy

Jako wynik powyższego kodu otrzymujemy taki wykres.



Wykres 4 – Średnia liczba odtworzeń w grupach tempa

3.Wnioski z przeprowadzonej analizy

Analiza zależności między tempem utworu a jego popularnością wykazała, że utwory o umiarkowanym tempie (90-120 BPM) cieszą się największą popularnością, osiągając średnio około 553 milionów odtworzeń. To sugeruje, że takie tempo jest najbardziej atrakcyjne dla szerokiego grona słuchaczy, co czyni je dominującym wyborem w muzyce masowej. Wolniejsze utwory (poniżej 90 BPM) również mają wysoką średnią liczbę odtworzeń (~495 milionów), co wskazuje na ich znaczącą rolę w tworzeniu relaksujących i emocjonalnych doświadczeń muzycznych. Szybsze utwory (powyżej 120 BPM) uzyskały najniższą średnią liczbę odtworzeń (~487 milionów), co może świadczyć o ich bardziej niszowej naturze, związanej z określonymi gatunkami i sytuacjami.

Popularność umiarkowanego tempa wynika prawdopodobnie z jego uniwersalności i zdolności do sprawdzania się w różnych kontekstach – od codziennego słuchania po wykorzystanie w popularnych playlistach. Wolniejsze utwory przyciągają słuchaczy preferujących spokojniejsze, emocjonalne brzmienia, podczas gdy szybkie tempo może być atrakcyjne głównie w określonych zastosowaniach, takich jak muzyka klubowa czy treningowa.

Dla artystów i producentów wyniki te wskazują, że tworzenie utworów w umiarkowanym tempie zwiększa szanse na masową popularność, choć warto pamiętać o

potencjale wolniejszych utworów w budowaniu głębszej więzi z odbiorcami. Szybsze utwory, choć mniej popularne w ogólnej skali, mogą trafiać do bardziej wyspecjalizowanych grup słuchaczy.

Analiza nr. 3— Analiza tonacji utworów w kontekście daty ich wydania pośród najpopularniejszych .

1.Wyjaśnienie celu szczegółowego

Celem szczegółowym analizy jest zbadanie, jak tonacja utworów (klucz muzyczny key oraz tryb mode) zmieniały się w kontekście daty ich wydania. Analiza pozwoli odpowiedzieć na pytania takie jak:

-Czy określone tonacje były bardziej popularne w określonych latach?

-Czy można zauważyć wzrost lub spadek popularności niektórych tonacji na przestrzeni lat?

-Czy utwory w trybie durowym (Major) lub molowym (Minor) dominowały w poszczególnych latach?

2. Opis procesu uzyskania danych wynikowych

Jak we wcześniejszych analizach zaczynamy utworzeniem tabeli z interesującymi nas kolumnami w tym przypadku skupimy się na released_date {dacie wydania) oraz key (kluczu utworu) oraz mode(czyli trybie muzycznym).

```
PROC SQL ;
CREATE TABLE PROJEKT.tempo as
SELECT track_name as utwór , key as klucz ,mode as tryb ,released_year as rok_wydania from PROJEKT.PROJEKT;
RUN;
QUIT;

PROC DATASETS NOLIST NODETAILS;
CONTENTS DATA= WORK.query OUT= WORK.details;
RUN;

PROC PRINT DATA=WORK.details;
Run;
```

Kod 11 – Utworzenie tabeli do analizy 3

Do tabeli dodane zostały nazwy utworów w celu łatwiejszego rozeznania po danych



KOD LOG REZULTATY DANE WYNIKOWE

Tabela: PROJEKT.TEMPO | Wyświetlanie: Nazwy kolumn | Filtr: (brak)

Kolumny

- Wybierz wszystko
- utwór
- klucz
- tryb
- rok_wydania

Właściwość	Wartość
Etykieta	
Nazwa	
Długość	
Typ	
Format	
Informat	

Wiersze razem: 953 Kolumn razem: 4 Wiersze 1-100

	utwór	klucz	tryb	rok_wydania
1	Seven (feat. Latto) (Explicit Ver.)	B	Major	2023
2	LALA	C#	Major	2023
3	vampire	F	Major	2023
4	Cruel Summer	A	Major	2019
5	WHERE SHE GOES	A	Minor	2023
6	Sprinter	C#	Major	2023
7	Ella Baila Sola	F	Minor	2023
8	Columbia	F	Major	2023
9	fukumean	C#	Minor	2023
10	La Bebe - Remix	D	Minor	2023
11	un x100to	F#	Minor	2023
12	Super Shy	F	Minor	2023
13	Flowers		Major	2023
14	Daylight	D	Minor	2023
15	As It Was	F#	Minor	2022
16	Kill Bill	G#	Major	2022
17	Cupid - Twin Ver.	B	Minor	2023
18	What Was I Made For? [From The Motion Picture "Barbie"]		Major	2023
19	Classy 101	B	Major	2023
20	Like Crazy	G	Major	2023
21	LADY GAGA	F	Minor	2023
22	I Can See You (Taylor¿½i¿½s Version) (From The	F#	Major	2023
23	I Wanna Be Yours		Minor	2013

Tabela 4 - Dane wejściowe do analizy 3

W celu szczegółowego wglądu w rozkład liczby utworów dla każdej tonacji w danym roku oraz zauważenia anomalii lub nietypowych wyników generujemy dość spora tabele która będzie przedstawiać liczbę utworów w każdej tonacji dla każdego roku.

```
PROC FREQ DATA=PROJEKT.tempo;
    TABLES klucz*rok_wydania / NOCUM NOPERCENT OUT=key_trends;
RUN;
```

Kod 12 –sprawdzenie częstotliwości występowania danej tonacji

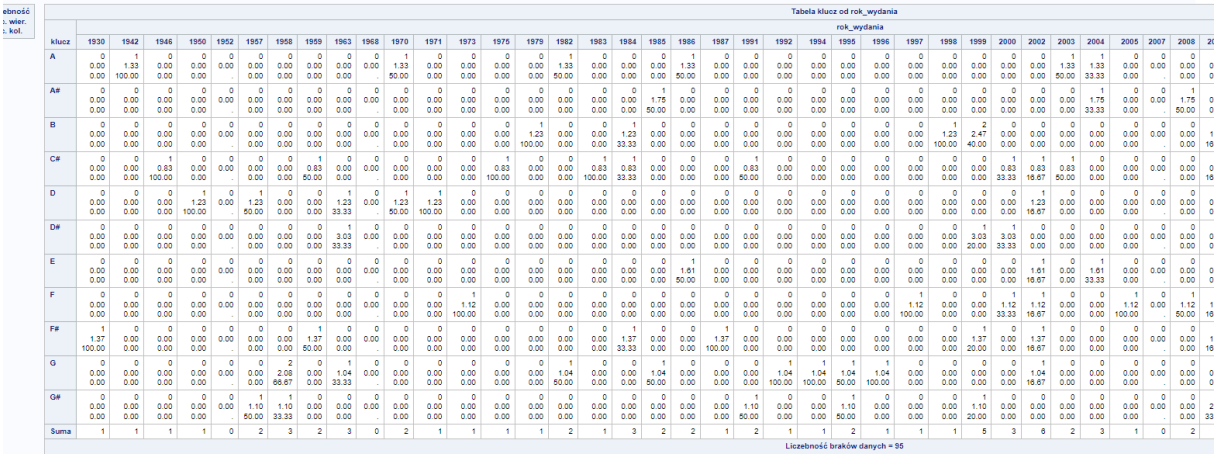


Tabela klucz od rok_wydania

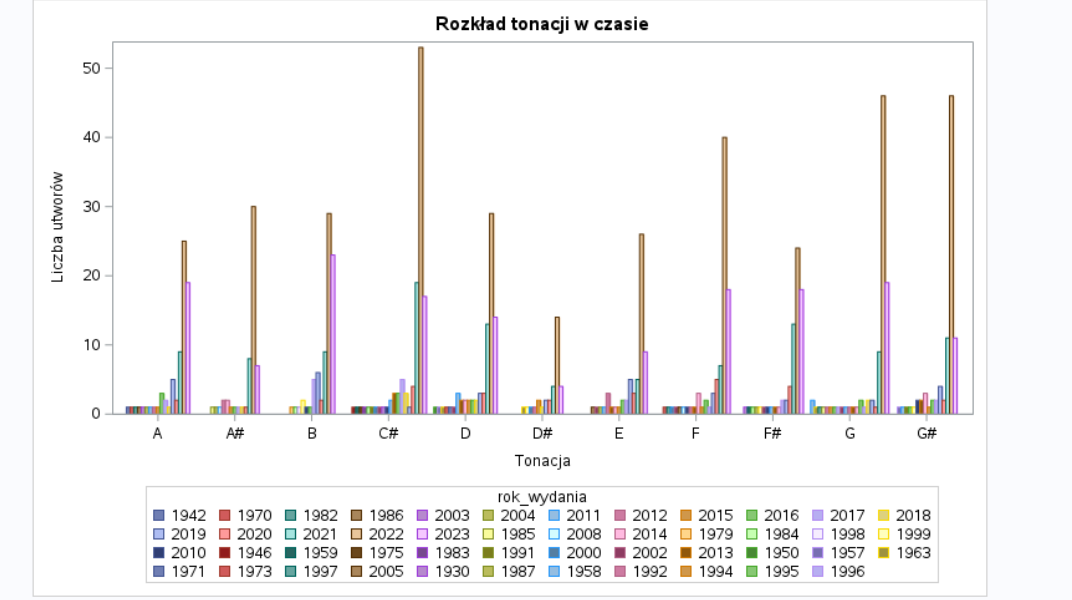
| klucz | rok_wydania | | |

Do kodu została dodana formuła ods graphics ,aby wykres był bardziej czytelny poprzez jego przepełnienie danymi.

```
ODS GRAPHICS / WIDTH=8in HEIGHT=5in;
PROC SGPLOT DATA=key_trends;
    VBAR klucz/ GROUP=rok_wydania GROUPDISPLAY=cluster RESPONSE=count;
    XAXIS LABEL="Tonacja";
    YAXIS LABEL="Liczba utworów";
    TITLE "Rozkład tonacji w czasie";
RUN;
```

Kod 13 - Wykres słupkowy

Na wykresie możemy dostrzec dużą dominacje tonacji c# oraz roku 2022 ,co może być spowodowane jego dużym występowaniem w trendujących piosenkach na platformach streamingowych.



Wykres 5 – Rozkład tonacji w czasie

3.Wnioski z przeprowadzonej analizy

Na podstawie analizy danych dotyczących tonacji utworów w kontekście roku ich wydania można zaobserwować wyraźne trendy w muzyce, które odzwierciedlają zmieniające się preferencje słuchaczy na przestrzeni czasu. Pewne tonacje, takie jak C Major i A Minor, wydają się dominować w wybranych okresach, co może sugerować ich uniwersalność lub lepsze dopasowanie do ówczesnych nastrojów społecznych. Analiza wykazała także, że tonacje molowe zyskują na popularności w określonych latach, co może być powiązane z melancholijnymi nastrojami słuchaczy. Z kolei tonacje durowe są bardziej powszechne w okresach pozytywnych zmian.

Wykresy trendów w czasie wskazują na wyraźne wzrosty i spadki popularności niektórych tonacji, co może być wynikiem wpływu określonych gatunków muzycznych lub twórczości popularnych artystów. Zauważono również, że pewne tonacje są częściej wybierane w najbardziej streamowanych utworach, co sugeruje ich potencjalny wpływ na sukces komercyjny.

Ogólnie rzecz biorąc, analiza ta podkreśla znaczenie tonacji jako istotnego elementu w kompozycji muzycznej i jej roli w kształtowaniu emocji słuchaczy. Wyniki mogą być cennym źródłem informacji dla artystów, producentów muzycznych oraz platform streamingowych, pomagając lepiej dostosować twórczość i algorytmy rekomendacji do dynamicznych preferencji rynku.

Analiza nr. 4— Analiza artystów najczęściej występujących na playlistach Spotify oraz Apple music.

1.Wyjaśnienie celu szczegółowego

Celem szczegółowym tej analizy jest zidentyfikowanie najczęściej odtwarzanych artystów na Spotify oraz zrozumienie ich popularności w kontekście liczby utworów oraz playlist, na których się znajdują. Analiza ma na celu określenie, którzy artyści dominują na platformie, poprzez zliczenie wystąpień ich piosenek w zestawie danych oraz sumaryczną liczbę playlist, w których te utwory się pojawiają. Dzięki temu możliwe jest stworzenie rankingu popularności artystów, który może dostarczyć cennych informacji dla różnych interesariuszy branży muzycznej.

2. Opis procesu uzyskania danych wynikowych

Tak jak we wcześniejszych analizach zaczynamy utworzeniem tabeli z interesującymi nas kolumnami podczas tej analizy zastosujemy artist(s)_name jako nazwy artystów oraz in_spotify_playlists czyli kolumnę odpowiedzialną za zliczenie występowania utworów na poszczególnych playlistach oraz in_apple_playlists analogicznie w tym samym celu . Do tego użyliśmy poniższego kodu.

```
PROC SQL;
CREATE TABLE PROJEKT.WYKONAWCY AS
SELECT "artist(s)_name"n AS wykonawca,  in_spotify_playlists FROM PROJEKT.PROJEKT;
QUIT;
```

Kod 14 – Utworzenie tabeli do analizy 4

Wiersze razem: 953 Kolumn razem: 2 Wiersze 1-100

	wykonawca	in_spotify_playlists
1	Latto, Jung Kook	553
2	Myke Towers	1474
3	Olivia Rodrigo	1397
4	Taylor Swift	7858
5	Bad Bunny	3133
6	Dave, Central Cee	2186
7	Eslabon Armado, Peso Pluma	3090
8	Quevedo	714
9	Gunna	1096
10	Peso Pluma, Yng Lvcas	2953
11	Bad Bunny, Grupo Frontera	2876
12	NewJeans	422
13	Miley Cyrus	12211
14	David Kushner	3528
15	Harry Styles	23575
16	SZA	8109
17	Fifty Fifty	2942
18	Billie Eilish	873
19	Feid, Young Miko	2610
20	Jimin	596
21	Gabito Ballesteros, Junior H	332
22	Taylor Swift	516
23	Arctic Monkeys	12855

Tabela 5 – Dane wejściowe do analizy 4

W celu zniwelowania problemu z nazwą posiadającą nawiasy musiałem dać ją w cudzysłów oraz dodać literkę „n” .

Jako kolejny krok postanowiłem stworzyć tabelkę która pokażę 10 najczęściej występujących artystów na spotify. Jako pierwsze rozdzieliłem artystów na pojedyncze wiersze.

```
DATA artysci_rozdzieleni;
    SET PROJEKT.WYKONAWCY;
    LENGTH artysci $50;
    DO i = 1 TO COUNTW(wykonawca, ',');
        artysci = STRIP(SCAN(wykonawca, i, ','));
        OUTPUT;
    END;
    KEEP artysci in_spotify_playlists;
RUN;
```

Kod 15 – Rozdzielenie artystów

Następnie zsumowałem liczby utworów oraz playlist dla każdego artysty oraz wyświetliłem top 10 w tabeli.

```
PROC SQL;
CREATE TABLE artysci_suma AS
SELECT artysci, COUNT(*) AS wszystkie_nuty, SUM(in_spotify_playlists) AS wszystkie_playlisty FROM artysci_rozdzieleni
GROUP BY artysci
ORDER BY wszystkie_playlis
PROC SQL;
CREATE TABLE PROJEKT.WYKONAWCY AS
SELECT
    "artist(s)_name"n AS wykonawca,
    in_spotify_playlists
FROM PROJEKT.PROJEKT;
QUIT;


DATA artysci_rozdzieleni;
    SET PROJEKT.WYKONAWCY;
    LENGTH artysci $50;
    DO i = 1 TO COUNTW(wykonawca, ',');
        artysci = STRIP(SCAN(wykonawca, i, ','));
        OUTPUT;
    END;
    KEEP artysci in_spotify_playlists;
RUN;


PROC SQL;
CREATE TABLE artysci_suma AS
SELECT
    artysci,
    COUNT(*) AS wszystkie_utwory,
    SUM(in_spotify_playlists) AS wszystkie_playlisty
FROM artysci_rozdzieleni
GROUP BY artysci
ORDER BY wszystkie_playlisty DESC;
QUIT;
```

Kod 16 – zsumowanie liczb utworów oraz playlist

```
PROC PRINT DATA=artysci_suma(OBS=10) NOOBS;
TITLE "Top 10 Artyści z Największą Liczbą Playlist i Utworów";
RUN;
tys DESC;
QUIT;
```

Kod 17 - Wyświetlanie pierwszej 10

W wyniku powyższego kodu 15,16 oraz 17 otrzymaliśmy następującą tabele.

Top 10 Artyści z Największą Liczbą Playlist i Utworów

artysci	wszystkie_utwory	wszystkie_playlisty
The Weeknd	37	233079
Eminem	9	155091
Ed Sheeran	14	142877
Taylor Swift	38	137766
Bad Bunny	39	131006
Dua Lipa	9	119490
Kendrick Lamar	23	113963
Harry Styles	17	110026
Coldplay	5	105218
Dr. Dre	5	104608

Tabela 6 – Top 10 artystów z największą liczbą playlist i utworów na Spotify

Następnie ponawiamy wszystkie powyższe kroki aczkolwiek zamiast in_spotify_playlists stosujemy in_apple_playlists ,w celu osiągnięcia wyników dla apple music. Użyty kod jest bliźniaczo podobny.

```sql
DATA artysci_rozdzieleni;
    SET PROJEKT.WYKONAWCY;
    LENGTH artysci $50;
    DO i = 1 TO COUNTW(wykonawca, ',');
        artysci = STRIP(SCAN(wykonawca, i, ','));
        OUTPUT;
    END;
    KEEP artysci in_apple_playlists;
RUN;


PROC SQL;
CREATE TABLE artysci_suma AS
SELECT artysci, COUNT(*) AS wszystkie_nuty, SUM(in_apple_playlists) AS wszystkie_playlisty FROM artysci_rozdzieleni
GROUP BY artysci
ORDER BY wszystkie_playlis
PROC SQL;
CREATE TABLE PROJEKT.WYKONAWCY AS
SELECT
    "artist(s)_name"n AS wykonawca,
    in_apple_playlists
FROM PROJEKT.PROJEKT;
QUIT;

PROC SQL;
CREATE TABLE artysci_suma AS
SELECT
    artysci,
    COUNT(*) AS wszystkie_utwory,
    SUM(in_apple_playlists) AS wszystkie_playlisty
FROM artysci_rozdzieleni
GROUP BY artysci
ORDER BY wszystkie_playlisty DESC;
QUIT;


PROC PRINT DATA=artysci_suma(OBS=10) NOOBS;
TITLE "Top 10 Artyści z Największą Liczbą Playlist i Utworów";
RUN;
```

Kod 18 - Top 10 artystów z największą liczbą playlist i utworów na Apple Music

Top 10 Artyści z Największą Liczbą Playlist i Utworów

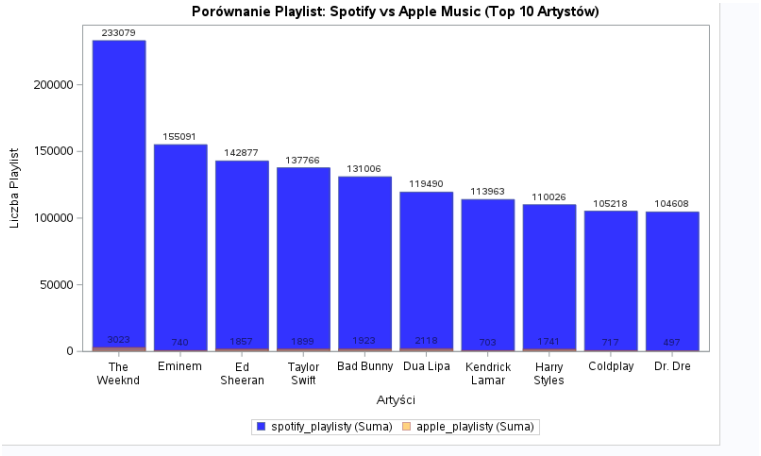
artysci	wszystkie_utwory	wszystkie_playlisty
The Weeknd	37	3023
Dua Lipa	9	2118
Bad Bunny	39	1923
Taylor Swift	38	1899
Ed Sheeran	14	1857
Harry Styles	17	1741
Drake	19	1370
Justin Bieber	6	1340
Calvin Harris	6	1232
Doja Cat	10	1151

Tabela 7 - Top 10 artystów z największą liczbą playlist i utworów na Apple Music

W celu lepszej Wizualizacji zastosowany został wykres słupkowy (wykres 6)

```sql
PROC SGPLOT DATA=artysci_suma(OBS=10);
    VBAR artysci / RESPONSE=spotify_playlisty DATALABEL
                   FILLATTRS=(COLOR=BLUE) TRANSPARENCY=0.2;
    VBAR artysci / RESPONSE=apple_playlisty DATALABEL
                   FILLATTRS=(COLOR=ORANGE) TRANSPARENCY=0.5;
    TITLE "Porównanie Playlist: Spotify vs Apple Music (Top 10 Artystów)";
    XAXIS LABEL="Artyści" DISCRETEORDER=DATA;
    YAXIS LABEL="Liczba Playlist";
RUN;
```

Kod 19 – Wykres słupkowy



Wykres 6 – Porównanie wyników Apple Music oraz Spotify

3.Wnioski z przeprowadzonej analizy

Najczęściej pojawiającym się artystą na playlistach Spotify jest The Weeknd (233,079 playlist), z dużą przewagą nad kolejnymi artystami. Eminem (155,091 playlist) oraz Ed Sheeran (142,877 playlist) zajmują odpowiednio drugie i trzecie miejsce. Ogólnie widoczna jest duża liczba playlist Spotify przypadających na popularnych artystów, co sugeruje ich szeroką obecność w różnych gatunkach i regionach. Artyści tacy jak Dua Lipa i Bad Bunny wykazują stosunkowo równomierne występowanie na obu platformach, co może świadczyć o ich globalnym zasięgu i popularności. Warto jednak zauważyć, że liczba playlist na Apple Music jest ogólnie niższa niż na Spotify. Najbardziej popularni artyści na Apple Music, tacy jak The Weeknd (3,023 playlist) czy Ed Sheeran (1,857 playlist), nie osiągają tak imponujących wyników jak na Spotify. Niektórzy artyści, tacy jak Kendrick Lamar i Dr. Dre, mają wyraźnie więcej playlist na Spotify niż na Apple Music. To może wynikać z preferencji użytkowników Spotify dla określonych gatunków, takich jak hip-hop i rap. Artyści, którzy dominują na Spotify, należą do różnych gatunków muzycznych: od popu (Taylor Swift, Harry Styles) przez hip-hop (Eminem, Kendrick Lamar) po muzykę latynoską (Bad Bunny). To sugeruje, że Spotify ma szeroki zasięg gatunkowy, co może być jednym z powodów ich większej liczby playlist. Spotify wydaje się być bardziej dynamiczną platformą, jeśli chodzi o różnorodność i liczebność playlist, co może wynikać z jej społecznościowego charakteru. Apple Music ma bardziej ograniczoną liczbę playlist, ale liczby te mogą odzwierciedlać różnice w sposobie korzystania z platformy przez użytkowników. Najbardziej znani artyści, tacy jak The Weeknd, Eminem, czy Ed Sheeran, skutecznie docierają do szerokiego grona odbiorców na obu platformach.

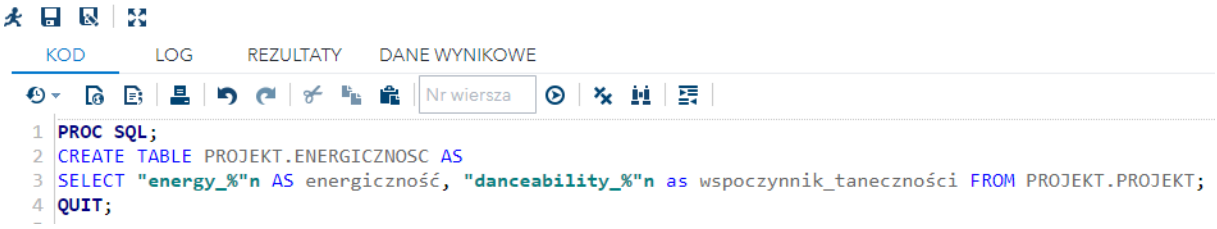
Analiza nr. 5— Analiza wpływu energiczności piosenek na ich taneczność

1.Wyjaśnienie celu szczegółowego

Celem szczegółowym tej analizy jest zbadanie, jak energiczność piosenek wpływa na ich taneczność, co może dostarczyć cennych informacji dla przemysłu muzycznego optymalizując playlisty przeznaczone na imprezy lub gdzieś gdzie taniec jest kluczowym elementem.

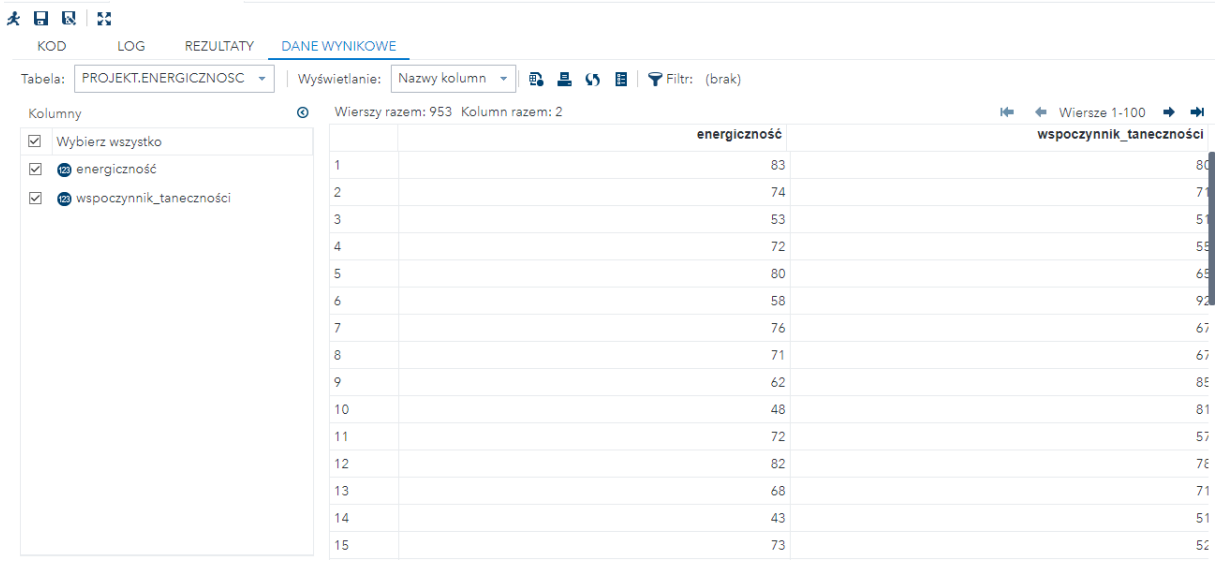
2. Opis procesu uzyskania danych wynikowych

Tak jak w poprzednich analizach zaczynami utworzeniem tabeli z potrzebnymi nam kolumnami. Podczas tej analizy zastosujemy danceability_% (,która jest współczynnikiem taneczności utworu) oraz Energy_% (która jest współczynnikiem energiczności).



Kod 20 – Utworzenie tabeli do analizy 5

Tak przedstawia się wygenerowany zbiór danych.



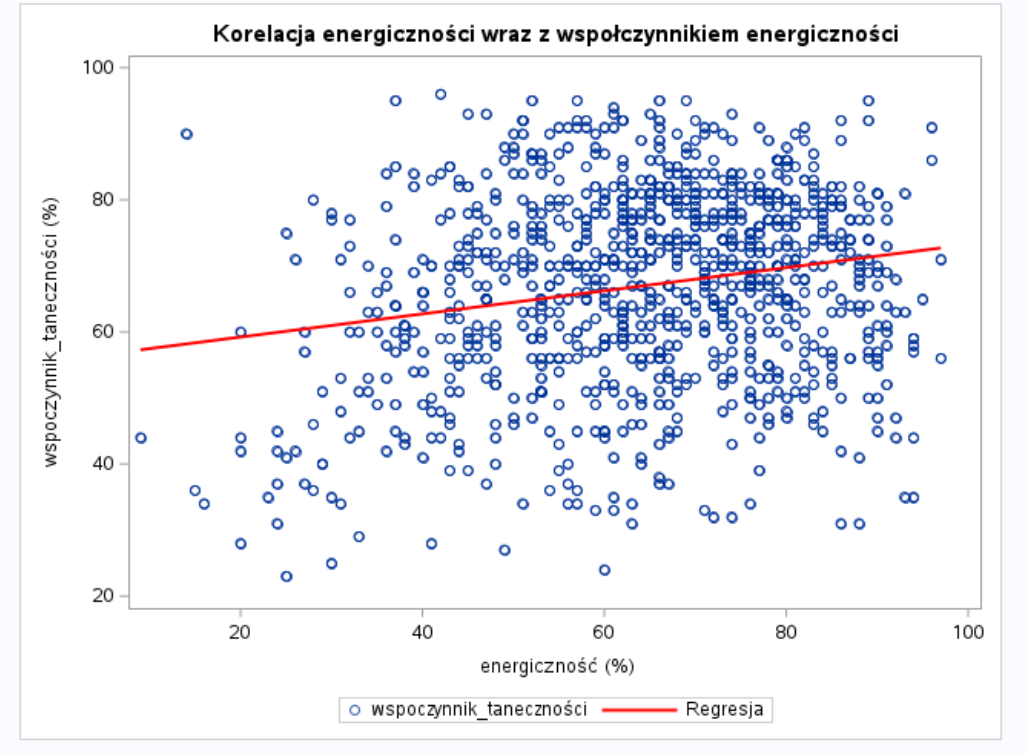
	energiczność	wspoczynnik_taneczności
1	83	80
2	74	71
3	53	51
4	72	58
5	80	65
6	58	92
7	76	67
8	71	67
9	62	85
10	48	81
11	72	57
12	82	78
13	68	71
14	43	51
15	73	52

Tabela 8 – Dane wejściowe do analizy 5

Na początku wygenerujemy wykres Scatter plot z linią regresji , który umożliwi wizualizację związku między energicznością a tanecznością, a liniowa regresja pozwala oszacować ogólny trend w tym celu zastosowany został poniższy kod .

```
proc sgplot data=PROJEKT.ENERGICZNOSC;
    scatter x=energiczność y=wspoczynnik_taneczności / transparency=0.2;
    reg x=energiczność y=wspoczynnik_taneczności / lineattrs=(color=red thickness=2);
    xaxis label="energiczność (%)";
    yaxis label="wspoczynnik_taneczności (%)";
    title "Korelacja energiczności wraz z współczynnikiem energiczności";
run;
```

Kod 21 – Wykres Scatter Plot



Wykres 7 – Korelacja energiczności utworów wraz z współczynnikiem taneczności

Powyższy wykres ukazuje ,że Piosenki o wysokim poziomie energiczności częściej mają również wyższe wartości taneczności, co może wynikać z szybszego tempa, intensywnych rytmów lub bardziej dynamicznego charakteru muzyki aczkolwiek można zauważyć parę wyjątków .

W kolejnym etapie wygenerujemy wykres Box plot (pomoże nam zobrazować jak współczynnik taneczności różni się w grupach energiczności) oraz wygenerujemy do niego statystyki opisowe w tym celu podzieliliśmy energiczność na 3 różne grupy :

- niską energiczność (od 0% do 33%)

- średnią energiczność (od 33% do 66%)

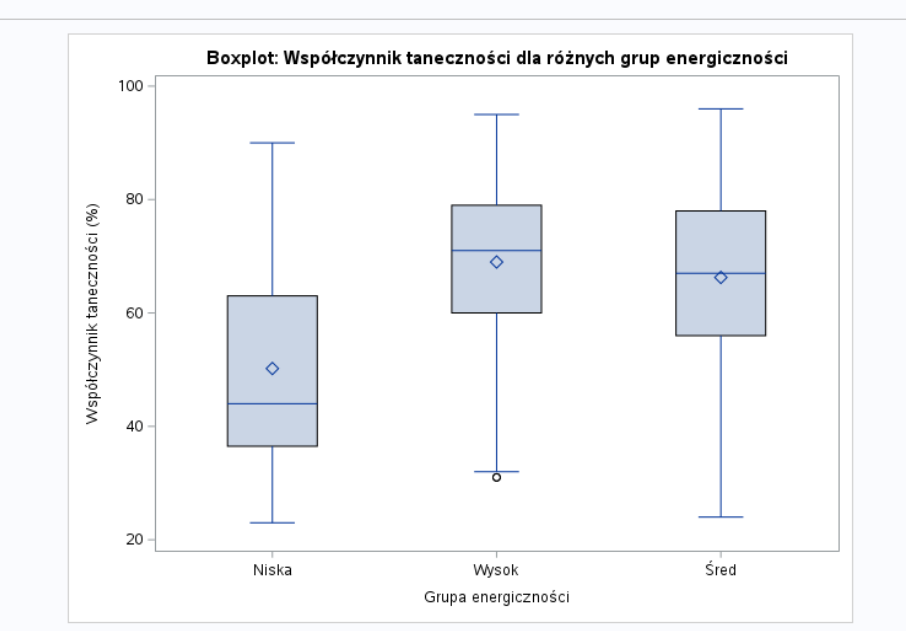
- wysoką energiczność (od 66% do 100%)

```sas
data PROJEKT.ENERGICZNOSC_GRUPY;
    set PROJEKT.ENERGICZNOSC;
    if energiczność < 33 then grupa_energiczność = "Niska";
    else if energiczność < 66 then grupa_energiczność = "Średnia";
    else grupa_energiczność = "Wysoka";
run;

proc sgplot data=PROJEKT.ENERGICZNOSC_GRUPY;
    vbox współczynnik_taneczności / category=grupa_energiczność;
    xaxis label="Grupa energiczności";
    yaxis label="Współczynnik taneczności (%)";
    title "Boxplot: Współczynnik taneczności dla różnych grup energiczności";
run;
proc means data=PROJEKT.ENERGICZNOSC_GRUPY mean median std min max;
    class grupa_energiczność;
    var współczynnik_taneczności;
    title "Statystyki opisowe dla grup energiczności";
run;
```

Kod 22 – Wykres box plot

W wyniku powyższego kodu otrzymujemy taki wykres



Wykres 8 – Współczynnik taneczności dla różnych grup energiczności

W wyniku procedury MEANS ,która domyślnie umieszcza w oknie rezultaty informacje statystyczne dotyczące agregowanych zmiennych otrzymujemy taki Rezultat .

Statystyki opisowe dla grup energiczności

Procedura MEANS

Zmienna analizowana: współczynnik_taneczności						
grupa_energiczność	N obs.	Średnia	Mediana	Odch. std.	Minimum	Maksimum
Niska	40	50.2000000	44.0000000	17.4740834	23.0000000	90.0000000
Wysok	483	68.9855072	71.0000000	13.1960087	31.0000000	95.0000000
Śred	430	66.2651163	67.0000000	14.8429052	24.0000000	96.0000000

Rezultat 4 – Statystyki opisowe dla grup energiczności

Wykres pozwala nam powiedzieć ,że Mediana współczynnika taneczności może rosnąć wraz ze wzrostem energiczności, co sugeruje, że bardziej energiczne utwory są bardziej taneczne. Rozrzut danych (odległość między kwartylami) może być większy dla utworów o wysokiej energiczności, co oznacza większą różnorodność ich taneczności.

Tabela XX ukazuje nam ,że Grupa o wysokiej energiczności może mieć wyższą średnią taneczność niż grupy o średniej lub niskiej energiczności. Wysokie wartości w grupie Odchylenie standardowe "Wysoka energiczność" sugerują większe zróżnicowanie taneczności w tej kategorii.

3.Wnioski z przeprowadzonej analizy

Analiza wykazała, że między energicznością a tanecznością utworów istnieje bardzo słaba. Chociaż bardziej energiczne utwory są nieco bardziej taneczne, zależność ta nie jest silna ani wyraźna.

Wykres Box plot ukazał różnice w taneczności między grupami energiczności. Utwory o niskiej energiczności charakteryzują się niższymi wartościami taneczności, natomiast w grupach średniej i wysokiej energiczności mediana oraz rozrzut taneczności są wyższe. W szczególności w grupie wysokiej energiczności zaobserwowano największe zróżnicowanie taneczności, co może wynikać z różnorodności gatunków muzycznych.

Statystyki opisowe potwierdziły, że średnia i mediana taneczności rosną wraz ze wzrostem energiczności. Jednocześnie w grupie wysokiej energiczności odchylenie standardowe taneczności jest najwyższe, co wskazuje na większe rozproszenie danych. Wykres punktowy pokazał, że chociaż większość utworów o wysokiej energiczności jest bardziej taneczna, to brak jest wyraźnego liniowego trendu.

Podsumowanie analiz

Projekt obejmował kompleksową analizę danych dotyczących muzyki dostępnej na platformach streamingowych, takich jak Spotify i Apple Music. Badanie miało na celu identyfikację kluczowych trendów i czynników wpływających na popularność utworów oraz preferencje słuchaczy. Analiza objęła dane z lat 1930–2023, dostarczając wszechstronnych informacji o popularności artystów, cechach muzycznych utworów oraz ich sukcesach komercyjnych. Poniżej przedstawiono szczegółowe wnioski z poszczególnych analiz.

1. Analiza roku wydania najbardziej trendujacych utworów

- Starsze utwory, zwłaszcza wydane przed 2000 rokiem, osiągają wyższą średnią liczbę odtworzeń niż nowsze kompozycje. Może to wynikać z ich statusu jako klasyków lub kultowych hitów, które zyskały uznanie w czasie i cieszą się nostalgią słuchaczy.
- Analiza korelacji pokazała, że zależność między rokiem wydania a popularnością nie jest liniowa. Starsze utwory są obecne na tematycznych playlistach, które zapewniają im stałą widoczność i odtwarzalność.
- Współczynniki korelacji Spearmana i Pearsona ujawniły, że inne czynniki, takie jak trendy, promocja i obecność w kulturze masowej, odgrywają kluczową rolę w popularności.

2. Analiza tepa utworów w kontekście ich popularności

- Umiarkowane tempo (90-120 BPM) cieszy się największą popularnością, z wynikami średnio 553 milionów odtworzeń. Jest to idealny zakres dla muzyki masowej, zarówno w kontekście codziennego słuchania, jak i popularnych playlist.
- Wolne tempo (<90 BPM) również wykazuje wysoką popularność (~495 milionów odtworzeń), co wskazuje na jego atrakcyjność w tworzeniu relaksujących, emocjonalnych doświadczeń muzycznych.
- Szybkie tempo (>120 BPM) okazało się mniej popularne (~487 milionów odtworzeń), co może być związane z jego bardziej niszowym charakterem, typowym dla określonych gatunków, takich jak muzyka klubowa czy treningowa.

3. Analiza tonacji utworów w kontekście daty ich wydania pośród najpopularniejszych .

- Tonacje takie jak C Major i A Minor wyróżniają się swoją popularnością w różnych okresach, co wskazuje na ich uniwersalność oraz zdolność do dopasowania do szerokich preferencji słuchaczy.
- Tryb molowy (Minor) zyskał na znaczeniu w niektórych latach, co może być powiązane z melancholijnymi nastrojami społecznymi lub trendami w kulturze masowej.
- Z kolei tryb durowy (Major) dominował w bardziej optymistycznych okresach, sugerując, że tonacja wpływa na odbiór emocjonalny utworu i jego sukces.

4. Analiza artystów najczęściej występujących na playlistach spotify oraz apple music.

- The Weeknd okazał się najczęściej występującym artystą na playlistach Spotify (233,079 playlist), co potwierdza jego globalną popularność. Na kolejnych miejscach znaleźli się Eminem (155,091 playlist) i Ed Sheeran (142,877 playlist).
- Apple Music charakteryzuje się mniejszą liczbą playlist niż Spotify. The Weeknd prowadzi również na tej platformie (3,023 playlist), ale różnice w liczbach playlist są wyraźne, co może wynikać z różnic w preferencjach użytkowników oraz funkcjonalnościach platform.
- Popularni artyści na Spotify reprezentują różnorodne gatunki muzyczne: od popu (Taylor Swift, Harry Styles), przez hip-hop (Eminem, Kendrick Lamar), po muzykę latynoską (Bad Bunny), co wskazuje na szeroki zakres preferencji użytkowników tej platformy.

5. Analiza wpływu energiczności piosenek na ich taneczność

- Piosenki o wyższym poziomie energiczności mają wyższą taneczność, choć zależność ta jest stosunkowo słaba. Wysoka energia utworów często wiąże się z szybszym tempem, intensywnymi rytmami i dynamicznym charakterem, co sprzyja ich atrakcyjności w kontekście tanecznym.
- Wykres Box plot ujawnił, że utwory o wysokiej energiczności charakteryzują się większą różnorodnością taneczności, co wskazuje na zróżnicowanie gatunkowe.
- Statystyki opisowe potwierdziły, że średnia i mediana taneczności rosną wraz ze wzrostem energiczności, co może być kluczową wskazówką dla producentów muzycznych i twórców playlist.